

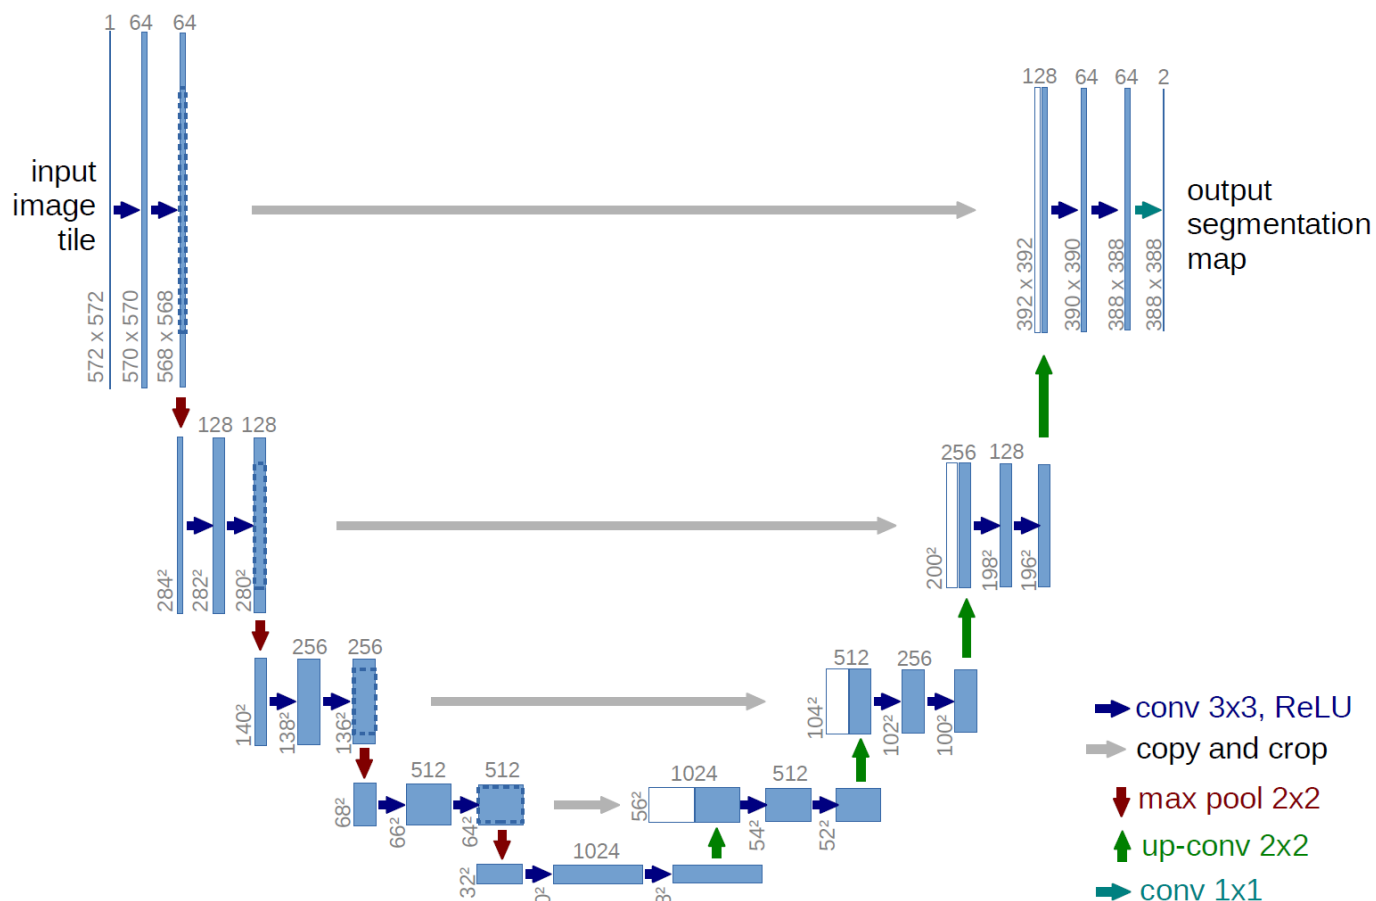
# Домашнее задание 11

## Правила:

- Дедлайн **29 мая 23:59**. После дедлайна работы не принимаются кроме случаев наличия уважительной причины.
- Выполненную работу нужно отправить на почту `mipt.stats@yandex.ru`, указав тему письма "`[ml]` Фамилия Имя - задание 11". Квадратные скобки обязательны. Если письмо дошло, придет ответ от автоответчика.
- Прислать нужно файл с кодом модели, ноутбук и его pdf-версию (без архивов). Названия файлов должны быть такими: `11.N.model.py`, `11.N.ipynb` и `11.N.pdf`, где `N` - ваш номер из таблицы с оценками.
- Решения, размещенные на каких-либо интернет-ресурсах не принимаются. Кроме того, публикация решения в открытом доступе может быть приравнена к предоставлению возможности списать.
- Для выполнения задания используйте этот ноутбук в качестве основы, ничего не удаляя из него.
- Никакой код из данного задания при проверке запускаться не будет.

## Условие

В этом задании вам предстоит реализовать модель `U-Net` для задачи семантической сегментации: `0` — не автомобиль, `1` — автомобиль. Реализация должна быть в файле `model.py`. Назовите класс с моделью `SegmenterModel`, унаследуйте его от `torch.nn.Module`, напишите метод `forward`. Ваша модель должна принимать четырёхмерные тензоры картинок (нулевая размерность — батч) и предсказывать трёхмерные тензоры (нулевая размерность — батч) из логарифмов вероятностей (логитов) каждого пикселя принадлежать классу `1`. В качестве функции ошибки при обучении используется **бинарная кросс-энтропия** в реализации с логитами — `torch.nn.BCEWithLogitsLoss()`. Переход от логитов к маске осуществляется посредством отсечения по порогу: `logits > 0`.



Нужно добиться среднего значения метрики IoU по тестовой выборке:

- **на половину баллов** — хотя бы в  $0.6$  ;
- **на полный балл** — хотя бы в  $0.8$  .

Авторское решение даёт значение  $0.95$  .

Большая часть кода в этом ноутбуке уже реализована за вас. Ваша реализация должна быть согласована с уже написанным кодом (любая разумная реализация удовлетворяет этим требованиям; если вы уверены, что это не так, то напишите в чат курса или на [ivanov.vv@phystech.edu](mailto:ivanov.vv@phystech.edu) (<mailto:ivanov.vv@phystech.edu>));

Данные — подмножество датасета [Carvana](https://www.kaggle.com/c/carvana-image-masking-challenge) (<https://www.kaggle.com/c/carvana-image-masking-challenge>) с Kaggle.

### Рекомендации:

- Используйте Google Colab . Загрузите туда `data.zip` (довольно долго), `carvana_dataset.py` и `train.py` . Эти файлы заранее скачайте себе на папку в GDrive, потом примонтируйте диск к Colab и выкачайте архив с данными оттуда. **Важно:** сначала выберите рантайм с GPU , а потом уже загружайте файлы! Файлы нужно именно загрузить, т.к. иначе работать будет слишком медленно (придётся при обучении каждый раз читать файлы по сети);
- Обучайте модель достаточно долго. Несколько десятков эпох это норма.
- Прекращайте обучение только тогда, когда лосс на тестовой выборке перестаёт падать;
- Для визуализации процесса обучения используйте `tensorboard` . Он уже интегрирован в `training loop` для вас. Запустить его можно и на своей машине: просто скачайте папку `log` с Colab и введите в терминале `tensorboard --log_dir /path/to/log` .

## Загрузка файлов и данных на Colab

Заранее сделайте папку на своём GDrive , потом примонтируйте её и скачайте оттуда все файлы.

In [ ]:

```
1 from google.colab import drive
2 drive.mount('/content/drive')
3 !cp -r ./drive/My\ Drive/segmentation_hw/* .
```

Распакуем данные на инстансе

In [ ]:

```
1 !sudo apt install pv
2 !unzip data.zip | pv -l >/dev/null
```

## Подключаем TensorBoard

Это нужно сделать до запуска скрипта с обучением. Этот виджет интерактивный. Он автоматически обновляется по мере обучения модели

In [ ]:

```
1 !pip install tensorboardx
2 !mkdir log
3 %load_ext tensorboard
4 %tensorboard --logdir ./log
```

## Обучение модели

Для вашего удобства, обучение и валидация модели вынесены в отдельный файл `train.py` . При условии, что вы правильно реализовали модель, для начала обучения достаточно запустить ячейку ниже.

На каждой итерации обученная модель сохраняется на диск в виде файла `unet_dump_recent` . Используйте это для отладки.

Каждый дамп довольно объёмный — порядка 120 мб. для авторской модели, — но если вы хотите сохранять модель на диск по какой-то другой логике, то поправьте соответствующие строки в файле `train.py` .

In [ ]:

```
1 !python train.py --n_epochs 50 --batch_size 10 --learning_rate 0.01
```

## Визуализация результатов

Импортируйте нужные библиотеки и отрисуйте предсказания модели на нескольких случайных объектах из тестовой выборки.

In [ ]:

```
1 %load_ext autoreload
2 %autoreload 2
3
4 import torch
5 import torch.utils.data as dt
6 import numpy as np
7 from tqdm.auto import tqdm
8
9 import matplotlib.pyplot as plt
10 import seaborn as sns
11
12 from model import SegmenterModel
13 from carvana_dataset import CarvanaDataset
14
15 %matplotlib inline
```

Датасет преобразуется в формат, совместимый с `torch.utils.data.DataLoader` посредством класса `CarvanaDataset`.

**Не меняйте его**, примеры использования для своих нужд вы можете найти ниже:

In [ ]:

```
1 train_data = CarvanaDataset('data/train/', 'data/train_masks/')
2 test_data = CarvanaDataset('data/test/', 'data/test_masks/')
```

Подгрузим предобученную модель. Если вы изменили логику сохранения копий модели на диск, отразите эти изменения и здесь тоже.

In [ ]:

```
1 unet = SegmenterModel().cuda()
2 unet.load_state_dict(torch.load("unet_dump_recent", map_location="cuda:0"))
3 unet.train(False);
```

Код для отрисовки предсказаний модели на одной картинке

In [ ]:

```
1 ▾ def plot_predictions_on_random_image(fitted_model: SegmenterModel,
2                                     test_data: CarvanaDataset,
3                                     seed: int = None):
4 ▾     if seed is None:
5         rvgen = np.random
6 ▾     else:
7         rvgen = np.RandomState(seed)
8
9     n_img = len(test_data.files)
10    img_idx = rvgen.randint(0, n_img)
11    img = test_data[img_idx][0]
12    true_mask = test_data[img_idx][1].squeeze(0)
13
14    pred_logits = fitted_model.forward(img.unsqueeze(0).cuda())
15 ▾    pred_logits = pred_logits\
16                    .squeeze(0).squeeze(0)\
17                    .detach().cpu().numpy()
18    pred_mask = pred_logits > 0
19
20    images_to_plot = [img.permute(1, 2, 0), true_mask, pred_mask, pred_logits]
21 ▾    ax_titles = ["Оригинал",
22                "Истинная маска",
23                "Предсказанная маска (порог = 0)",
24                "Предсказанные логиты"]
25
26    fig, axes = plt.subplots(1, 4, figsize=(20, 10))
27 ▾    for i in range(len(axes)):
28        ax = axes[i]
29        ax.imshow(images_to_plot[i], cmap="inferno")
30        ax.set_title(ax_titles[i], fontsize=15, fontweight="bold")
31        ax.set_axis_off()
```

Сравним предсказанные маски с истинными


In [ ]:

```
1 ▾ for i in range(5):
2     plot_predictions_on_random_image(unet, test_data)
```

## Оценка качества модели

В задаче семантической сегментации уместно использовать метрику IoU — *Intersection over Union* — которая равняется доле корректно предсказанных пикселей маски среди всех пикселей, которые либо модель, либо разметка считают пикселями маски:

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$



Реализуйте функцию, вычисляющую данную метрику. На вход она принимает два батча из бинарных масок одинакового размера.

In [ ]:

```
1 ▼ def iou_loss(predicted_mask_batch, target_mask_batch):  
2     """ Считает IoU по всем элементам батча """  
3  
4     loss = ...  
5     return loss
```

In [ ]:

```
1  dl_test = dt.DataLoader(test_data, shuffle=False,
2                          num_workers=8,
3                          batch_size=1)
4
5
6  test_loss = []
7  for i, (input_batch, target_mask_batch) in enumerate(tqdm(dl_test)):
8      with torch.no_grad():
9          output_logits_batch = unet(input_batch.to("cuda")).cpu()
10         output_mask_batch = output_logits_batch > 0
11         loss = iou_loss(output_mask_batch, target_mask_batch > 0)
12         test_loss.append(loss.numpy())
13 test_loss = np.hstack(test_loss)
14
15 print(f"Среднее значение IoU на тесте: {np.mean(test_loss)}")
16
17 plt.figure(figsize=(8, 5))
18 sns.distplot(test_loss);
19 plt.title("Распределение IoU на тесте")
```

Найдите какую-либо фотографию с автомобилем (в интернете или сфоткайте), обрежьте ее до нужных размеров и получите из нее маску с помощью вашей модели. Визуализируйте маску и исходную фотографию.

In [ ]:

1

Разметьте вручную область с автомобилем на этой фотографии и посчитайте IoU по ней.

In [ ]:

1

Сделайте выводы по проделанной работе.

## Бонусная часть

Попробуйте побить `baseline` в виде авторского решения:

1. Сделайте аугментацию данных;
2. Подберите оптимальную архитектуру (может отличаться от рекомендованной);
3. Обратитесь к литературе за сведениями о том, как делают fine-tuning для U-Net ;