In [1]:

```
import numpy as np
import pandas as pd
import scipy.stats as sps
from tqdm.notebook import tqdm

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.datasets import fetch_california_housing

from sklearn.base import BaseEstimator, RegressorMixin
from sklearn.ensemble import BaggingRegressor
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.ensemble import RandomForestRegressor
from sklearn.linear_model import Ridge, LinearRegression
from sklearn.tree import DecisionTreeRegressor

from sklearn.metrics import mean_squared_error as mse
from sklearn.model_selection import RandomizedSearchCV
from sklearn.model_selection import train_test_split
from sklearn.model_selection import cross_val_score
from sklearn.utils import shuffle

plt.rcParams['axes.facecolor'] = 'lightgrey'
sns.set(palette='Set2', font_scale=1.6)
```

started 12:54:53 2020-03-22, finished in 1.16s

Задача 5.2

Внимание! Перед выполнением задачи прочитайте полностью условие. В задаче используются смеси различных моделей с разными гиперпараметрами. Подумайте над тем, какой гиперпараметр как подбирать и на каком множестве. Не забудьте, что на тестовой выборке, по которой делаются итоговые выводы, ничего не должно обучаться.

1. Повторите исследование, проведенное в задаче 2 предыдущего домашнего задания, используя градиентный бустинг из `sklearn` . Сравните полученные результаты со случайным лесом. Детали:

- в качестве основы можно использовать как свое решение предыдущего задания, так и выложенное на Вики. В большинстве случаев нужно только заменить `RandomForestRegressor` на `GradientBoostingRegressor` .
- у градиентного бустинга есть также важный гиперпараметр `learning_rate` . Поясните его смысл и проведите аналогичные исследования.
- при сравнении методов по одинаковым свойствам желательно рисовать результаты на одном графике.
- обратите внимание на метод `staged_predict` у `GradientBoostingRegressor` . Он позволяет получить "кумулятивные" предсказания, то есть по первым t деревьям по всем значениям t.
- при кросс-валидации проводите достаточное количество итераций рандомизированного поиска (при $\geqslant 2$ параметров) на большой сетке параметров. Даже если долго обучается.

2. Выберите самый значимый признак согласно `feature_importances_` и визуализируйте работу первых 10 деревьев на графиках зависимости таргета от этого признака. Пример графиков смотрите в лекции.

3. Обучите градиентный бустинг на решающих деревьях, у которого в качестве инициализирующей модели используется линейная регрессия. Для этого используйте класс `GradientBoostingRegressor`, которому при инициализации в качестве параметра `init` передайте модель ридж-регрессии Ridge, которая должна быть инициализирована, но необучена. Подберите оптимальные гиперпараметры такой композиции. Как вы будете подбирать гиперпараметр ридж-регрессии? Улучшилось ли качество модели на тестовой выборке?

4. Рассмотрим модели смеси градиентного бустинга $\widehat{y}_{gb}$ и случайного леса $\widehat{y}_{rf}$ в виде

$$\widehat{y}(x) = w\widehat{y}_{gb}(x) + (1-w)\widehat{y}_{rf}(x),$$

где $w \in [0, 1]$ --- коэффициент усреднения. Подберите оптимальное значение гиперпараметра w. Удалось ли добиться улучшения качества на тестовой выборке?

Повтор исследования и сравнение со случайным лесом

В качестве данных возьмём датасет `california_housing` из библиотеки `sklearn` о стоимости недвижимости в различных округах Калифорнии. Этот датасет состоит из 20640 записей и содержит следующие признаки для каждого округа: `MedInc`, `HouseAge`, `AveRooms`, `AveBedrms`, `Population`, `AveOccup`, `Latitude`, `Longitude`. `HouseAge` и `Population` - целочисленные признаки. Остальные признаки - вещественные.

Совет. При отладке кода используйте небольшую часть данных. Финальные вычисления проведите на полных данных. Для оценки времени работы используйте `tqdm` в циклах.

In [2]:

```
housing = fetch_california_housing()
X, y = housing.data, housing.target
```

started 12:54:54 2020-03-22, finished in 13ms

In [3]:

```
X.shape
```

started 12:54:54 2020-03-22, finished in 4ms

Out[3]:

```
(20640, 8)
```

Разобьём данные на обучающую выборку и на валидацию, выделив на валидацию 25% данных.

In [4]:

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25)
```

started 12:54:54 2020-03-22, finished in 14ms

Посмотрите, как изменяется качество предсказаний градиентного бустинга в зависимости от выбранных параметров. Для этого постройте графики зависимости MSE на тестовой выборке от количества деревьев и от максимальной глубины дерева. Когда варьируете один из параметров, для другого берите значение по умолчанию.

Построение зависимости MSE от количества деревьев

Вспомогательная функция

In [5]:

```
def plot_dependence_test(param_grid, test_values, param_label,
                         metrics_label, title):
    '''
    Функция для построения графиков зависимости целевой метрики
    от некоторого параметра модели на валидационной выборке.

    Параметры.
    1) param_grid - значения исследуемого параметра,
    2) test_values - значения метрики на валидационной выборке,
    3) param_label - названия параметра,
    4) metrics_label - название метрики,
    5) title - заголовок для графика.
    '''

    plt.figure(figsize=(12, 6))
    plt.plot(param_grid, test_values, label='тестовая выборка', linewidth=4)

    plt.xlabel(param_label)
    plt.ylabel(metrics_label)
    plt.legend()
    plt.title(title)
    plt.show()
```

started 12:54:54 2020-03-22, finished in 8ms

Вычисления и построение графика

In [6]:

```
mse_values = []
n_estimators_grid = range(1, 300)
regressor = GradientBoostingRegressor(
    n_estimators=max(list(n_estimators_grid))
)
regressor.fit(X_train, y_train)
staged_predictions = regressor.staged_predict(X_test)

mse_values = [mse(prediction, y_test) for prediction in staged_predictions]
```

started 12:54:54 2020-03-22, finished in 2.76s

In [7]:

```
plot_dependence_test(n_estimators_grid, mse_values,
                     'Количество деревьев', 'MSE',
                     'Зависимость MSE от количества деревьев')
```

started 12:54:57 2020-03-22, finished in 362ms

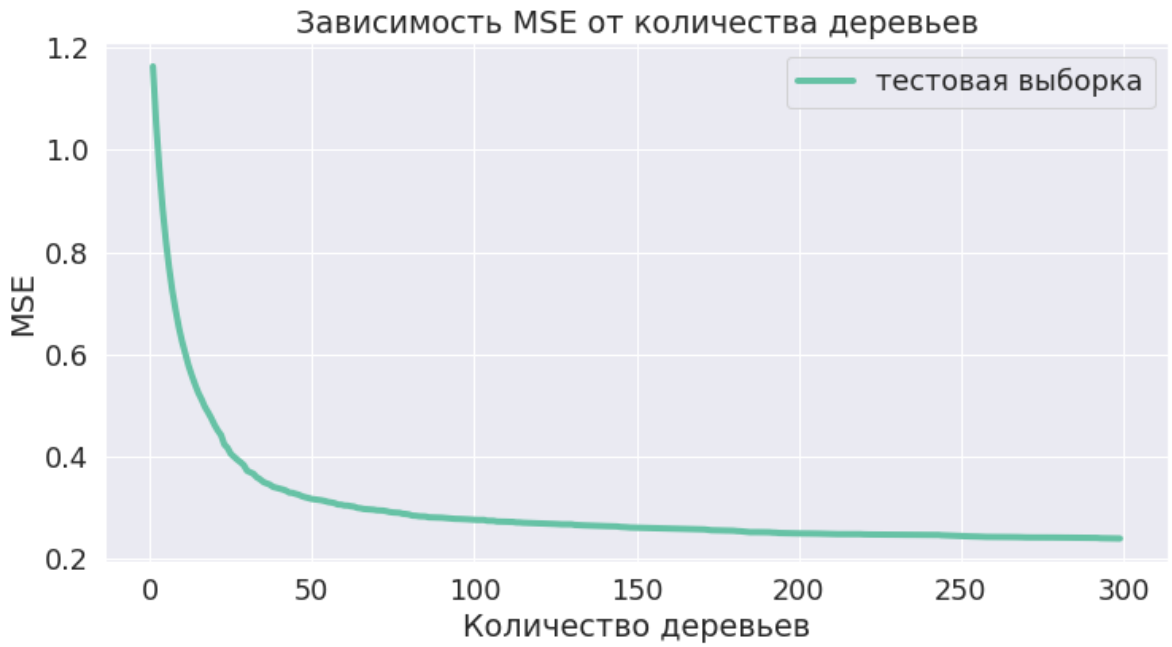

Как и при использовании случайного леса, ошибка на тестовой выборке монотонно убывает. Но если в лесе при `n_estimators`, близком к 100, `mse` практически переставала уменьшаться, то в градиентном бустинге эта разница выглядит более существенной.

Построение зависимости MSE от максимальной глубины

In [8]:

```
mse_values = []

for max_depth in tqdm(range(3, 15)):
    regressor = GradientBoostingRegressor(max_depth=max_depth,
                                          n_estimators=300)
    regressor.fit(X_train, y_train)
    predictions = regressor.predict(X_test)
    mse_values.append(mse(predictions, y_test))
```

started 12:54:57 2020-03-22, finished in 3m 31s

100% 12/12 [03:30<00:00, 17.57s/it]

In [9]:

```
plot_dependence_test(np.arange(3, 15), mse_values,
                     'Максимальная глубина дерева', 'MSE',
                     'Зависимость MSE от максимальной глубины')
```

started 12:58:28 2020-03-22, finished in 321ms

Посмотрим, что будет происходить при меньших значениях `n_estimators` .

In [10]:

```
mse_values = []

for max_depth in tqdm(range(3, 15)):
    regressor = GradientBoostingRegressor(max_depth=max_depth,
                                          n_estimators=50)
    regressor.fit(X_train, y_train)
    predictions = regressor.predict(X_test)
    mse_values.append(mse(predictions, y_test))
```

started 12:58:28 2020-03-22, finished in 1m 0.65s

100% 12/12 [01:00<00:00, 5.06s/it]

In [11]:

```
plot_dependence_test(np.arange(3, 15), mse_values,
                     'Максимальная глубина дерева', 'MSE',
                     'Зависимость MSE от максимальной глубины')
```

started 12:59:29 2020-03-22, finished in 311ms

Построение зависимости MSE от значения `learning rate`

Как мы видим, в отличие от случайного леса, при использовании градиентного бустинга стоит ограничивать глубину дерева, поскольку на каждой итерации бустинг уменьшает смещение (bias) итоговой модели, а не дисперсию.

In [36]:

```
mse_values = []

for lr in tqdm(np.linspace(0.05, 0.7, 700)):
    regressor = GradientBoostingRegressor(learning_rate=lr,
                                          n_estimators=300)
    regressor.fit(X_train, y_train)
    predictions = regressor.predict(X_test)
    mse_values.append(mse(predictions, y_test))
```

started 14:42:59 2020-03-22, finished in 31m 20s

100% 700/700 [31:20<00:00, 2.69s/it]

In [37]:

```
plot_dependence_test(np.linspace(0.05, 0.7, 700), mse_values,
                     'learning rate', 'MSE',
                     'Зависимость MSE от learning rate')
```

started 15:14:19 2020-03-22, finished in 814ms

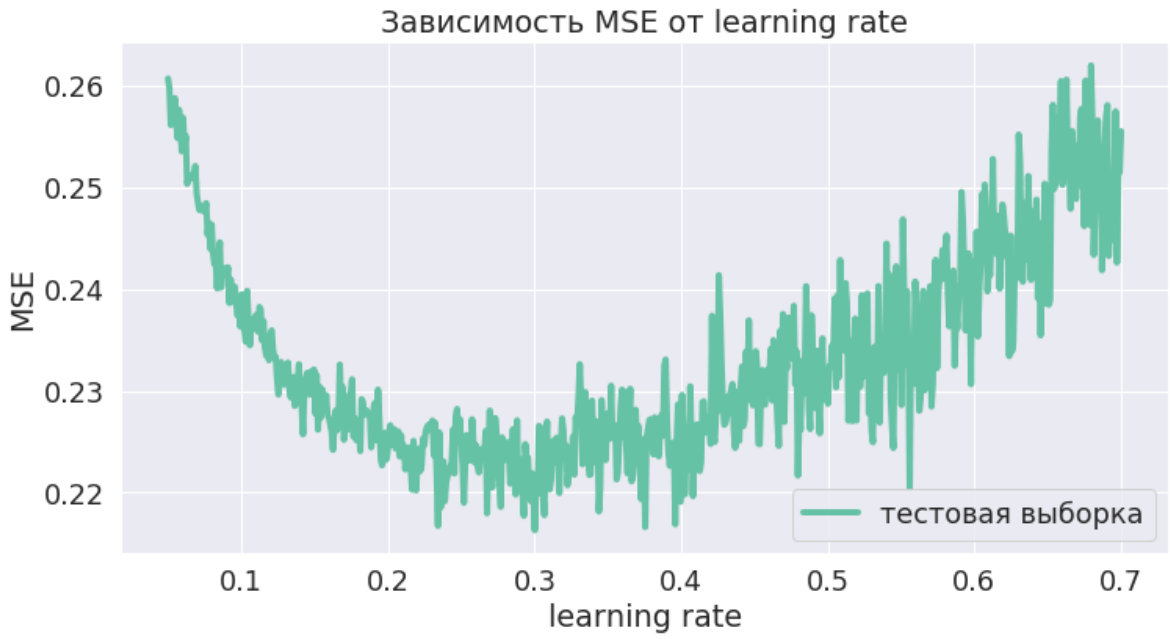

Оптимальное значение `learning rate` близко к 0.3.

Основываясь на полученных графиках, ответьте на следующие вопросы.

1. Какие закономерности можно увидеть на построенных графиках? Почему графики получились такими?
2. Как изменяется качество предсказаний с увеличением исследуемых параметров, когда эти параметры уже достаточно большие.
3. В предыдущем задании вы на практике убедились, что решающее дерево начинает переобучаться при достаточно больших значениях максимальной глубины. Справедливо ли это утверждение для решающего леса? Поясните свой ответ, опираясь на своё знание статистики.

Вывод.

По первому графику можно сделать вывод, что с возрастанием числа использованных деревьев используется, MSE снижается. Но при достаточно больших значениях `n_estimators` значение MSE практически перестаёт меняться. Здесь получается похожая ситуация, что и при использовании случайного леса. Однако "пороговое" значение `n_estimators` выше.

С параметром `max_depth` ситуация не такая, как при использовании случайного леса. Существует пороговое значение `max_depth` , выше которого модель имеет слишком высокую дисперсию и потому `mse` повышается. Отсюда можно сделать предположение, что градиентный бустинг имеет более высокую дисперсию, чем случайный лес, но более низкое смещение.

Параметр `learning_rate` стоит подбирать аккуратно. Надо сделать его достаточно большим, чтобы градиентный спуск быстро сходился и не застревал в точках, близких к локальным минимумам, но при этом не расходился.

Обучите градиентный бустинг со значениями гиперпараметров по умолчанию и выведите mse на тестовой выборке. Проведите эксперимент 3 раза. Почему результаты почти не отличаются?

In [14]:

```
for iteration in tqdm(range(3)):
    regressor = GradientBoostingRegressor(n_estimators=100)
    regressor.fit(X_train, y_train)
    predictions = regressor.predict(X_test)
    print('MSE = {:.4f}'.format(mse(predictions, y_test)))
```

started 13:04:33 2020-03-22, finished in 2.81s

100% 3/3 [00:02<00:00, 1.06it/s]

```
MSE = 0.2765
MSE = 0.2764
MSE = 0.2764
```

Ответ.

Результаты слабо отличаются, потому что единственный источник случайности здесь -- случайная перестановка признаков в цикле для разбиения вершины. Если при разбиении вершины существуют два разделяющихся признака, которые дают одинаковое значение критерия информативности, то из них выбирается тот, что первым перебирается в цикле.

Подбор гиперпараметров градиентного бустинга

Было бы неплохо определиться с тем, какое количество деревьев нужно использовать и какой максимальной глубины они будут. Подберите оптимальные значения `max_depth` и `n_estimators` с помощью кросс-валидации.

In [15]:

```
gb_gridsearch = RandomizedSearchCV(
    estimator=GradientBoostingRegressor(),
    param_distributions={
        'max_depth': np.arange(3, 30),
        'n_estimators': np.arange(10, 200),
        'learning_rate': np.linspace(0.05, 0.3, 300)
    },
    cv=5,  # разбиение выборки на 5 фолдов
    verbose=10,  # насколько часто печатать сообщения
    n_jobs=2,  # кол-во параллельных процессов
    n_iter=20  # кол-во итераций случайного выбора гиперпараметров
)
```

started 13:04:36 2020-03-22, finished in 4ms

In [16]:

```
1  gb_gridsearch.fit(X_train, y_train)
```

started 13:04:36 2020-03-22, finished in 15m 38s

```
Fitting 5 folds for each of 20 candidates, totalling 100 fits

[Parallel(n_jobs=2)]: Using backend LokyBackend with 2 concurrent work
ers.
[Parallel(n_jobs=2)]: Done   1 tasks      | elapsed:    2.2s
[Parallel(n_jobs=2)]: Done   4 tasks      | elapsed:    3.8s
[Parallel(n_jobs=2)]: Done   9 tasks      | elapsed:   50.0s
[Parallel(n_jobs=2)]: Done  14 tasks      | elapsed:  2.6min
[Parallel(n_jobs=2)]: Done  21 tasks      | elapsed:  3.4min
[Parallel(n_jobs=2)]: Done  28 tasks      | elapsed:  4.4min
[Parallel(n_jobs=2)]: Done  37 tasks      | elapsed:  5.1min
[Parallel(n_jobs=2)]: Done  46 tasks      | elapsed:  8.4min
[Parallel(n_jobs=2)]: Done  57 tasks      | elapsed:  9.3min
[Parallel(n_jobs=2)]: Done  68 tasks      | elapsed:  9.9min
[Parallel(n_jobs=2)]: Done  81 tasks      | elapsed: 13.1min
[Parallel(n_jobs=2)]: Done  94 tasks      | elapsed: 15.0min
[Parallel(n_jobs=2)]: Done 100 out of 100 | elapsed: 15.6min finished
```

Out[16]:

```
RandomizedSearchCV(cv=5, error_score='raise-deprecating',
                   estimator=GradientBoostingRegressor(alpha=0.9,
                                                       criterion='frie
dman_mse',
                                                       init=None,
                                                       learning_rate=
0.1,
                                                       loss='ls', max_
depth=3,
                                                       max_features=No
ne,
                                                       max_leaf_nodes=
None,
                                                       min_impurity_de
crease=0.0,
                                                       min_impurity_sp
lit=None,
                                                       min_samples_lea
f=1,
                                                       min_samples_spl
it=2,
                                                       min_weight_frac
tion_leaf=0.0,
                                                       n_estimators=10
0,...
       127, 128, 129, 130, 131, 132, 133, 134, 135, 136, 137, 138, 13
9,
       140, 141, 142, 143, 144, 145, 146, 147, 148, 149, 150, 151, 15
2,
       153, 154, 155, 156, 157, 158, 159, 160, 161, 162, 163, 164, 16
5,
       166, 167, 168, 169, 170, 171, 172, 173, 174, 175, 176, 177, 17
8,
       179, 180, 181, 182, 183, 184, 185, 186, 187, 188, 189, 190, 19
1,
       192, 193, 194, 195, 196, 197, 198, 199])},
                   pre_dispatch='2*n_jobs', random_state=None, refit=T
```

```
rue,
                   return_train_score=False, scoring=None, verbose=10)
```

Выведите найденные оптимальные параметры.

In [17]:

```
1  print(gb_gridsearch.best_params_)
```

started 13:20:14 2020-03-22, finished in 3ms

```
{'n_estimators': 194, 'max_depth': 5, 'learning_rate': 0.1545150501672
2408}
```

Зафиксируем эти оптимальные значения параметров и будем их использовать в дальнейшем.

In [18]:

```
1  max_depth = gb_gridsearch.best_params_['max_depth']
2  n_estimators = gb_gridsearch.best_params_['n_estimators']
```

started 13:20:14 2020-03-22, finished in 7ms

Оценим качество предсказаний обученного градиентного бустинга.

In [19]:

```
1  predictions = gb_gridsearch.best_estimator_.predict(X_test)
2  print('{:.4f}'.format(mse(predictions, y_test)))
```

started 13:20:14 2020-03-22, finished in 29ms

```
0.2143
```

Зависимость MSE от количества признаков

Исследуйте зависимость метрики `mse` от количества признаков, по которым происходит разбиение в вершине дерева. Поскольку количество признаков в датасете не очень большое (их 8), то можно перебрать все возможные варианты количества признаков, использующихся при разбиении вершин.

Не забывайте делать пояснения и выводы!

In [20]:

```
1  learning_rate = gb_gridsearch.best_params_['learning_rate']
```

started 13:20:14 2020-03-22, finished in 3ms

In [21]:

```
mse_train_values = []
mse_test_values = []

for n_features in tqdm(range(1, 9)):
    rf_regressor = GradientBoostingRegressor(max_depth=max_depth,
                                             n_estimators=n_estimators,
                                             learning_rate=learning_rate,
                                             max_features=n_features)
    rf_regressor.fit(X_train, y_train)
    current_train_mse = mse(rf_regressor.predict(X_train), y_train)
    current_test_mse = mse(rf_regressor.predict(X_test), y_test)
    print('n_features: {}, train_mse: {:.4f}, test_mse: {:.4f}'.format(
        n_features, current_train_mse, current_test_mse
    ))
    mse_train_values.append(current_train_mse)
    mse_test_values.append(current_test_mse)
```

started 13:20:14 2020-03-22, finished in 16.7s

100% 8/8 [00:16<00:00, 2.10s/it]

```
n_features: 1, train_mse: 0.1479, test_mse: 0.2400
n_features: 2, train_mse: 0.1222, test_mse: 0.2188
n_features: 3, train_mse: 0.1129, test_mse: 0.2158
n_features: 4, train_mse: 0.1054, test_mse: 0.2087
n_features: 5, train_mse: 0.1087, test_mse: 0.2144
n_features: 6, train_mse: 0.1061, test_mse: 0.2127
n_features: 7, train_mse: 0.1061, test_mse: 0.2211
n_features: 8, train_mse: 0.1039, test_mse: 0.2152
```

Постройте график зависимости метрики mse на `test` и `train` от числа признаков, использующихся при разбиении каждой вершины.

In [22]:

```
def plot_dependence(param_grid, train_values, test_values,
                    param_label='', metrics_label='', title='',
                    train_label='обучающая выборка',
                    test_label='тестовая выборка',
                    create_figure=True):
    '''
    Функция для построения графиков зависимости целевой метрики
    от некоторого параметра модели на обучающей и на валидационной
    выборке.

    Параметры.
    1) param_grid - значения исследуемого параметра,
    2) train_values - значения метрики на обучающей выборке,
    3) test_values - значения метрики на валидационной выборке,
    4) param_label - названия параметра,
    5) metrics_label - название метрики,
    6) title - заголовок для графика,
    7) create_figure - флаг, устанавливающий нужно ли создавать
    новую фигуру для графика.
    '''

    if create_figure:
        plt.figure(figsize=(12, 6))
    plt.plot(param_grid, train_values, label=train_label, linewidth=3)
    plt.plot(param_grid, test_values, label=test_label, linewidth=3)

    plt.legend()
    if create_figure:
        plt.xlabel(param_label)
        plt.ylabel(metrics_label)
        plt.title(title, fontsize=20)
```

started 13:20:31 2020-03-22, finished in 5ms

In [23]:

```
plot_dependence(range(1, 9), mse_train_values, mse_test_values,
                'Количество признаков', 'MSE',
                'Зависимость MSE от количества признаков')
```

started 13:20:31 2020-03-22, finished in 425ms

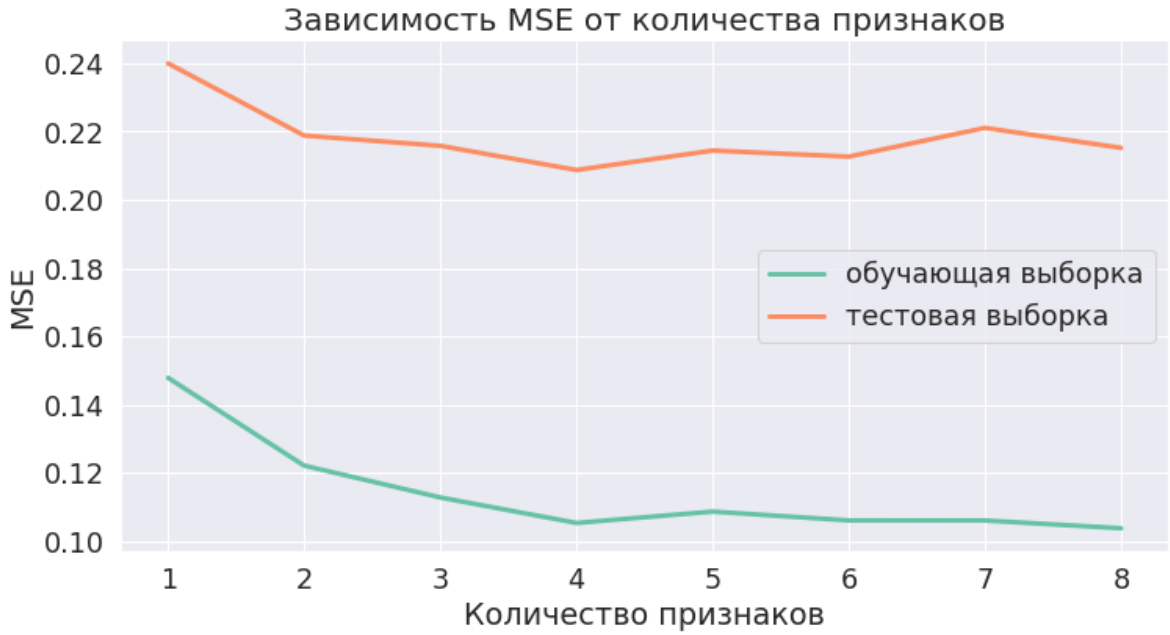

Почему график получился таким? Как зависит разнообразие деревьев от величины `max_features` ?

Вывод.

Чем больше значение `max_features` , тем меньше разнообразие деревьев. Когда `max_features` равно количеству признаков в датасете, градиентный бустинг перестаёт быть случайным. Как мы помним, при использовании случайного леса с некоторого значения `max_features` ошибка MSE начинала расти.

Визуализация наиболее значимого признака

Для определения наиболее значимого признака, обучим бустинг с оптимальными гиперпараметрами.

In [24]:

```
gb_regressor = GradientBoostingRegressor(
    max_depth=max_depth, n_estimators=n_estimators,
    learning_rate=learning_rate
)

gb_regressor.fit(X_train, y_train)
```

started 13:20:31 2020-03-22, finished in 3.28s

Out[24]:

```
GradientBoostingRegressor(alpha=0.9, criterion='friedman_mse', init=No
ne,
                          learning_rate=0.15451505016722408, loss='l
s',
                          max_depth=5, max_features=None, max_leaf_nod
es=None,
                          min_impurity_decrease=0.0, min_impurity_spli
t=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=1
94,
                          n_iter_no_change=None, presort='auto',
                          random_state=None, subsample=1.0, tol=0.000
1,
                          validation_fraction=0.1, verbose=0, warm_sta
rt=False)
```

Важности признаков

In [25]:

```
gb_regressor.feature_importances_
```

started 13:20:34 2020-03-22, finished in 5ms

Out[25]:

```
array([0.54720802, 0.04669553, 0.0326843 , 0.01439739, 0.01365882,
       0.12954587, 0.10397711, 0.11183297])
```

Первый признак (`MedInc`) оказался наиболее значимым.

Обучим градиентный бустинг для построения зависимости целевой переменной от `MedInc` .

In [26]:

```
gb_regressor = GradientBoostingRegressor(n_estimators=10)
gb_regressor.fit(X_train[:, [0]], y_train)
```

started 13:20:34 2020-03-22, finished in 50ms

Out[26]:

```
GradientBoostingRegressor(alpha=0.9, criterion='friedman_mse', init=No
ne,
                          learning_rate=0.1, loss='ls', max_depth=3,
                          max_features=None, max_leaf_nodes=None,
                          min_impurity_decrease=0.0, min_impurity_spli
t=None,
                          min_samples_leaf=1, min_samples_split=2,
                          min_weight_fraction_leaf=0.0, n_estimators=1
0,
                          n_iter_no_change=None, presort='auto',
                          random_state=None, subsample=1.0, tol=0.000
1,
                          validation_fraction=0.1, verbose=0, warm_sta
rt=False)
```

Визуализируем построенные деревья.

In [27]:

```
grid = np.linspace(0, np.max(X_train[:, 0]), 1000)
staged_predicts = list(
    gb_regressor.staged_predict(grid.reshape((-1, 1)))
)
residuals = y_train

fig, ax = plt.subplots(10, 2, figsize=(15, 30))
for i in range(10):
    ax[i, 0].plot(
        grid, gb_regressor.estimators_[i, 0].predict(grid.reshape((-1, 1))),
        linewidth=3, color='#FF3300'
    )
    ax[i, 1].plot(grid, staged_predicts[i], linewidth=3, color='#FF3300')
    ax[i, 0].scatter(X_train[:, 0], residuals - y_train.mean(),
                     color='#0099CC', alpha=0.01)
    ax[i, 1].scatter(X_train[:, 0], y_train[:], color='#00CC66', alpha=0.01)
    ax[i, 0].set_ylabel(f't={i}')

    ax[i, 0].set_xlim((0, 12))
    ax[i, 1].set_xlim((0, 12))

    residuals -= learning_rate * gb_regressor.estimators_[i, 0].predict(X_tra

ax[0, 0].set_title('Дерево $b_t$')
ax[0, 1].set_title('Композиция $\\widehat{y}_t$')
plt.show()
```

started 13:20:34 2020-03-22, finished in 6.27s

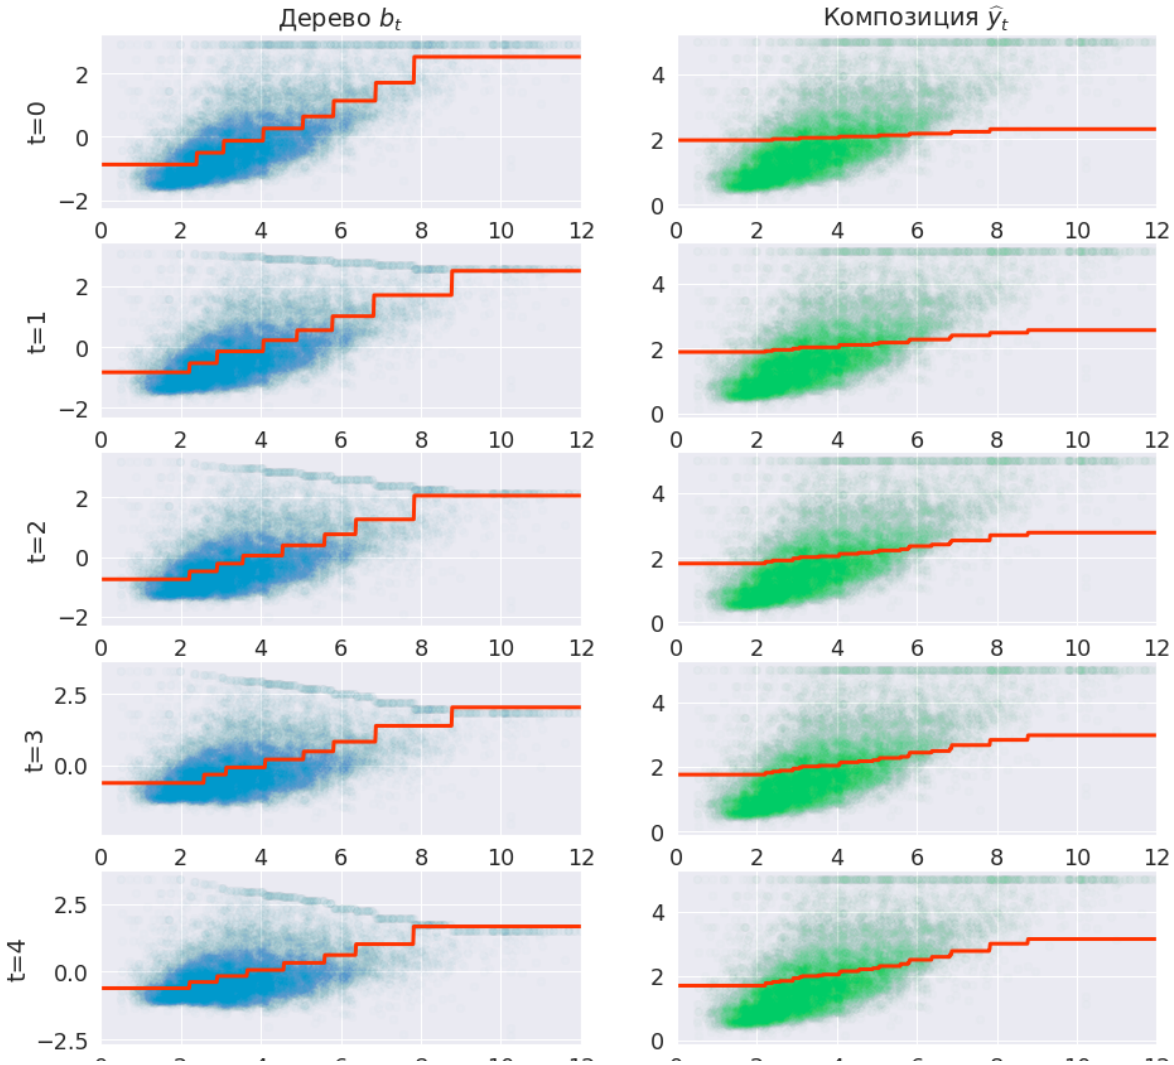

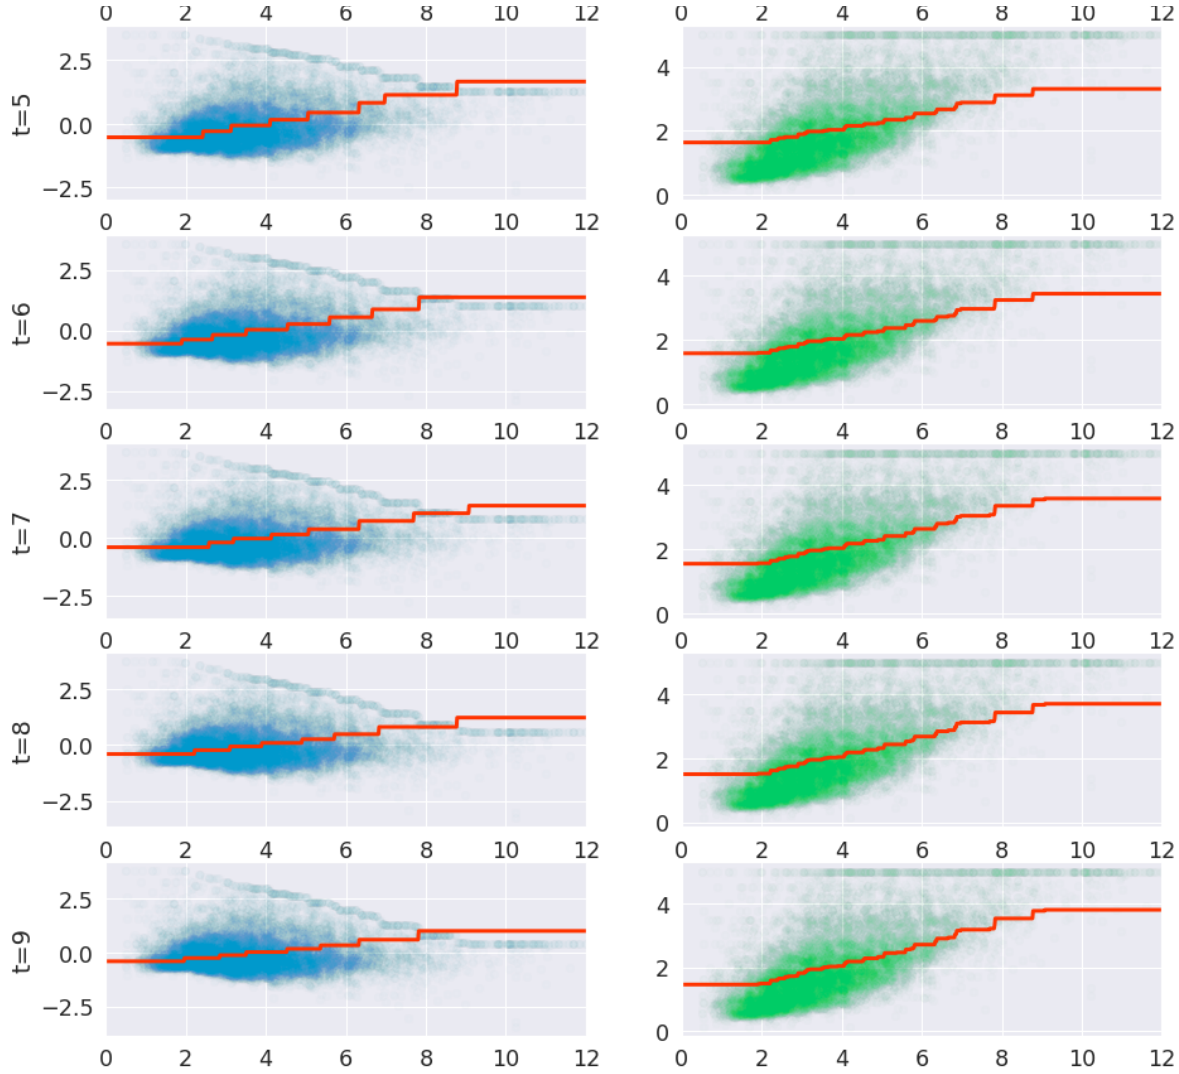

Вывод.

По графику видно, что с возрастанием числа деревьев x композиция становится более гладкой и лучше приближает обучающую выборку.

Замена инициализирующей модели

Посмотрим на то, какие параметры есть у градиентного бустинга, который инициализируется с помощью линейной регрессии.

In [45]:

```
gb_ridge_regressor = GradientBoostingRegressor(init=Ridge())
print(gb_ridge_regressor.get_params())
```

started 15:31:52 2020-03-22, finished in 11ms

```
{'alpha': 0.9, 'criterion': 'friedman_mse', 'init__alpha': 1.0, 'init_
_copy_X': True, 'init__fit_intercept': True, 'init__max_iter': None,
'init__normalize': False, 'init__random_state': None, 'init__solver':
'auto', 'init__tol': 0.001, 'init': Ridge(alpha=1.0, copy_X=True, fit_
intercept=True, max_iter=None,
      normalize=False, random_state=None, solver='auto', tol=0.001),
'learning_rate': 0.1, 'loss': 'ls', 'max_depth': 3, 'max_features': No
ne, 'max_leaf_nodes': None, 'min_impurity_decrease': 0.0, 'min_impurit
y_split': None, 'min_samples_leaf': 1, 'min_samples_split': 2, 'min_we
ight_fraction_leaf': 0.0, 'n_estimators': 100, 'n_iter_no_change': Non
e, 'presort': 'auto', 'random_state': None, 'subsample': 1.0, 'tol':
0.0001, 'validation_fraction': 0.1, 'verbose': 0, 'warm_start': False}
```

К параметру `alpha` Ridge-регрессии нужно обращаться через имя `init__alpha`. Не путать с `alpha`, являющимся гиперпараметром самого градиентого бустинга!

In [47]:

```
gb_ridge_gridsearch = RandomizedSearchCV(
    estimator=gb_ridge_regressor,
    param_distributions={
        'max_depth': np.arange(3, 7),
        'n_estimators': np.arange(10, 300),
        'learning_rate': np.linspace(0.05, 0.3, 300),
        'init__alpha': np.linspace(0, 5, 501)
    },
    cv=5,  # разбиение выборки на 5 фолдов
    verbose=2,  # насколько часто печатать сообщения
    n_jobs=-1,  # кол-во параллельных процессов
    n_iter=1000  # кол-во итераций случайного выбора гиперпараметров
)
```

started 15:32:39 2020-03-22, finished in 16ms

Обучим кросс-валидацию.

In [48]:

```
1  gb_ridge_gridsearch.fit(X_train, y_train)
```

started 15:32:40 2020-03-22, finished in 1h 6m 32s

```
Fitting 5 folds for each of 1000 candidates, totalling 5000 fits

[Parallel(n_jobs=-1)]: Using backend LokyBackend with 4 concurrent wor
kers.
[Parallel(n_jobs=-1)]: Done  33 tasks      | elapsed:   12.9s
[Parallel(n_jobs=-1)]: Done 154 tasks      | elapsed:  1.3min
[Parallel(n_jobs=-1)]: Done 357 tasks      | elapsed:  3.0min
[Parallel(n_jobs=-1)]: Done 640 tasks      | elapsed:  6.0min
[Parallel(n_jobs=-1)]: Done 1005 tasks      | elapsed:  9.3min
[Parallel(n_jobs=-1)]: Done 1450 tasks      | elapsed: 14.8min
[Parallel(n_jobs=-1)]: Done 1977 tasks      | elapsed: 22.8min
[Parallel(n_jobs=-1)]: Done 2584 tasks      | elapsed: 32.2min
[Parallel(n_jobs=-1)]: Done 3273 tasks      | elapsed: 42.1min
[Parallel(n_jobs=-1)]: Done 4042 tasks      | elapsed: 52.0min
[Parallel(n_jobs=-1)]: Done 4893 tasks      | elapsed: 65.2min
[Parallel(n_jobs=-1)]: Done 5000 out of 5000 | elapsed: 66.4min finish
ed
/usr/local/lib/python3.7/dist-packages/sklearn/linear_model/ridge.py:1
47: LinAlgWarning: Ill-conditioned matrix (rcond=1.78491e-08): result
may not be accurate.
  overwrite_a=True).T
```

Out[48]:

```
RandomizedSearchCV(cv=5, error_score='raise-deprecating',
                   estimator=GradientBoostingRegressor(alpha=0.9,
                                                       criterion='frie
dman_mse',
                                                       init=Ridge(alph
a=1.0,
                                                                  copy
_X=True,
                                                                  fit_
intercept=True,
                                                                  max_
iter=None,
                                                                  norm
alize=False,
                                                                  rand
om_state=None,
                                                                  solv
er='auto',
                                                                  tol=
0.001),
                                                       learning_rate=
0.1,
                                                       loss='ls', max_
depth=3,
                                                       max_features=No
ne,
                                                       max_leaf_nodes=
None,
                                                       min_impurity_de
creas...
       231, 232, 233, 234, 235, 236, 237, 238, 239, 240, 241, 242, 24
3,
       244, 245, 246, 247, 248, 249, 250, 251, 252, 253, 254, 255, 25
```

```
6,
       257, 258, 259, 260, 261, 262, 263, 264, 265, 266, 267, 268, 26
9,
       270, 271, 272, 273, 274, 275, 276, 277, 278, 279, 280, 281, 28
2,
       283, 284, 285, 286, 287, 288, 289, 290, 291, 292, 293, 294, 29
5,
       296, 297, 298, 299])},
                   pre_dispatch='2*n_jobs', random_state=None, refit=T
rue,
                   return_train_score=False, scoring=None, verbose=2)
```

Оптимальные значения гиперпараметров

In [49]:

```
1  print(gb_ridge_gridsearch.best_params_)
```

started 16:45:32 2020-03-22, finished in 7ms

```
{'n_estimators': 238, 'max_depth': 6, 'learning_rate': 0.1043478260869
5653, 'init__alpha': 3.89}
```

Оптимальное качество по MSE

In [50]:

```
1  mse(gb_ridge_gridsearch.predict(X_test), y_test)
```

started 16:45:33 2020-03-22, finished in 139ms

Out[50]:

```
0.21245963246239333
```

Вывод.

Удалось немного улучшить качество на тестовой выборке. Отсюда можно сделать вывод, что при работе с градиентным бустингом может быть полезно попробовать разные инициализирующие модели.

Смесь бустинга и решающего леса

Обучим модели градиентного бустинга с подобранными ранее гиперпараметрами и случайного леса.

In [33]:

```
regressor1 = GradientBoostingRegressor(
    max_depth=max_depth, n_estimators=n_estimators,
    learning_rate=learning_rate
)
regressor2 = RandomForestRegressor(
    n_estimators=200
)
regressor1.fit(X_train, y_train)
regressor2.fit(X_train, y_train)
```

started 13:28:15 2020-03-22, finished in 21.9s

Out[33]:

```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
                      max_features='auto', max_leaf_nodes=None,
                      min_impurity_decrease=0.0, min_impurity_split=No
ne,
                      min_samples_leaf=1, min_samples_split=2,
                      min_weight_fraction_leaf=0.0, n_estimators=200,
                      n_jobs=None, oob_score=False, random_state=None,
                      verbose=0, warm_start=False)
```

Подберем оптимальный вес для смеси моделей

In [34]:

```
mse_values = []
preds_boosting = regressor1.predict(X_test)
preds_forest = regressor2.predict(X_test)

for w in np.linspace(0, 1, 101):
    predictions = w * preds_boosting + (1 - w) * preds_forest
    mse_values.append(mse(predictions, y_test))
```

started 13:28:37 2020-03-22, finished in 332ms

Построим график зависимости mse от коэффициента смеси `w` .

In [35]:

```
plot_dependence_test(np.linspace(0.0, 1.0, 101), mse_values,
                     'Вес модели бустинга', 'MSE',
                     'Качество смеси бустинга и случайного леса')
```

started 13:28:37 2020-03-22, finished in 393ms

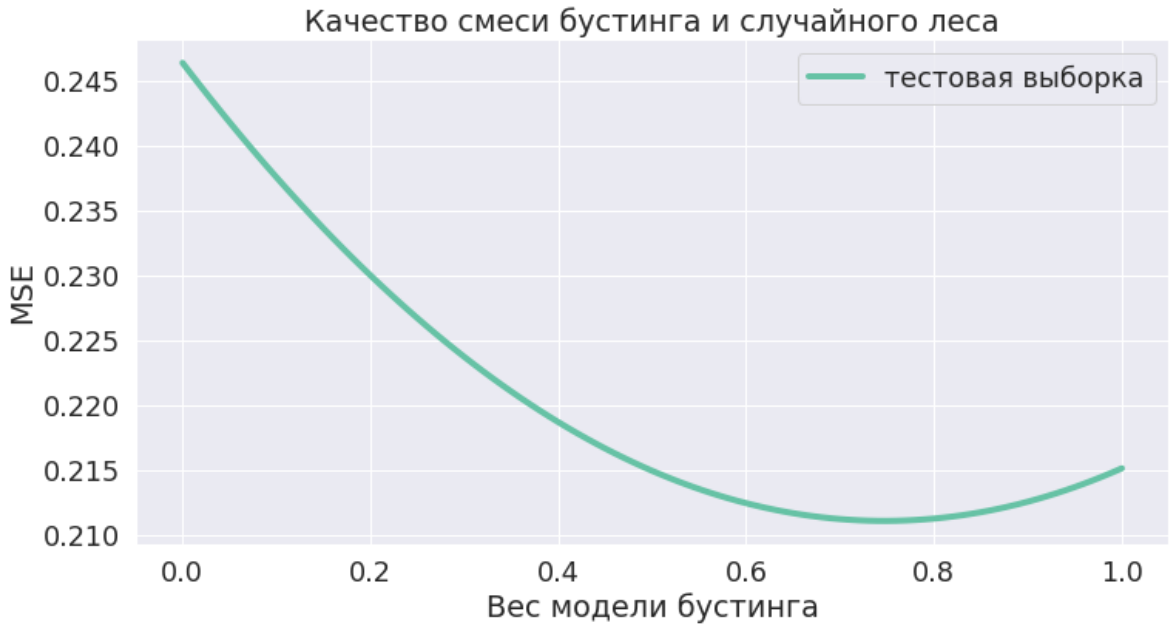

Вывод.

Использование смеси градиентного бустинга и решающего леса со значением $w \approx 0.7$ позволило получить более точный результат, чем в случае использования чистого бустинга.