In [1]:

```
import numpy as np
import pandas as pd
import warnings

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import MinMaxScaler, StandardScaler, LabelEncoder
from sklearn.metrics import mean_squared_error, make_scorer
from sklearn.ensemble import GradientBoostingRegressor

from xgboost import XGBRegressor
from lightgbm import LGBMRegressor
from catboost import CatBoostRegressor

sns.set(font_scale=1.5, palette='Set2')
warnings.filterwarnings("ignore")
```

started 01:43:57 2020-03-27, finished in 2.11s

Задача 6.2

Реализация MAPE

In [2]:

```
def mape(y_true, y_pred):
    return 100 * np.abs((y_true - y_pred) / y_true).mean()
```

started 01:43:59 2020-03-27, finished in 4ms

Считываем данные

In [3]:

```
train_df = pd.read_csv('houses_train.csv').drop(columns=['id', 'date'])
train_df.head()
```

started 01:43:59 2020-03-27, finished in 105ms

Out[3]:

	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	condition	gr
0	221900.0	3	1.00	1180	5650	1.0	0	0	3	
1	538000.0	3	2.25	2570	7242	2.0	0	0	3	
2	604000.0	4	3.00	1960	5000	1.0	0	0	5	
3	510000.0	3	2.00	1680	8080	1.0	0	0	3	
4	257500.0	3	2.25	1715	6819	2.0	0	0	3	

Посмотрим на их описания

In [4]:

```
1  train_df.describe()
```

started 01:43:59 2020-03-27, finished in 137ms

Out[4]:

	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	1
count	1.562600e+04	15626.000000	15626.000000	15626.000000	1.562600e+04	15626.000000	
mean	5.355339e+05	3.371240	2.111737	2073.132919	1.506655e+04	1.494304	
std	3.595051e+05	0.909872	0.769037	911.406092	4.235533e+04	0.539333	
min	7.500000e+04	0.000000	0.000000	290.000000	6.000000e+02	1.000000	
25%	3.200000e+05	3.000000	1.500000	1430.000000	5.060000e+03	1.000000	
50%	4.500000e+05	3.000000	2.250000	1910.000000	7.598500e+03	1.500000	
75%	6.400000e+05	4.000000	2.500000	2540.000000	1.057975e+04	2.000000	
max	7.700000e+06	11.000000	8.000000	13540.000000	1.651359e+06	3.500000	

In [5]:

```
1  train_df.columns
```

started 01:44:00 2020-03-27, finished in 6ms

Out[5]:

```
Index(['price', 'bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'f
loors',
       'waterfront', 'view', 'condition', 'grade', 'sqft_above',
       'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode', 'lat',
'long',
       'sqft_living15', 'sqft_lot15'],
      dtype='object')
```

Внимательно изучив признаки понимаем, что единственным категориальным признаком можно считать почтовый индекс `zipcode`

In [6]:

```
1  cat_features = ['zipcode']
```

started 01:44:00 2020-03-27, finished in 8ms

Уникальные значения этого признака

In [7]:

```
1  train_df['zipcode'].unique()
```

started 01:44:00 2020-03-27, finished in 8ms

Out[7]:

```
array([98178, 98125, 98136, 98074, 98003, 98198, 98146, 98038, 98007,
       98115, 98028, 98126, 98019, 98103, 98002, 98133, 98040, 98092,
       98030, 98119, 98112, 98052, 98027, 98117, 98058, 98001, 98056,
       98053, 98148, 98105, 98042, 98008, 98059, 98166, 98122, 98004,
       98005, 98116, 98023, 98199, 98032, 98045, 98102, 98077, 98168,
       98065, 98107, 98006, 98109, 98022, 98034, 98075, 98033, 98144,
       98177, 98155, 98108, 98118, 98011, 98024, 98010, 98106, 98070,
       98031, 98072, 98014, 98055, 98029, 98188, 98039])
```

Отобразим почтовый индекс на карте города, используя значения широты и долготы. Видим, что объекты разбиваются по райоам города

In [8]:

```
1  plt.figure(figsize=(12, 6))
2  plt.scatter(train_df['lat'], train_df['long'],
3              c=train_df['zipcode'], cmap='Set2', s=10);
```

started 01:44:00 2020-03-27, finished in 1.57s

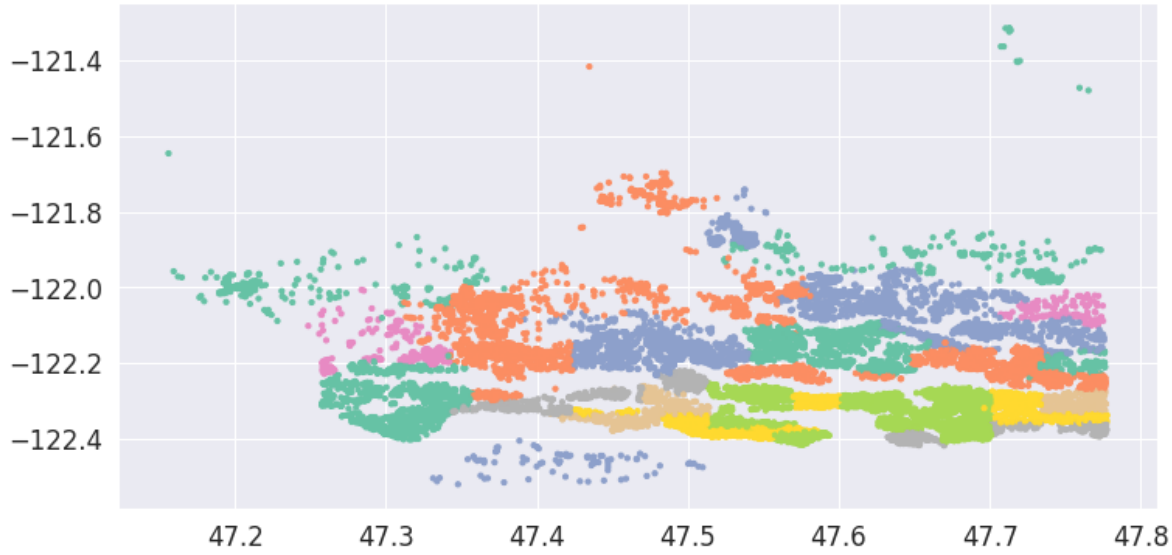

Разобьем данные на обучающую и валидационную выборки. На первой будем обучать все модели, на второй -- проверять качество моделей

In [9]:

```
1  X, labels = train_df.drop(columns=['price']), train_df['price']
2  x_train, x_valid, y_train, y_valid = train_test_split(X, labels,
3                                                        test_size=0.3)
```

started 01:44:01 2020-03-27, finished in 29ms

Для кодировки категориальных признаков будем использовать `MeanEncoder`, который заменяет значение категории на среднее значение таргета в этой категории. Если категория не встречалась в трейне, то на глобальное среднее таргета.

In [10]:

```
# https://github.com/AndreyKoceruba/mean-encoding/blob/master/mean_encoder.py

from sklearn.base import BaseEstimator
from sklearn.base import TransformerMixin

class MeanEncoder(BaseEstimator, TransformerMixin):

    def __init__(self, target_type='binary',
                 encoding='likelihood', func=None):
        if target_type == 'continuous' and encoding in ['woe', 'diff']:
            raise ValueError(
                '{} target_type can\'t be used with {} encoding'.format(targe
            )
        self.target_type = target_type
        self.encoding = encoding
        self.func = func

    def goods(self, x):
        return np.sum(x == 1)

    def bads(self, x):
        return np.sum(x == 0)

    def encode(self, X, y, agg_func):
        self.means = dict()
        self.global_mean = np.nan
        X['target'] = y
        for col in X.columns:
            if col != 'target':
                col_means = X.groupby(col)['target'].agg(agg_func)
                self.means[col] = col_means
        X.drop(['target'], axis=1, inplace = True)

    def fit(self, X, y):
        if self.encoding == 'woe':
            self.encode(X, y, lambda x: np.log(self.goods(x) / self.bads(x)) 
            self.global_mean = np.log(self.goods(y) / self.bads(y)) * 100
        elif self.encoding == 'diff':
            self.encode(X, y, lambda x: self.goods(x) - self.bads(x))
            self.global_mean = self.goods(y) - self.bads(y)
        elif self.encoding == 'likelihood':
            self.encode(X, y, np.mean)
            self.global_mean = np.mean(y)
        elif self.encoding == 'count':
            self.encode(X, y, np.sum)
            self.global_mean = np.sum(y)
        elif self.encoding == 'function':
            self.encode(X, y, lambda x: self.func(x))
            self.global_mean = self.func(y)
        return self

    def transform(self, X):
        X_new = pd.DataFrame()
        for col in X.columns:
            X_new[col] = X[col].map(self.means[col]).fillna(self.global_mean)
        return X_new

    def fit_transform(self, X, y):
        self.fit(X, y)
```

```
60          return self.transform(X)
```

started 01:44:01 2020-03-27, finished in 22ms

Сохраним оригинальные данные

In [11]:

```
1  x_train_origin = x_train.copy()
2  x_valid_origin = x_valid.copy()
```

started 01:44:01 2020-03-27, finished in 9ms

Закодируем категориальный признак

In [12]:

```
1  encoder = MeanEncoder()
2  x_train[cat_features] = encoder.fit_transform(x_train[cat_features], y_train)
3  x_valid[cat_features] = encoder.transform(x_valid[cat_features])
```

started 01:44:01 2020-03-27, finished in 26ms

Некоторая вспомогательная функция для отрисовки графиков

In [14]:

```
1  colors = ['#FF3300', '#0099CC', '#00CC66', 'orange']
2
3  def plot_dependence_test(param_grid, mape_train, mape_valid, descr,
4                           param_label,
5                           title, ylim=(11, 16)):
6      '''
7      Функция для построения графиков зависимости целевой метрики
8      от некоторого параметра моделей на обучающей и валидационной выборках.
9
10     Параметры.
11     1) param_grid - значения исследуемого параметра,
12     2) mape_train - значения метрик на обучающей выборке,
13     3) mape_train - значения метрик на валидационной выборке,
14     4) descr - описания моделей для легенды
15     5) param_label - названия параметра,
16     6) title - заголовок для графика.
17     '''
18
19     plt.figure(figsize=(16, 8))
20
21     for i in range(len(mape_train)):
22         plt.plot(param_grid, mape_train[i], color=colors[i],
23                  linewidth=2, linestyle='--', alpha=0.7,
24                 label=descr[i]+' train')
25         plt.plot(param_grid, mape_valid[i], color=colors[i],
26                  linewidth=4, alpha=0.7, label=descr[i]+' valid')
27
28     plt.xlabel(param_label)
29     plt.ylabel('MAPE, %')
30     plt.legend(ncol=2)
31     plt.title(title)
32     plt.ylim(ylim)
33     plt.show()
```

started 01:53:26 2020-03-27, finished in 6ms

1. Зависимость от количества деревьев

Для каждой модели используем функции получения предсказания с ограничением количества деревьев при предсказаний. Это позволяет не обучать каждый раз одни и те же модели.

In [13]:

```
n_estimators_grid = np.arange(1, 1000)

regressor = GradientBoostingRegressor(n_estimators=max(n_estimators_grid))
regressor.fit(x_train, y_train)
mape_train = [[mape(y_train, prediction)
               for prediction in regressor.staged_predict(x_train)]]
mape_valid = [[mape(y_valid, prediction) for
               prediction in regressor.staged_predict(x_valid)]]

regressor = XGBRegressor(n_estimators=max(n_estimators_grid))
regressor.fit(x_train, y_train)
mape_train += [[mape(y_train, regressor.predict(x_train, ntree_limit=i+1))
                for i in range(max(n_estimators_grid))]]
mape_valid += [[mape(y_valid, regressor.predict(x_valid, ntree_limit=i+1))
                for i in range(max(n_estimators_grid))]]

regressor = LGBMRegressor(n_estimators=max(n_estimators_grid))
regressor.fit(x_train_origin, y_train, categorical_feature=cat_features)
mape_train += [[mape(y_train, regressor.predict(x_train_origin,
                                                num_iteration=i+1))
                for i in range(max(n_estimators_grid))]]
mape_valid += [[mape(y_valid, regressor.predict(x_valid_origin,
                                                num_iteration=i+1))
                for i in range(max(n_estimators_grid))]]

regressor = CatBoostRegressor(n_estimators=max(n_estimators_grid),
                              cat_features=cat_features, verbose=0)
regressor.fit(x_train_origin, y_train)
mape_train += [[mape(y_train, regressor.predict(x_train_origin, ntree_end=i+1
                for i in range(max(n_estimators_grid))]]
mape_valid += [[mape(y_valid, regressor.predict(x_valid_origin, ntree_end=i+1
                for i in range(max(n_estimators_grid))]]
```

started 01:44:01 2020-03-27, finished in 9m 25s

In [15]:

```
plot_dependence_test(n_estimators_grid, mape_train, mape_valid,
                     ['GradientBoostingRegressor', 'XGBRegressor',
                      'LGBMRegressor', 'CatBoostRegressor'],
                     'Количество деревьев',
                     'Зависимость MSE от количества деревьев')
```

started 01:53:26 2020-03-27, finished in 574ms

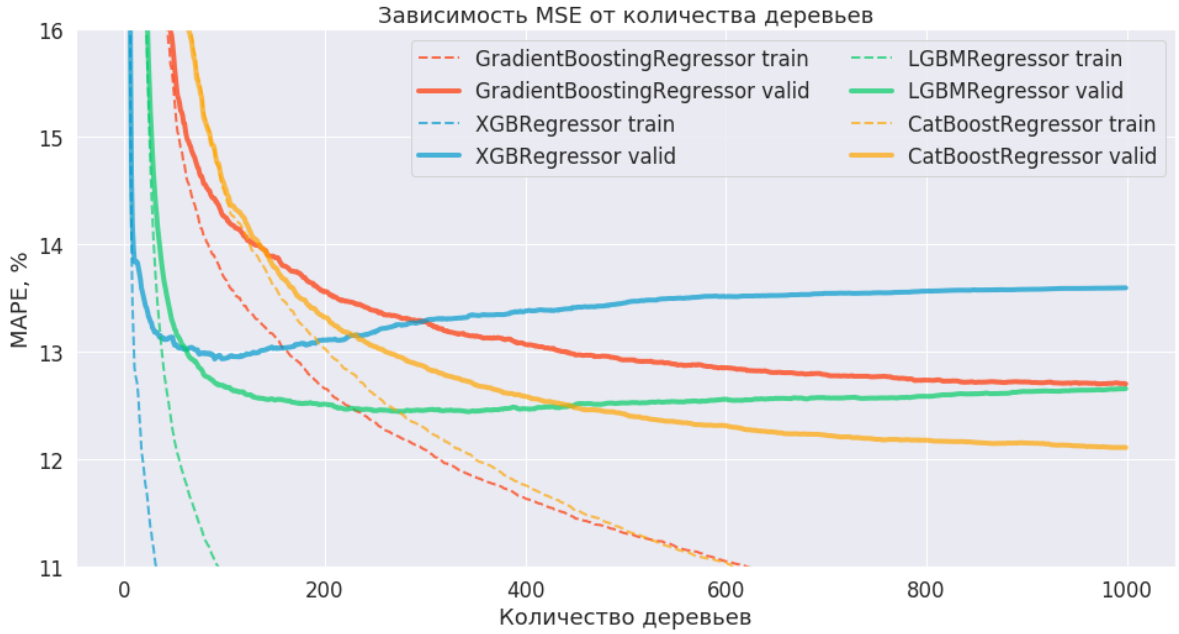

Вывод: XGBoost и LightGBM позволяют быстро получить довольно приемлимое качество на небольшом количестве деревьев. Однако при увеличении количества деревьев они начинают переобучаться. CatBoost'y требуется большое количество деревьев для получения хорошего качества, причем при увеличении количества деревьев не наблюдается переобучения. Подобные свойства наблюдаются у реализации из sklearn. Наилучшее качество на валидационной выборке позволяет получить CatBoost.

2. Зависимость от максимальной глубины дерева

In [16]:

```
max_depth_grid = np.arange(2, 12)

mape_train, mape_valid = np.zeros((2, 4, len(max_depth_grid)))

for i, max_depth in enumerate(max_depth_grid):
    regressor = GradientBoostingRegressor(max_depth=max_depth)
    regressor.fit(x_train, y_train)
    mape_train[0, i] = mape(y_train, regressor.predict(x_train))
    mape_valid[0, i] = mape(y_valid, regressor.predict(x_valid))

    regressor = XGBRegressor(max_depth=max_depth)
    regressor.fit(x_train, y_train)
    mape_train[1, i] = mape(y_train, regressor.predict(x_train))
    mape_valid[1, i] = mape(y_valid, regressor.predict(x_valid))

    regressor = LGBMRegressor(max_depth=max_depth)
    regressor.fit(x_train_origin, y_train, categorical_feature=cat_features)
    mape_train[2, i] = mape(y_train, regressor.predict(x_train_origin))
    mape_valid[2, i] = mape(y_valid, regressor.predict(x_valid_origin))

    regressor = CatBoostRegressor(max_depth=max_depth,
                                  cat_features=cat_features, verbose=0)
    regressor.fit(x_train_origin, y_train)
    mape_train[3, i] = mape(y_train, regressor.predict(x_train_origin))
    mape_valid[3, i] = mape(y_valid, regressor.predict(x_valid_origin))
```

started 01:53:27 2020-03-27, finished in 2m 29s

In [17]:

```
plot_dependence_test(max_depth_grid, mape_train, mape_valid,
                     ['GradientBoostingRegressor', 'XGBRegressor',
                      'LGBMRegressor', 'CatBoostRegressor'],
                     'Максимальная глубина дерева',
                     'Зависимость MAPE от максимальной глубины дерева')
```

started 01:55:56 2020-03-27, finished in 508ms

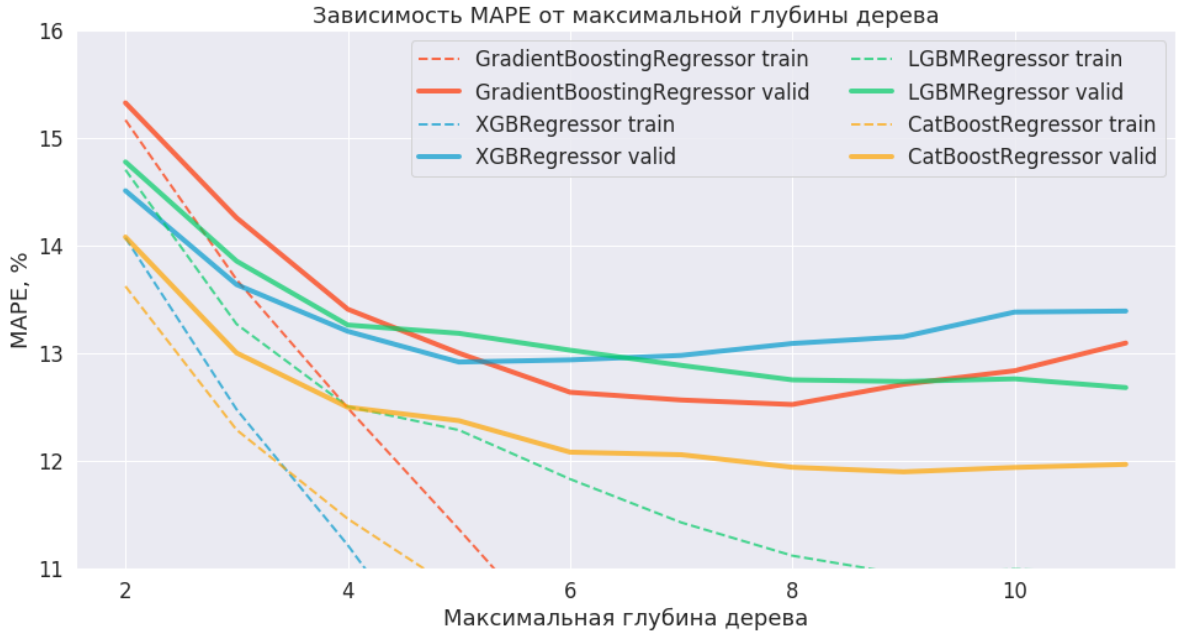

Вывод: Оптимальная глубина дерева для разных моделей равна от 5 до 8. Модели XGBoost и sklearn-реализация начинают переобучаться с увеличением глубины дерева. Модели LightGBM и CatBoost ведут

себя более устойчиво.

3. Зависимость от `learning_rate`

In [18]:

```
learning_rate_grid = np.linspace(0.0125, 0.6, 48)
n_estimators = 100

mape_train, mape_valid = np.zeros((2, 4, len(learning_rate_grid)))

for i, learning_rate in enumerate(learning_rate_grid):
    regressor = GradientBoostingRegressor(learning_rate=learning_rate)
    regressor.fit(x_train, y_train)
    mape_train[0, i] = mape(y_train, regressor.predict(x_train))
    mape_valid[0, i] = mape(y_valid, regressor.predict(x_valid))

    regressor = XGBRegressor(learning_rate=learning_rate)
    regressor.fit(x_train, y_train)
    mape_train[1, i] = mape(y_train, regressor.predict(x_train))
    mape_valid[1, i] = mape(y_valid, regressor.predict(x_valid))

    regressor = LGBMRegressor(learning_rate=learning_rate)
    regressor.fit(x_train_origin, y_train, categorical_feature=cat_features)
    mape_train[2, i] = mape(y_train, regressor.predict(x_train_origin))
    mape_valid[2, i] = mape(y_valid, regressor.predict(x_valid_origin))

    regressor = CatBoostRegressor(learning_rate=learning_rate,
                                  cat_features=cat_features, verbose=0)
    regressor.fit(x_train_origin, y_train)
    mape_train[3, i] = mape(y_train, regressor.predict(x_train_origin))
    mape_valid[3, i] = mape(y_valid, regressor.predict(x_valid_origin))
```

started 01:55:56 2020-03-27, finished in 5m 36s

In [19]:

```
plot_dependence_test(learning_rate_grid, mape_train, mape_valid,
                     ['GradientBoostingRegressor', 'XGBRegressor',
                      'LGBMRegressor', 'CatBoostRegressor'],
                     'learning_rate',
                     'Зависимость MAPE от learning_rate')
```

started 02:01:32 2020-03-27, finished in 586ms

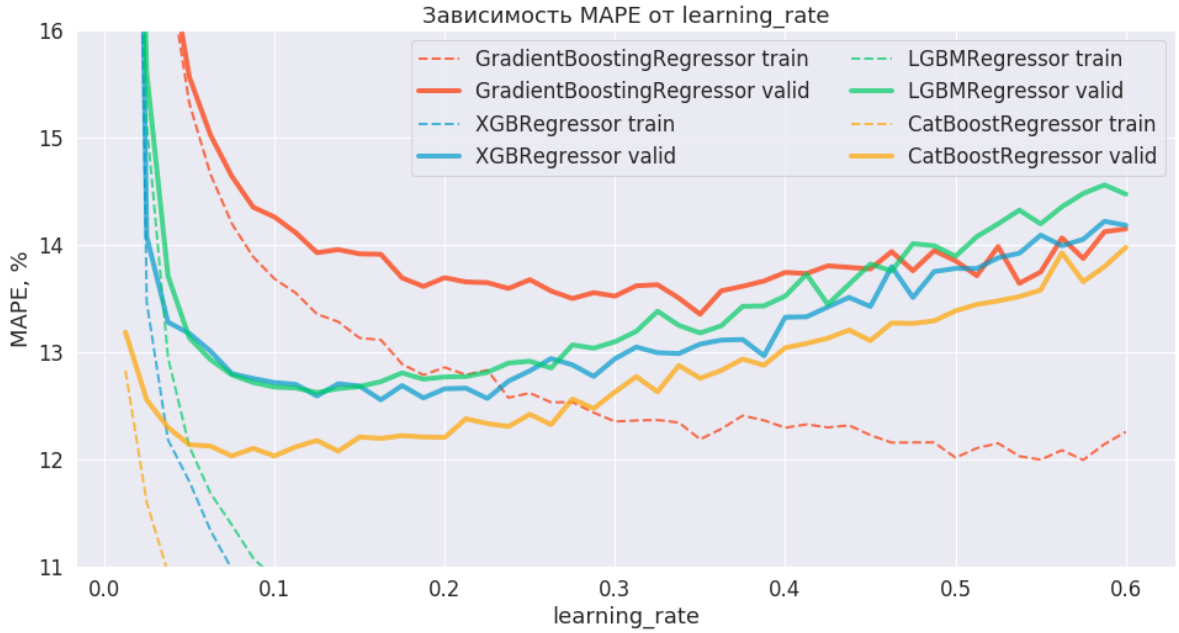

Вывод: Для каждой модели наблюдается некоторое оптимальное значение `learning_rate` . При меньших значениях модели недообучаются, при больших значениях наблюдается неустойчивость моделей при обучении --- графики начинает колбасить. Модель CatBoost показывает наилучшее качество. CatBoost лучший :)