In [1]:

```
from collections import defaultdict, Counter
from copy import deepcopy
from datetime import datetime
import itertools
import warnings
warnings.simplefilter("ignore")

from joblib import Parallel, delayed
import numpy as np
import pandas as pd
import scipy.stats as sps
import statsmodels.stats.multitest as multitest
from sklearn.datasets import load_boston
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.linear_model import LinearRegression, Ridge
from sklearn.metrics import accuracy_score, mean_squared_error, make_scorer
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.pipeline import Pipeline, make_pipeline
from sklearn.preprocessing import LabelBinarizer, LabelEncoder, StandardScaler
import xgboost as xgb

import matplotlib.colors
import matplotlib.gridspec as gridspec
import matplotlib.pyplot as plt
import seaborn as sns

from tqdm import tqdm, tqdm_notebook

plt.rc('text', usetex=False)
plt.rc('font', family='serif')
sns.set(font_scale=1.4, style="whitegrid")

%matplotlib inline
```

started 23:39:24 2019-04-13, finished in 22.9s

3 место после дедлайна

Автор решения: Иванов Вячеслав

1. Работа с признаками

Заведём список из модифицирующих датафрейм преобразований, чтобы не копировать код при обработке тестовой выборки.

In [2]:
```
1  transformer_lst = []
```
started 23:39:46 2019-04-13, finished in 3ms

Загрузим данные:

In [3]:
```
1  train_df = pd.read_csv("houses_train.csv").drop(columns=["id"])
2  train_df.describe()
```
started 23:39:46 2019-04-13, finished in 204ms

Out[3]:

	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	condition	gr
count	1.562600e+04	15626.000000	15626.000000	15626.000000	1.562600e+04	15626.000000	15626.000000	15626.000000	15626.000000	15626.000
mean	5.355339e+05	3.371240	2.111737	2073.132919	1.506655e+04	1.494304	0.007488	0.228465	3.408870	7.649
std	3.595051e+05	0.909872	0.769037	911.406092	4.235533e+04	0.539333	0.086209	0.757528	0.651925	1.171
min	7.500000e+04	0.000000	0.000000	290.000000	6.000000e+02	1.000000	0.000000	0.000000	1.000000	1.000
25%	3.200000e+05	3.000000	1.500000	1430.000000	5.060000e+03	1.000000	0.000000	0.000000	3.000000	7.000
50%	4.500000e+05	3.000000	2.250000	1910.000000	7.598500e+03	1.500000	0.000000	0.000000	3.000000	7.000
75%	6.400000e+05	4.000000	2.500000	2540.000000	1.057975e+04	2.000000	0.000000	0.000000	4.000000	8.000
max	7.700000e+06	11.000000	8.000000	13540.000000	1.651359e+06	3.500000	1.000000	4.000000	5.000000	13.000

In [4]:
```
1  train_df.columns
```
started 23:39:47 2019-04-13, finished in 5ms

Out[4]:
```
Index(['date', 'price', 'bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot',
       'floors', 'waterfront', 'view', 'condition', 'grade', 'sqft_above',
       'sqft_basement', 'yr_built', 'yr_renovated', 'zipcode', 'lat', 'long',
       'sqft_living15', 'sqft_lot15'],
      dtype='object')
```

Полезно сразу же смотреть на распределение целевой величины `price` :

In [5]:

```
1  plt.figure(figsize=(12, 8))
2  plt.title("Распределение целевой величины")
3  sns.distplot(train_df.price, kde_kws = {"lw": 3});
```

started 23:39:47 2019-04-13, finished in 419ms

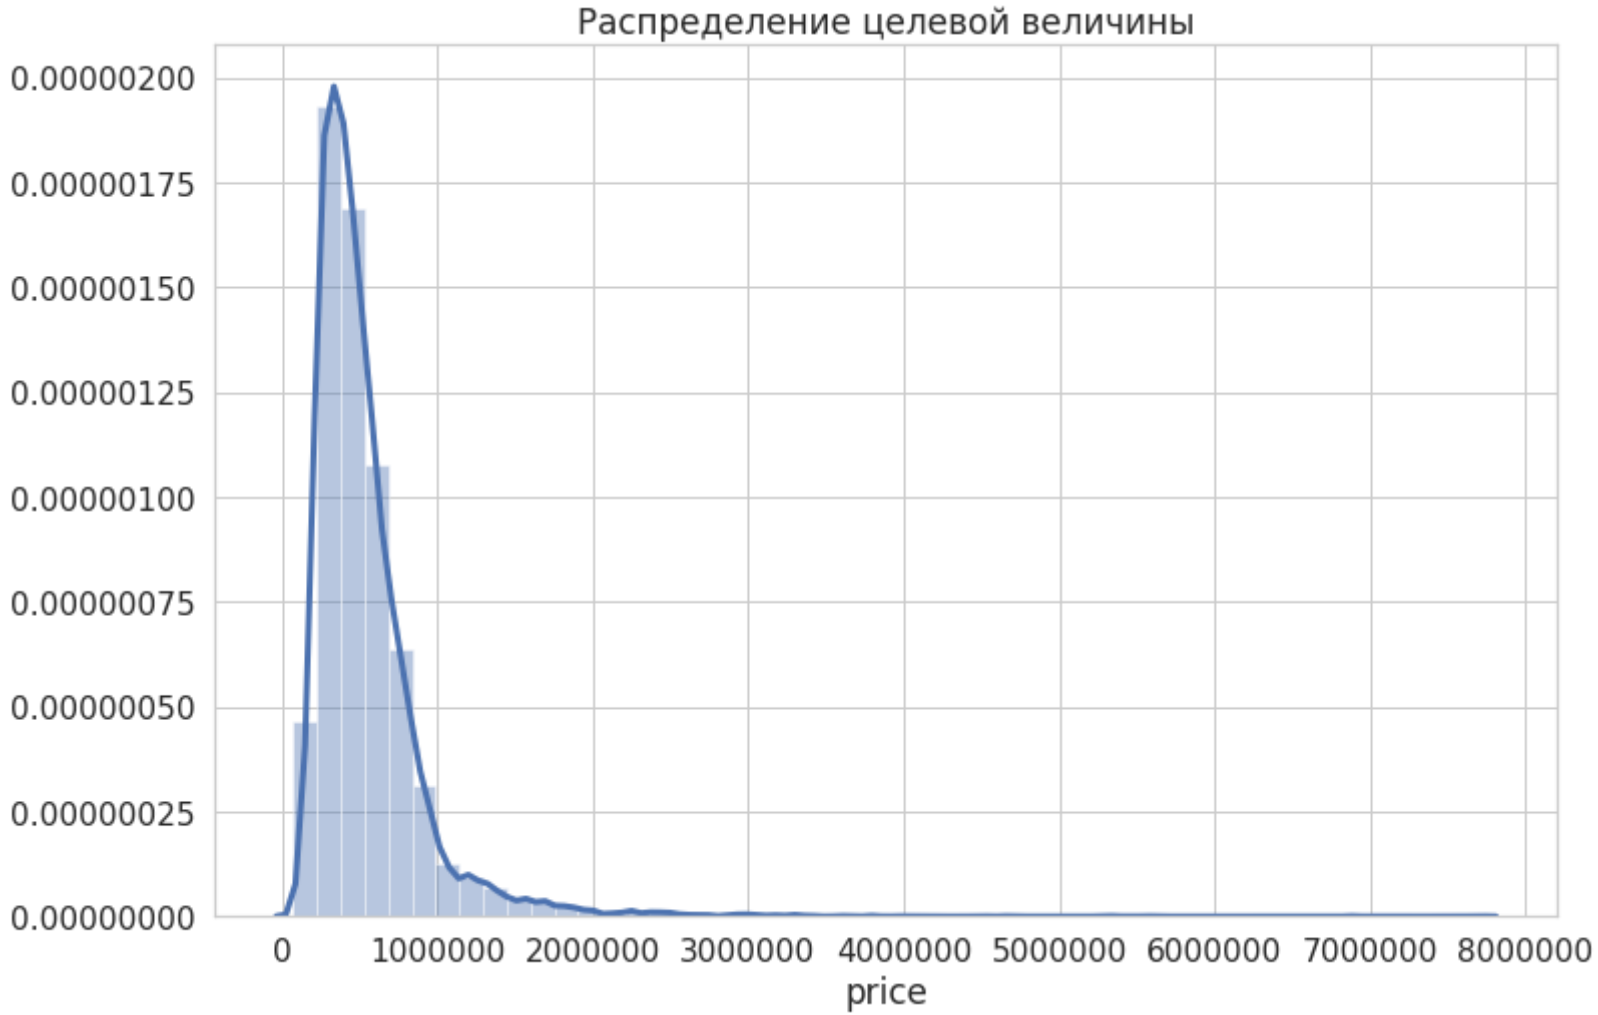

Распределение очень похоже на нормальное, но перекошено вправо.

В таких случаях принято логарифмировать, это повышает качество предсказания.

In [6]:

```
1  plt.figure(figsize=(12, 8))
2  train_df.price = train_df.price.apply(np.log)
3  plt.title("Распределение целевой величины после логарифмирования")
4  sns.distplot(train_df.price, kde_kws = {"lw": 3});
```

started 23:39:47 2019-04-13, finished in 317ms

Выделим из начальных данных полезные признаки (feature engineering).

Просуммируем такую группу признаков, как:

- `sqft_living`, `sqft_above`, `sqft_basement`

Т.к. это суммарная полезная площадь жилья без учёта приусадебного участка.

In [7]:
```
def add_up_useful_space(df):
    df["sqft_living"] += df["sqft_above"] + df["sqft_basement"]
    return df.drop(columns=["sqft_above", "sqft_basement"])

transformer_lst.append(add_up_useful_space)
train_df = train_df.pipe(add_up_useful_space)
```

started 23:39:47 2019-04-13, finished in 26ms

Кроме того, районы города `zipcode` неоднородны, потому посчитаем среднюю стоимость жилья в районе `price_by_zipcode`.

In [8]:
```
zip2price = dict(train_df.price.groupby(train_df.zipcode).mean())


def mean_price_by_zipcode(df):
    df["price_by_zipcode"] = df.zipcode.apply(zip2price.get)
    return df

transformer_lst.append(mean_price_by_zipcode)
train_df = train_df.pipe(mean_price_by_zipcode)
```

started 23:39:47 2019-04-13, finished in 12ms

Посмотрим на корреляции между признаками:

In [9]:

```
1  plt.figure(figsize=(12, 8))
2  sns.heatmap(train_df.corr(method="spearman"), cmap="coolwarm");
3  plt.title("Корреляция Спирмена между признаками");
```

started 23:39:47 2019-04-13, finished in 800ms

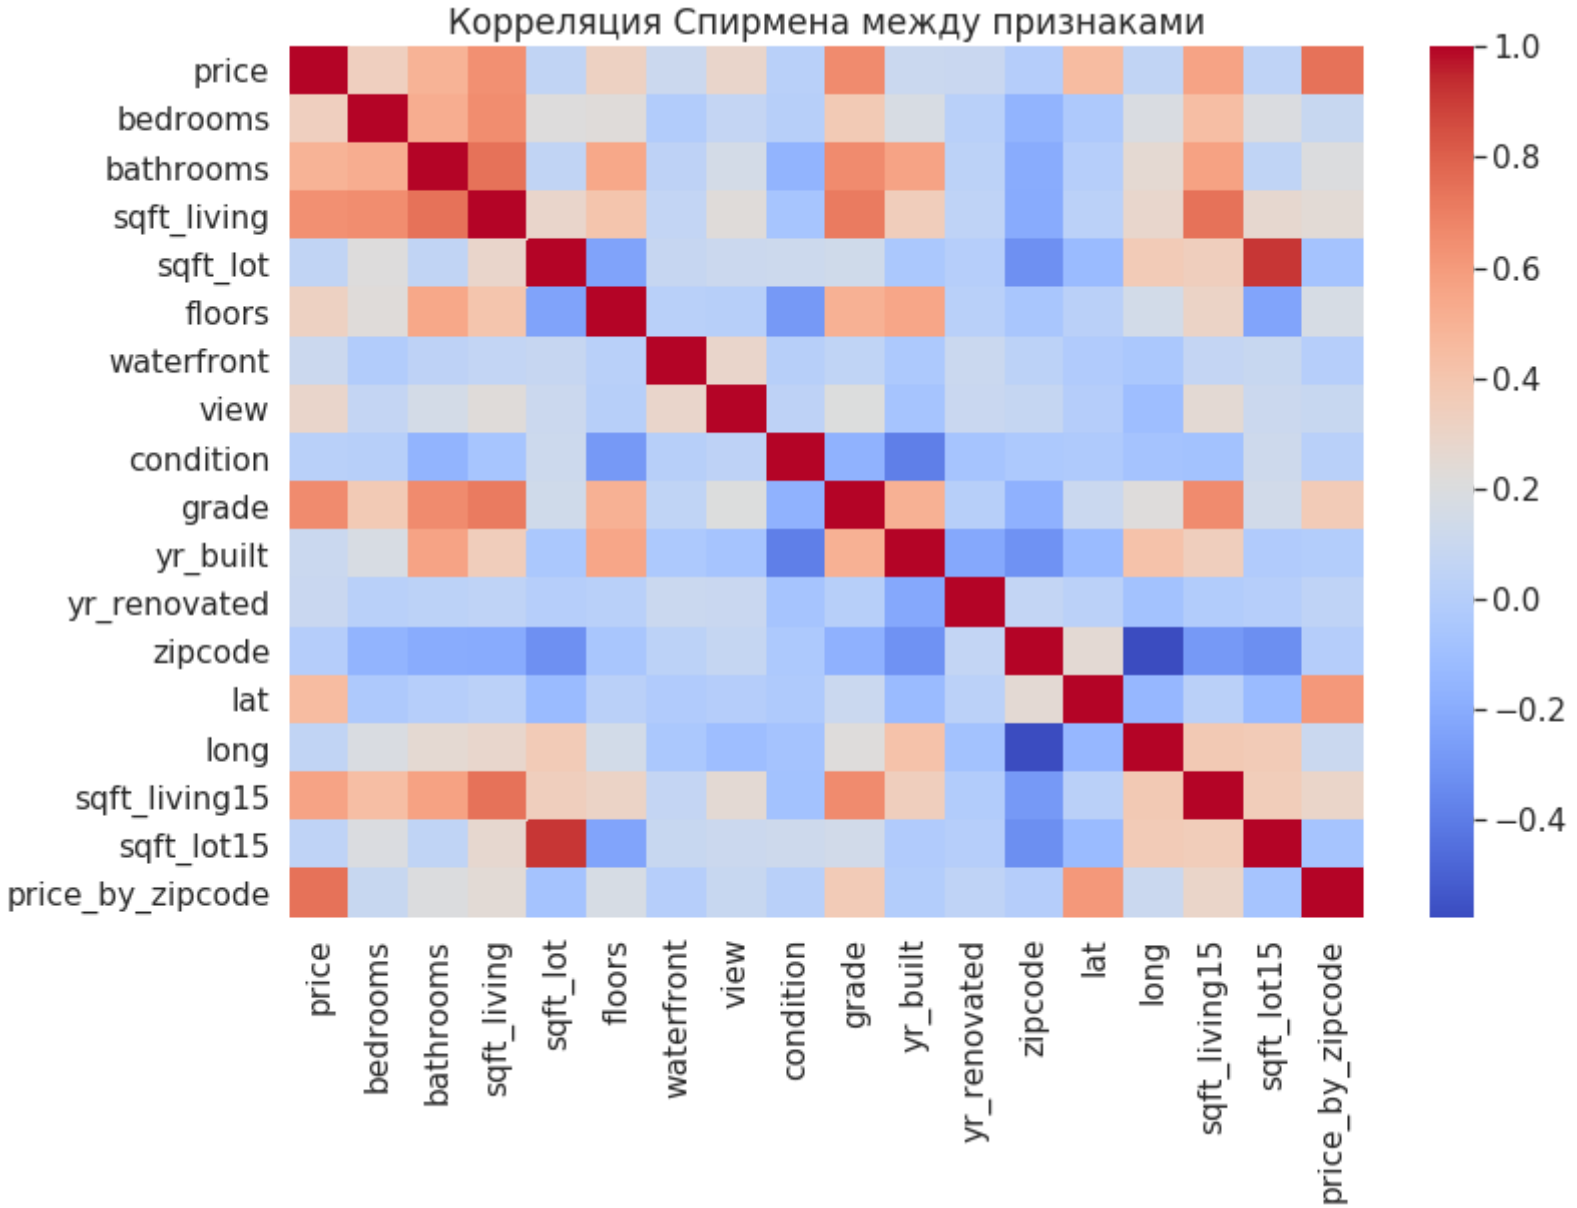

Уже отсюда видно положительную корреляцию между `price` и `sqft_living`, `sqft_living15`, `bedrooms`, `bathrooms`, `grade`, `lat`.

Посмотрим теперь на географическое распределение стоимости жилья, особенно по широте.

In [10]:

```
sns.set(style="darkgrid", font_scale=1.4)
plt.figure(figsize=(14, 10))
plt.title("Зависимость цены от географических координат")
ax = sns.scatterplot(x="long", y="lat",
                     data=train_df,
                     hue="price",
                     palette="coolwarm");
plt.title
plt.legend().get_frame().set_facecolor("white")
ax.set(xlabel='долгота (long)', ylabel='ширина (lat)');
```

started 23:39:48 2019-04-13, finished in 1.42s

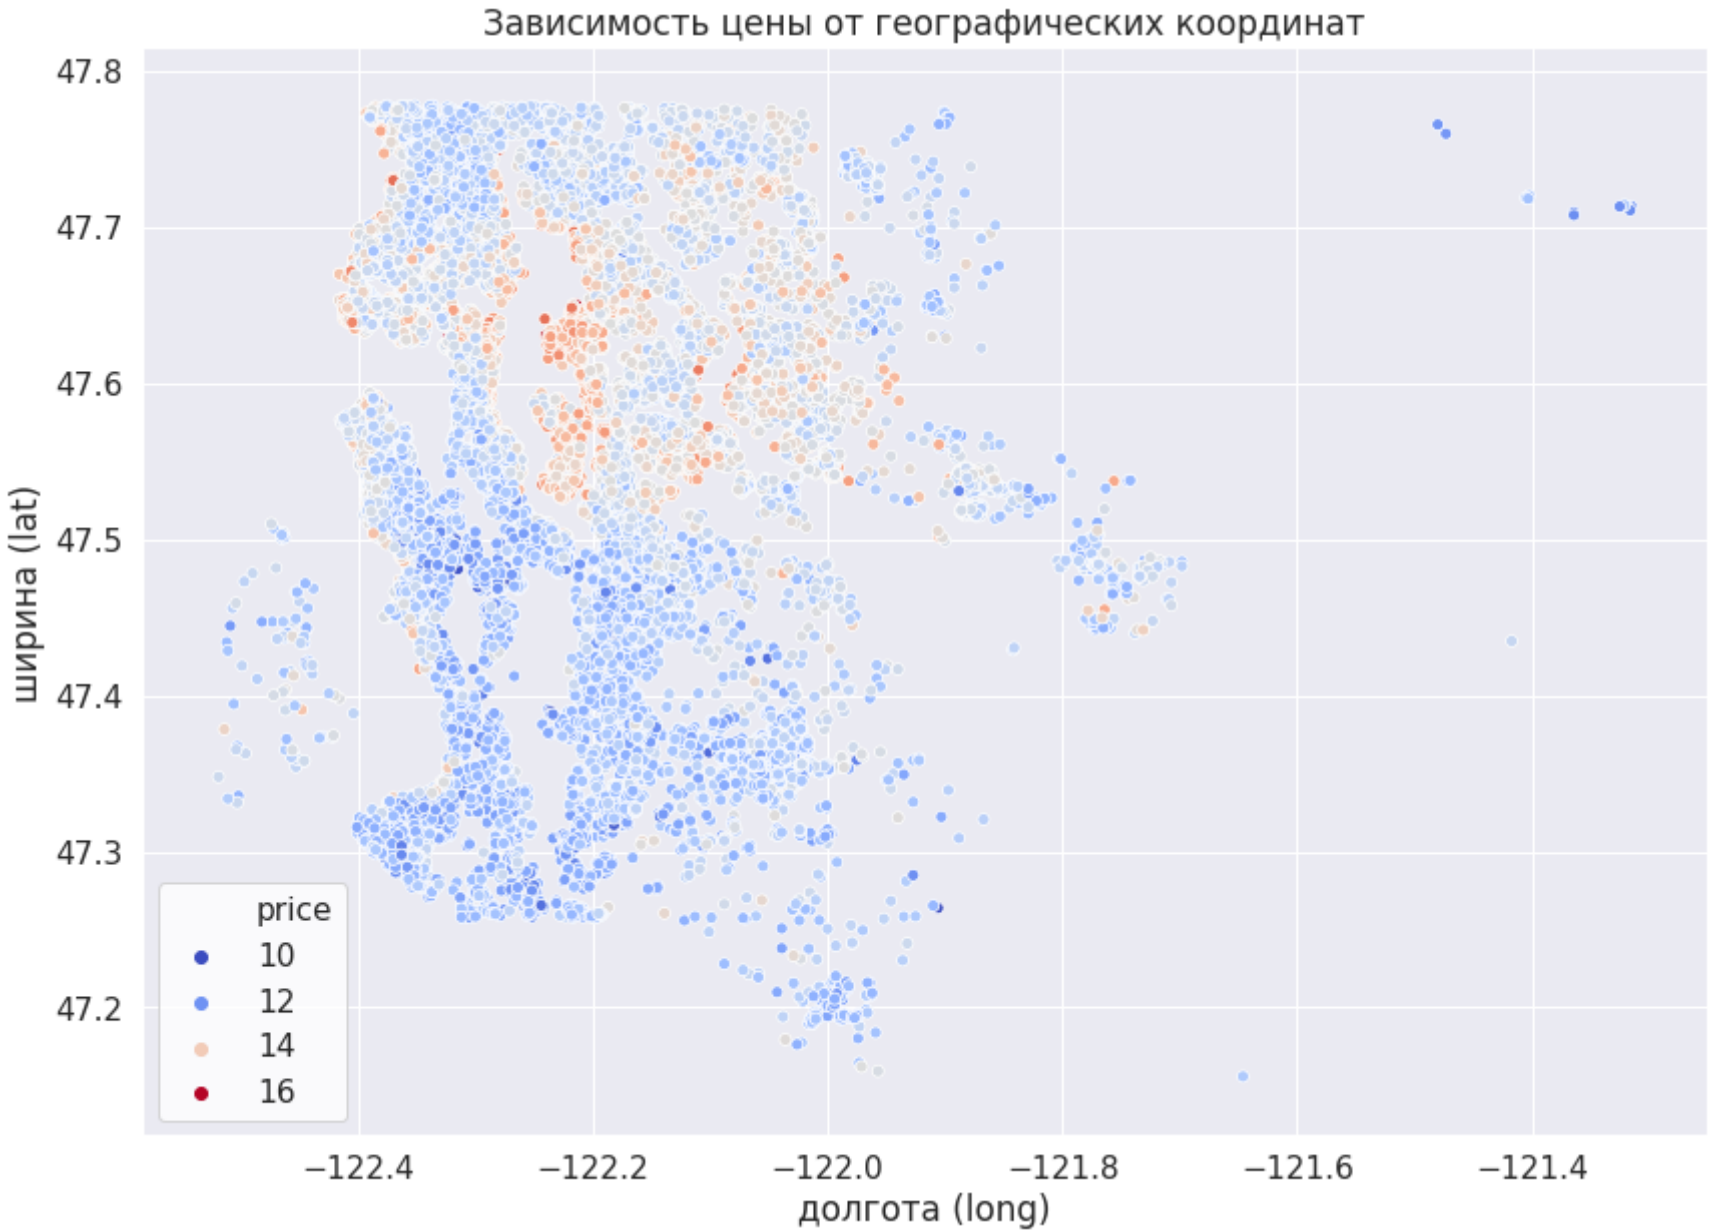

Чётко видно, что примерно по широте в 47.5 пролегает черта, над которой жильё сильно дороже, чем под ней.
По долготе таких закономерностей не наблюдается. Посмотрим на совместное распределение цены и широты.

In [11]:

```
1  sns.set(font_scale=1.4, style="whitegrid")
2  g = sns.jointplot(x="price", y="lat", data=train_df, kind="kde", cmap="coolwarm")
3  g.set_axis_labels(xlabel='цена (price)', ylabel='ширина (lat)');
4  g.fig.suptitle("Совместное распределение цены и широты", y = 1.05);
```

started 23:39:50 2019-04-13, finished in 12.8s

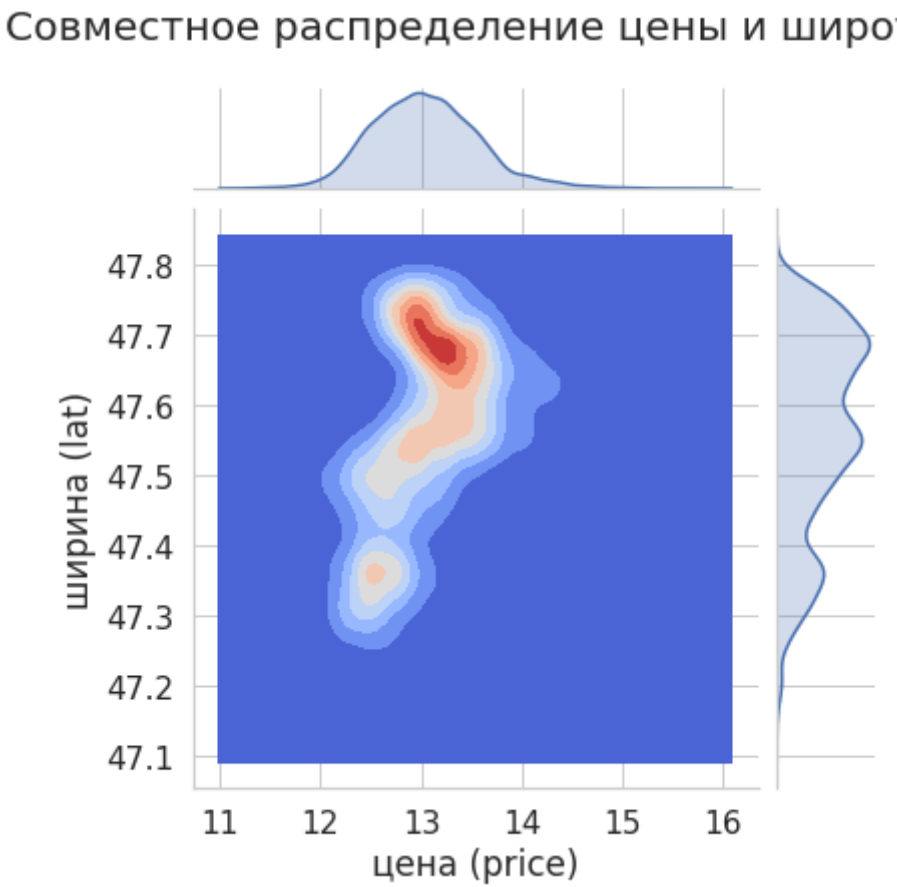

Построим аналогичный график, сделав окрашивание по средней цене дома в районе `zipcode` :

In [12]:

```
sns.set(style="darkgrid", font_scale=1.4)
plt.figure(figsize=(14, 10))
plt.title("Зависимость средней цены по району от географических координат")
ax = sns.scatterplot(x="long", y="lat",
                     data=train_df,
                     hue="price_by_zipcode",
                     palette="coolwarm");
plt.legend().get_frame().set_facecolor("white")
ax.set(xlabel='долгота (long)', ylabel='ширина (lat)');
```

started 23:40:03 2019-04-13, finished in 1.44s

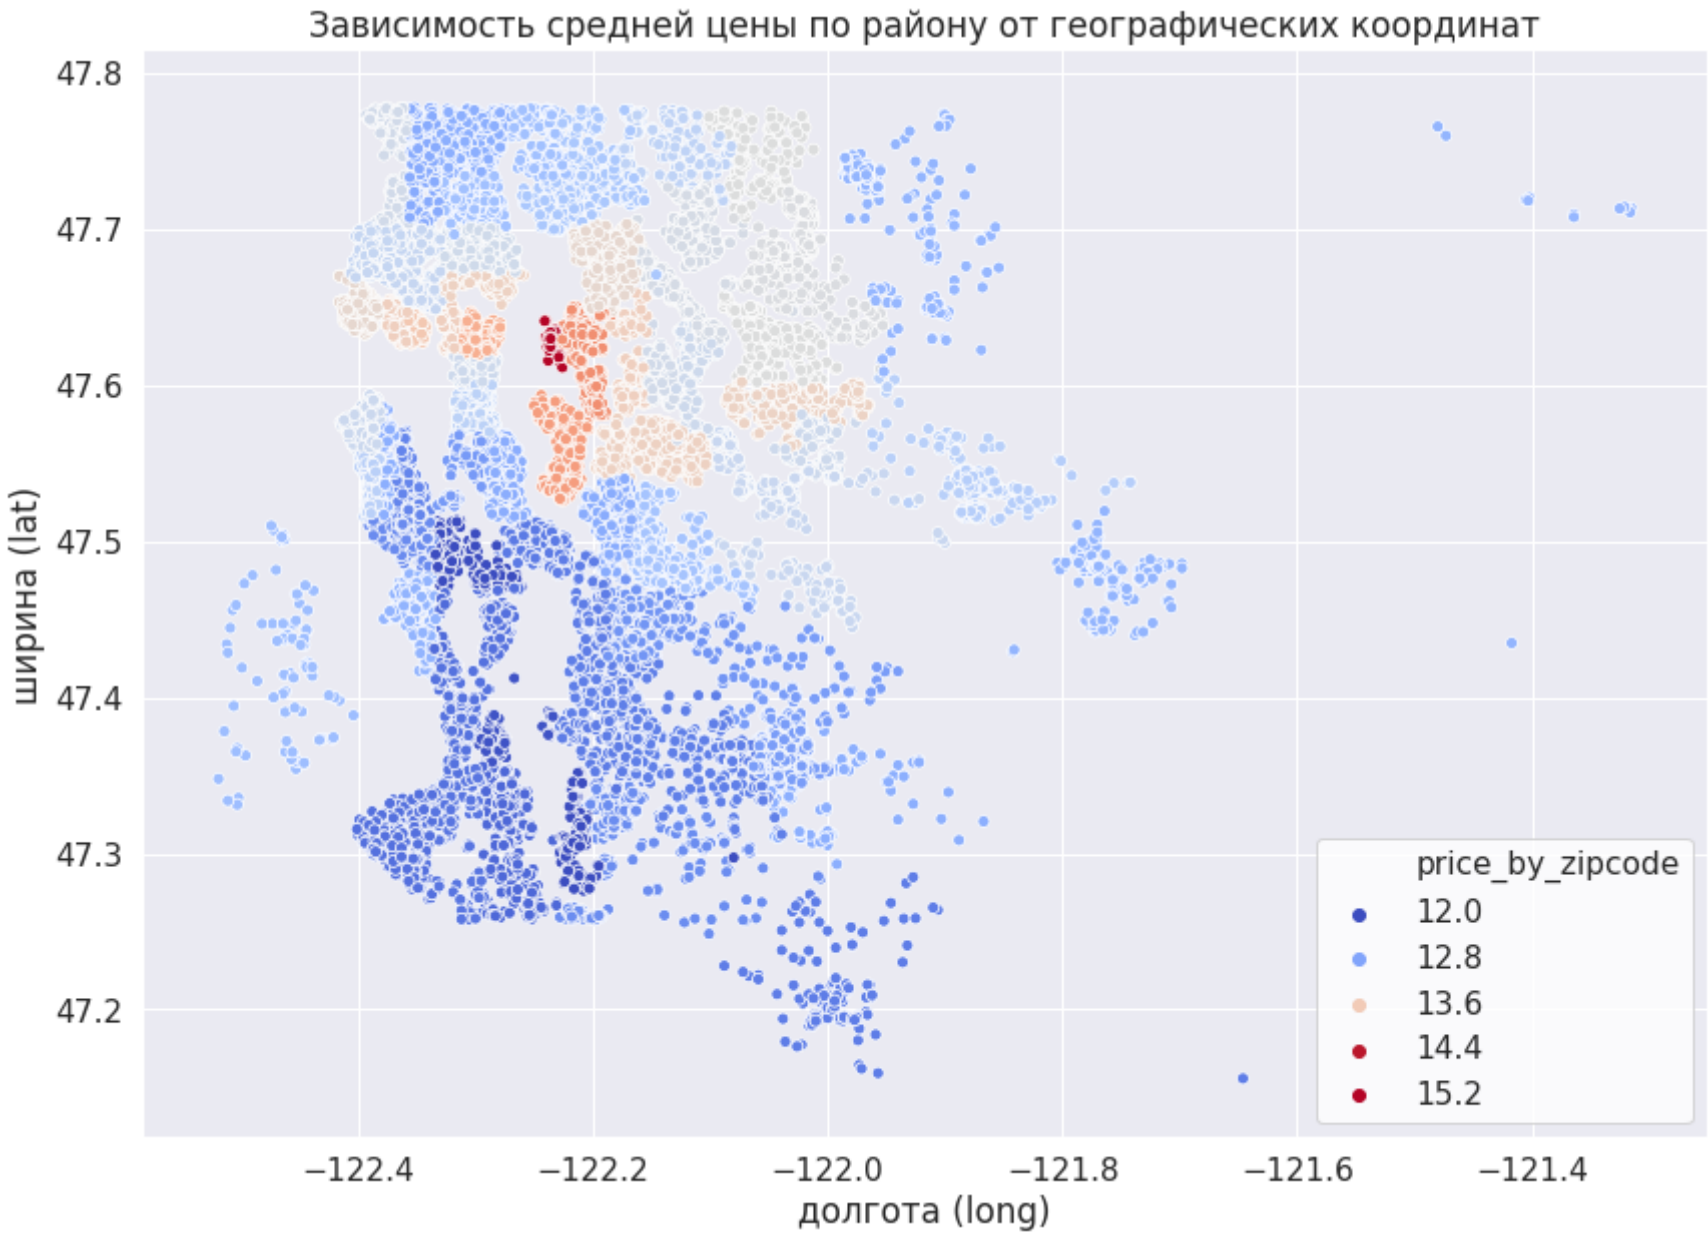

Ярко выделяется группа районов с существенно более высокой средей ценой жилья. Их стоит сделать отдельными признаками.

Так как география играет очень важное значение в распределении цены, добавим такие признаки, как расстояние до (центроида) самого дорогого района `dist_to_luxury` и лучшего дома там `dist_to_best_home` . Аналогично для самого дешевого района `dist_to_borough` и для самого дешевого дома `dist_to_worst_home` .

In [13]:

```
luxurious_zipcode = train_df["price"].groupby(train_df["zipcode"]).mean().argmax()
borough_zipcode = train_df["price"].groupby(train_df["zipcode"]).mean().argmin()
luxurious_centroid = train_df[["lat", "long"]][train_df["zipcode"] == luxurious_zipcode].mean(axis=0).
borough_centroid = train_df[["lat", "long"]][train_df["zipcode"] == borough_zipcode].mean(axis=0).valu
best_home =  train_df[["lat", "long"]][train_df.index == train_df["price"].argmax()].values
worst_home =  train_df[["lat", "long"]][train_df.index == train_df["price"].argmin()].values

def compute_distance_to_best(df):
    df["dist_to_luxury"] = np.sqrt(((df[["lat", "long"]] - luxurious_centroid)**2).sum(axis=1))
    df["dist_to_borough"] = np.sqrt(((df[["lat", "long"]] - borough_centroid)**2).sum(axis=1))
    df["dist_to_best_home"]  = np.sqrt(((df[["lat", "long"]] - best_home)**2).sum(axis=1))
    df["dist_to_worst_home"]  = np.sqrt(((df[["lat", "long"]] - worst_home)**2).sum(axis=1))
    return df

transformer_lst.append(compute_distance_to_best)
train_df = train_df.pipe(compute_distance_to_best)
```

started 23:40:04 2019-04-13, finished in 44ms

Посмотрим на среднюю цену `price` в зависимости от района `zipcode` :

In [14]:

```
top_zipcode_df = pd.DataFrame(zip2price.items(),
                              columns=["zipcode", "price_by_zipcode"])\
                .sort_values(by="price_by_zipcode", ascending=False)
top_zipcode_df.head(20)
```

started 23:40:04 2019-04-13, finished in 68ms

Out[14]:

	zipcode	price_by_zipcode
24	98039	14.439936
3	98004	13.966140
25	98040	13.896902
48	98112	13.795915
47	98109	13.629784
4	98005	13.564103
53	98119	13.558866
41	98102	13.558683
5	98006	13.546460
43	98105	13.534096
38	98075	13.527479
21	98033	13.472257
69	98199	13.466789
39	98077	13.388562
37	98074	13.387051
29	98053	13.368447
28	98052	13.330503
65	98177	13.295388
6	98007	13.295050
49	98115	13.288366

Возьмем первые 13 районов в порядке этой сортировки (т.к. потом происходит скачок в первом знаке после запятой) и добавим

отдельными признаками с помощью `one-hot encoding`.

In [15]:
```
top_zipcode_lst = top_zipcode_df.head(13).zipcode.values

def one_hot_best_zipcodes(df):
    old_zipcode_lst = np.unique(df.zipcode)
    df = pd.get_dummies(df, columns=["zipcode"])
    for zipcode in old_zipcode_lst:
        if zipcode not in top_zipcode_lst:
            df.drop(columns=[f"zipcode_{zipcode}"], inplace=True)
    return df

transformer_lst.append(one_hot_best_zipcodes)
train_df = train_df.pipe(one_hot_best_zipcodes)
```

started 23:40:04 2019-04-13, finished in 143ms

Кроме того, можно считать, что присутствует корреляция между возрастом здания `yr_built` и его **стоимостью**.
Также стоит отметить, что чем меньше **лет прошло с момента последнего ремонта** `yr_renovated`, тем лучше состояние квартиры.

Создадим новые признаки:

- `yr_published` - год продажи дома
- `mnth_published` - месяц продажи дома
- `age` - число лет с моменты постройки до продажи
- `yr_since_renovation` - число лет с момента последнего ремонта до продажи
- `new_building` - бинарный признак, дом считается новым, если ему менее 10 лет

In [16]:

```python
def extract_from_date(df):
    df["yr_published"] = df["date"].apply(lambda s: int(s.split("T")[0][:4]))
    df["mnth_published"] = df["date"].apply(lambda s: int(s.split("T")[0][4:6]))
    df["age"] = df["yr_published"] - df["yr_built"] + 1
    df["yr_since_renovation"] = df["yr_published"] - df["yr_renovated"] + 1
    df["yr_since_renovation"][df["yr_renovated"] == 0] = 0
    df["new_building"] = df["age"] <= 10
    return df.drop(columns=["date", "yr_built", "yr_renovated", "yr_published"])

transformer_lst.append(extract_from_date)
train_df = train_df.pipe(extract_from_date)
```

started 23:40:04 2019-04-13, finished in 100ms

Кроме того, спрос на жильё (и, как следствие, предложение на рынке) имеет сезонность, которую можно учесть. Посмотрим, есть ли зависимость между месяцем/годом и ценой.

In [17]:

```
plt.figure(figsize=(14, 10))
sns.set(font_scale=1.4, style="whitegrid")
plt.title("Зависимость цены от месяца продажи")
ax = sns.lineplot(x="mnth_published", y="price", data=train_df)
ax.set(xlabel='месяц продажи (mnth_published)', ylabel='цена (price)');
```

started 23:40:04 2019-04-13, finished in 650ms

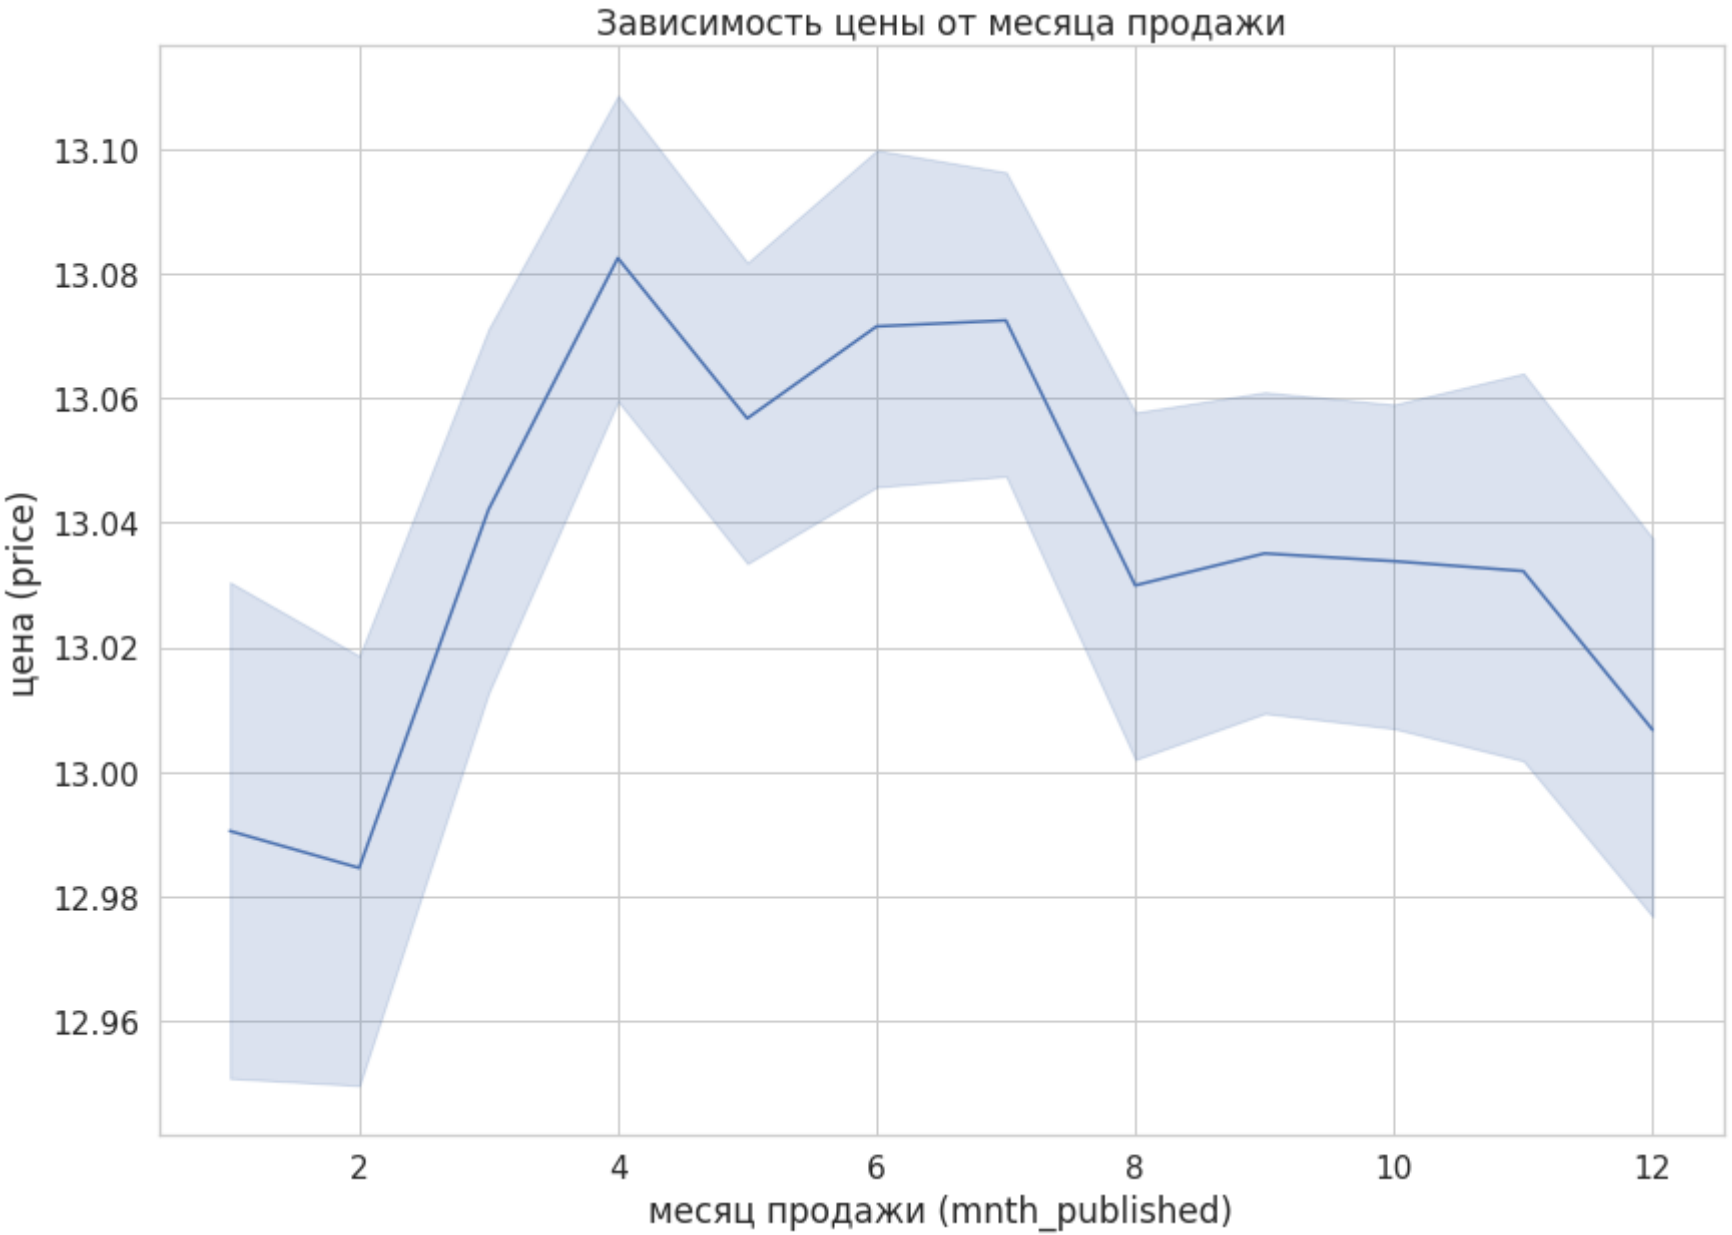

Видим, что стоимость жилья значимо выше в тёплое время года, с марта по июль. Поэтому добавим бинарный признак тёплого сезона.

In [18]:

```
def extract_seasonality(df):
    df["warm_season"] = (3 <= df["mnth_published"]) & (df["mnth_published"] <= 7)
    return df.drop(columns=["mnth_published"])

transformer_lst.append(extract_seasonality)
train_df = train_df.pipe(extract_seasonality)
```

started 23:40:05 2019-04-13, finished in 7ms

Посмотрим снова на корреляции между признаками:

In [19]:

```
1  plt.figure(figsize=(20, 15));
2  sns.heatmap(train_df.corr("spearman"), cmap="coolwarm")
3  plt.title("Корреляция Спирмена между признаками");
```

started 23:40:05 2019-04-13, finished in 2.30s

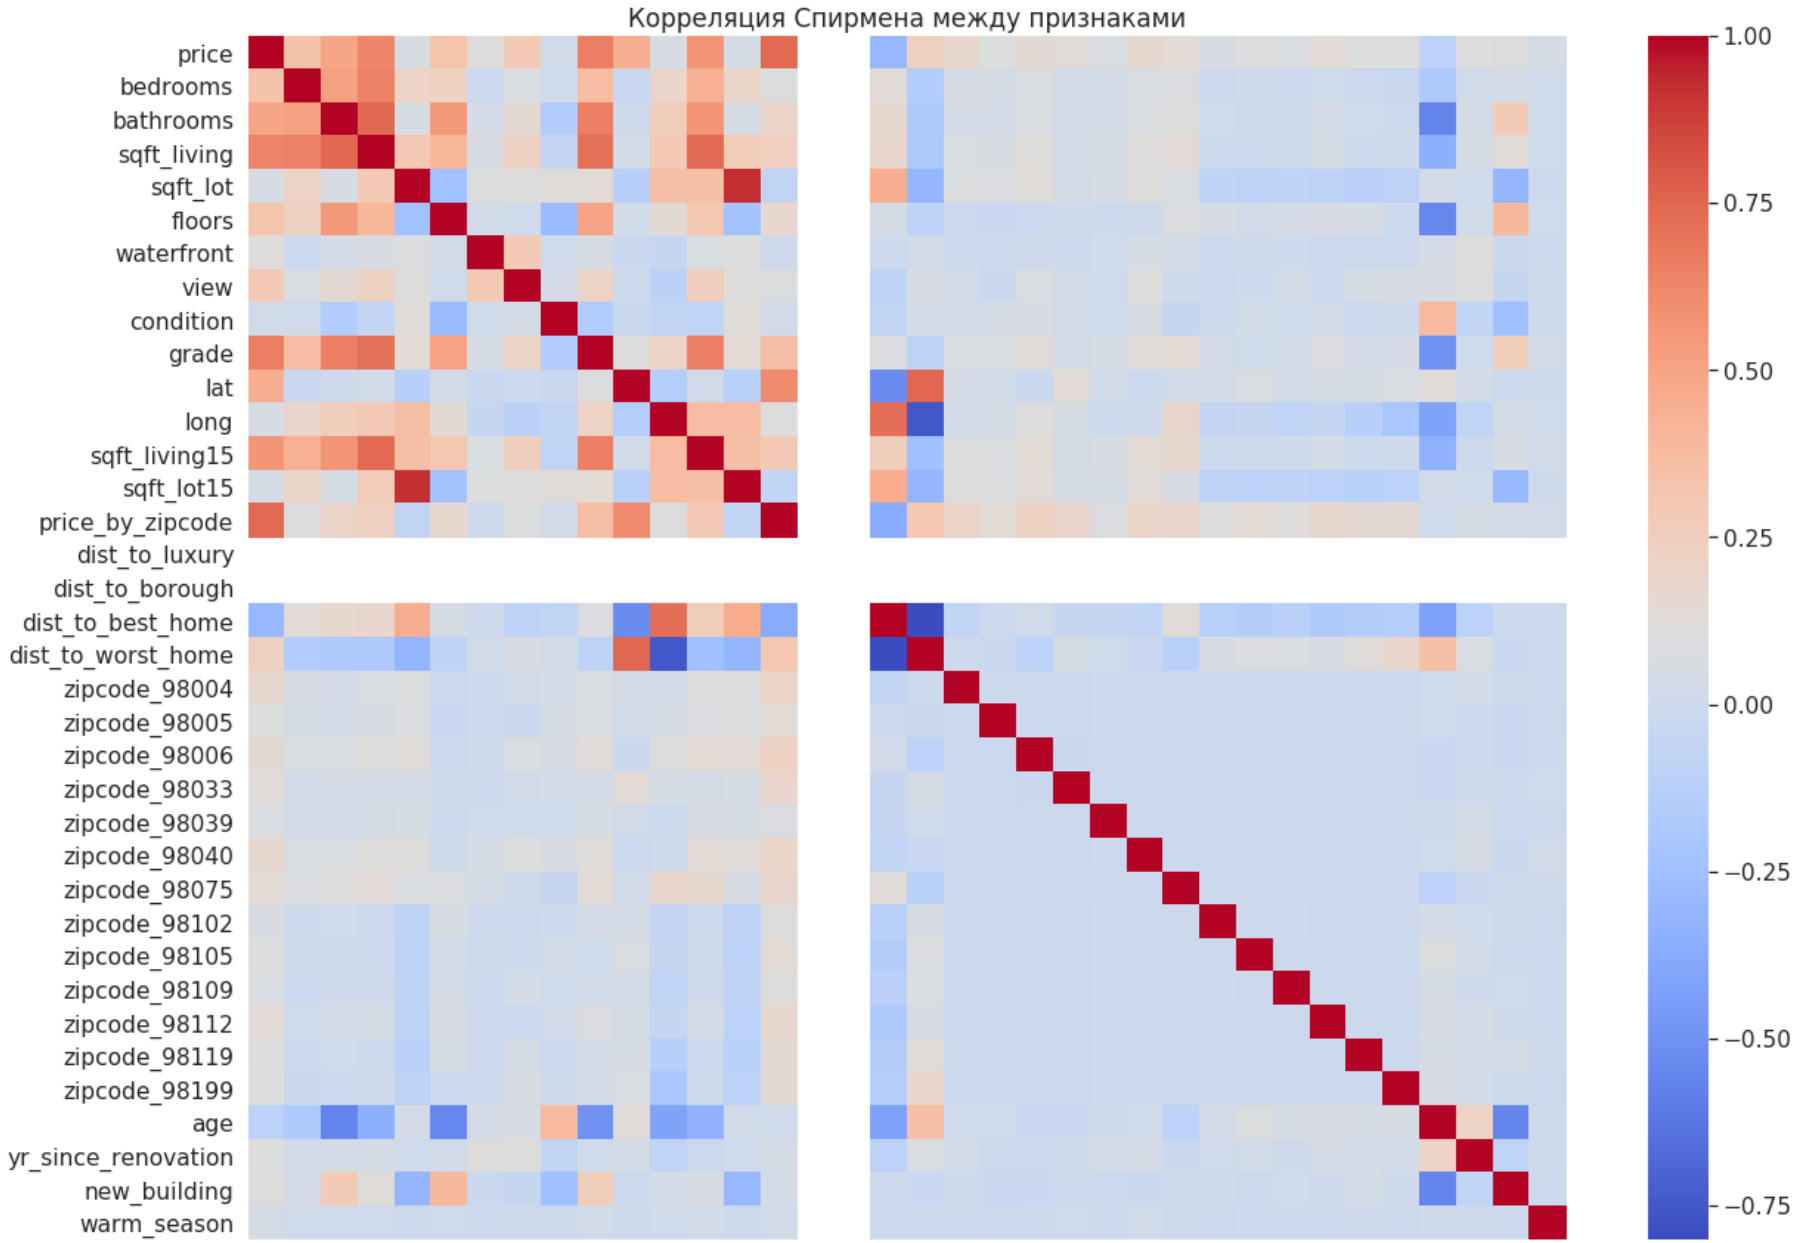

Складывается впечатление, что большая часть добавленных признаков бесполезна: стоимость почти не коррелирует с районом `zipcode` и сезонностью.

2. Обучение моделей и их анализ

Обучим теперь бустинг с параметрами, выбранными "на глаз", чтобы оценить по кросс-валидации текущую ошибку предсказания. Кроме того, по результатам бустинга уберём бесполезные признаки.

In [20]:

```
def mape(y_true, y_pred):
    y_true, y_pred = np.array(y_true), np.array(y_pred)
    return 100 * np.mean(np.abs((y_true - y_pred) / y_true))

mape_scorer = make_scorer(mape, greater_is_better=False)
```

started 23:40:07 2019-04-13, finished in 4ms

In [21]:

```
grid_cv = GridSearchCV(xgb.XGBRegressor(gamma=0.1, subsample=0.75,
                                        n_estimators=1000, max_depth=5,
                                        nthread=-1),
                       {}, cv=5, verbose=True, scoring=mape_scorer, n_jobs=5)
grid_cv.fit(train_df.drop(columns=["price"]), train_df.price)
```

started 23:40:07 2019-04-13, finished in 27.6s

```
Fitting 5 folds for each of 1 candidates, totalling 5 fits

[Parallel(n_jobs=5)]: Using backend LokyBackend with 5 concurrent workers.
[Parallel(n_jobs=5)]: Done   2 out of   5 | elapsed:   50.3s remaining:  1.3min
[Parallel(n_jobs=5)]: Done   5 out of   5 | elapsed:  1.0min finished
```

Out[21]:

```
GridSearchCV(cv=5, error_score=nan,
             estimator=XGBRegressor(base_score=None, booster=None,
                                    colsample_bylevel=None,
                                    colsample_bynode=None,
                                    colsample_bytree=None, gamma=0.1,
                                    gpu_id=None, importance_type='gain',
                                    interaction_constraints=None,
                                    learning_rate=None, max_delta_step=None,
                                    max_depth=5, min_child_weight=None,
                                    missing=nan, monotone_constraints=None,
                                    n_estimators...
                                    num_parallel_tree=None,
                                    objective='reg:squarederror',
                                    random_state=None, reg_alpha=None,
                                    reg_lambda=None, scale_pos_weight=None,
                                    subsample=0.75, tree_method=None,
                                    validate_parameters=False, verbosity=None),
             iid='deprecated', n_jobs=5, param_grid={}, pre_dispatch='2*n_jobs',
             refit=True, return_train_score=False,
             scoring=make_scorer(mape, greater_is_better=False), verbose=True)
```

In [22]:

```
-grid_cv.best_score_
```

started 23:40:35 2019-04-13, finished in 4ms

Out[22]:

```
0.950526231638612
```

In [23]:

```
1  sns.set(style="darkgrid", font_scale=1.4)
2  fig, ax = plt.subplots(1,1,figsize=(15, 15))
3  xgb.plot_importance(grid_cv.best_estimator_, ax=ax);
```

started 23:40:35 2019-04-13, finished in 695ms

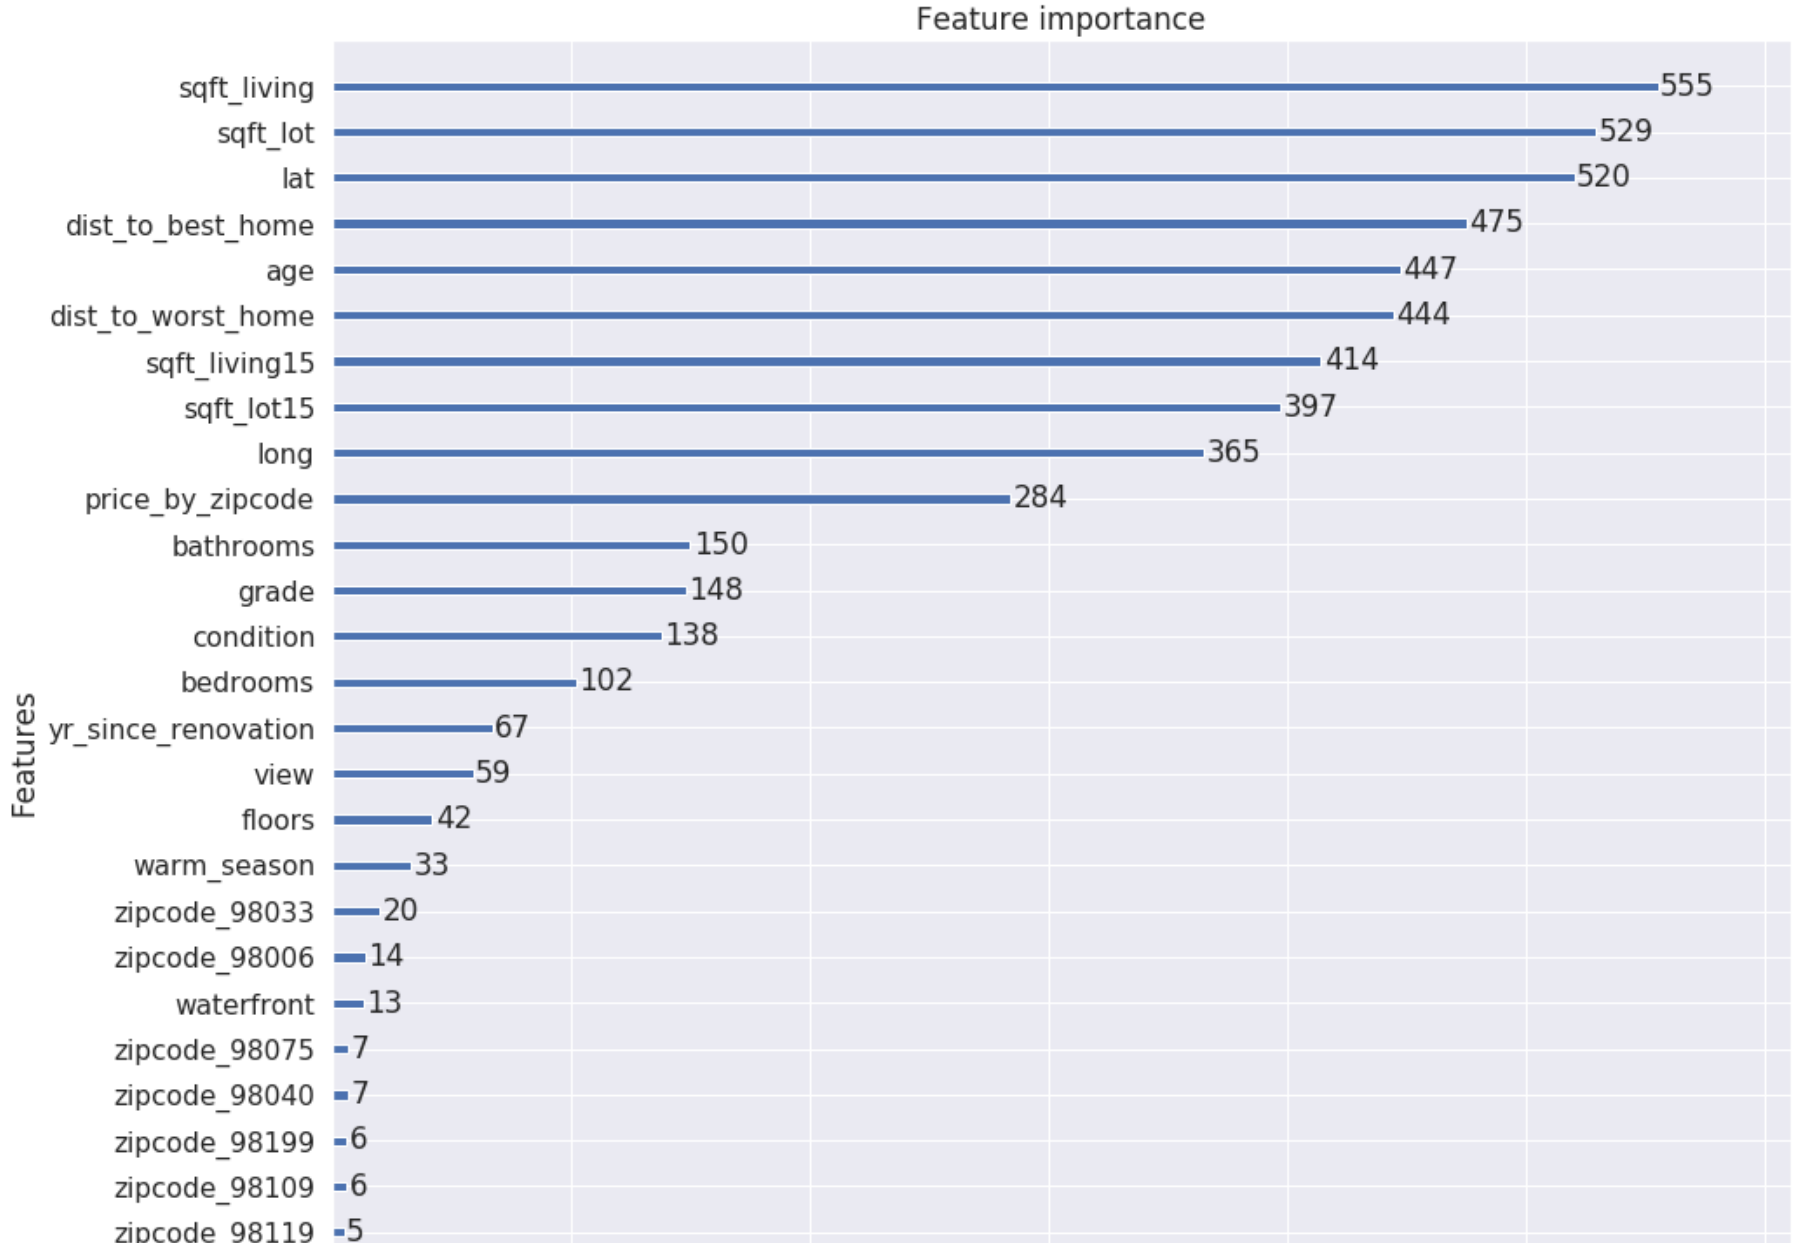

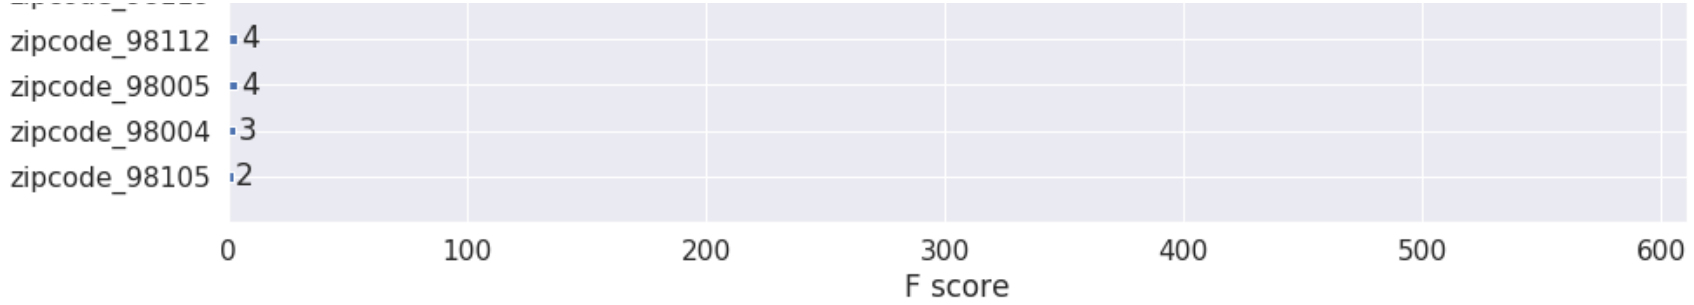

Видно, что **зипкоды** бесполезны (т.к. информация, которую они несут, дублируется другими признаками), потому просто выбросим их. Кроме того, **вид на воду** почему-то не вдохновляет покупателей, а **сезонность** оказалась притянутой за уши.
Важнее всего оказались географические и самые банальные признаки: широта, долгота, расстояние до самого дорогого и до самого плохого района, площадь помещений и участка, а также год постройки и окружение (средняя стоимость жилья в районе, средняя площадь окрестного жилья).

3. Дальнейший анализ признаков

Удалим незначимые признаки:

In [24]:
```
def remove_redundant_features(df):
    init_col_lst = df.columns
    for colname in init_col_lst:
        splitted = colname.split("_")
        if splitted[0] == "zipcode" and splitted[1] != top_zipcode_lst[0]:
            df.drop(columns=[colname], inplace=True)
    df.drop(columns=["warm_season", "waterfront", "new_building"], inplace=True)
    return df

transformer_lst.append(remove_redundant_features)
train_df = train_df.pipe(remove_redundant_features)
```

started 23:40:36 2019-04-13, finished in 24ms

In [25]:
```
1  train_df.columns
```
started 23:40:36 2019-04-13, finished in 13ms

Out[25]:
```
Index(['price', 'bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors',
       'view', 'condition', 'grade', 'lat', 'long', 'sqft_living15',
       'sqft_lot15', 'price_by_zipcode', 'dist_to_luxury', 'dist_to_borough',
       'dist_to_best_home', 'dist_to_worst_home', 'age',
       'yr_since_renovation'],
      dtype='object')
```

Чтобы учесть вклад самых значимых признаков в модель, дополним датасет взаимодействиями (произведениями признаков):

In [26]:
```
1  def add_interactions(df):
2      for xcolname in ["sqft_living", "lat"]:
3          for ycolname in ["bedrooms", "floors", "bathrooms", "condition", "grade"]:
4              df["{}_x_{}".format(xcolname, ycolname)] = df[xcolname] * df[ycolname]
5      return df
6
7  transformer_lst.append(add_interactions)
8  train_df = train_df.pipe(add_interactions)
```
started 23:40:36 2019-04-13, finished in 14ms

Посмотрим на распределение оставшихся признаков:

In [27]:

```
sns.set(font_scale=1.2, style="whitegrid")
f, axes = plt.subplots(7, 3, figsize=(17, 35))
i = 0
for feature in train_df.columns:
    if len(np.unique(train_df[feature])) > 100:
        sns.distplot(train_df[feature], kde_kws = {"lw": 3}, ax = axes[i // 3][i % 3])
        i += 1
plt.show()
```

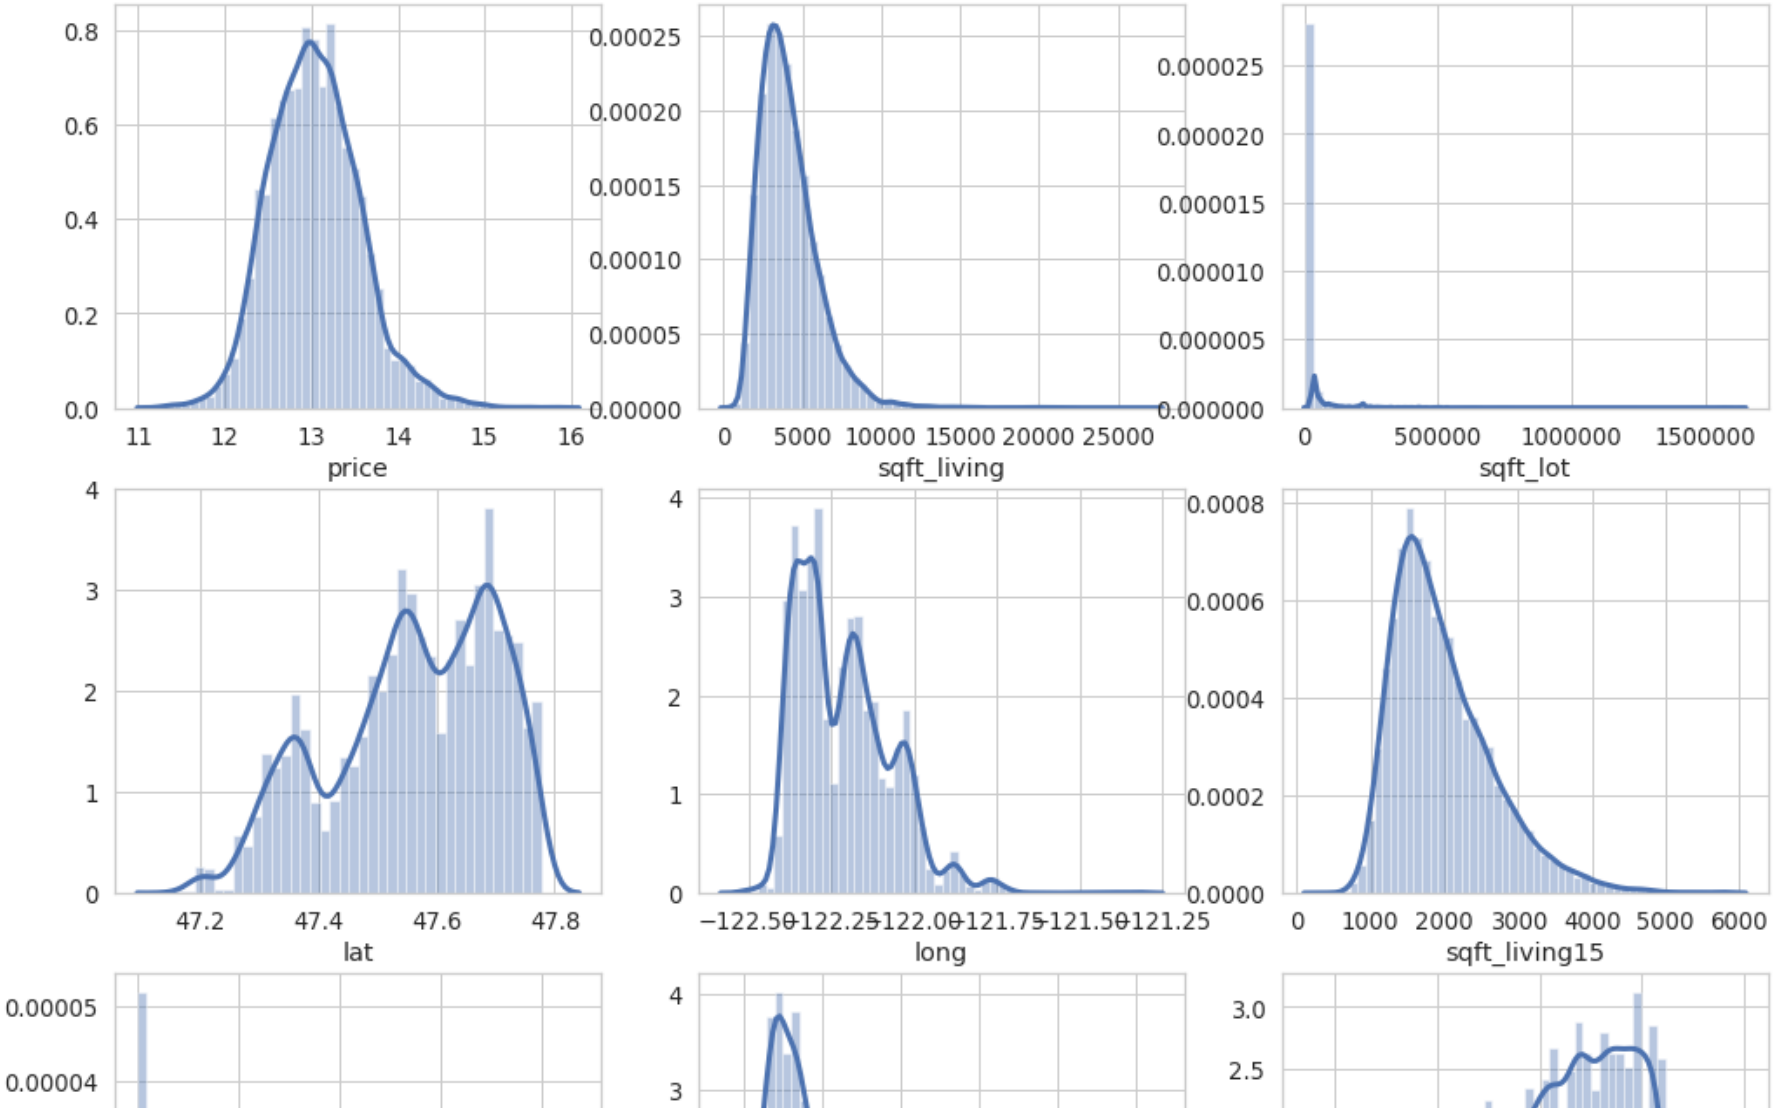

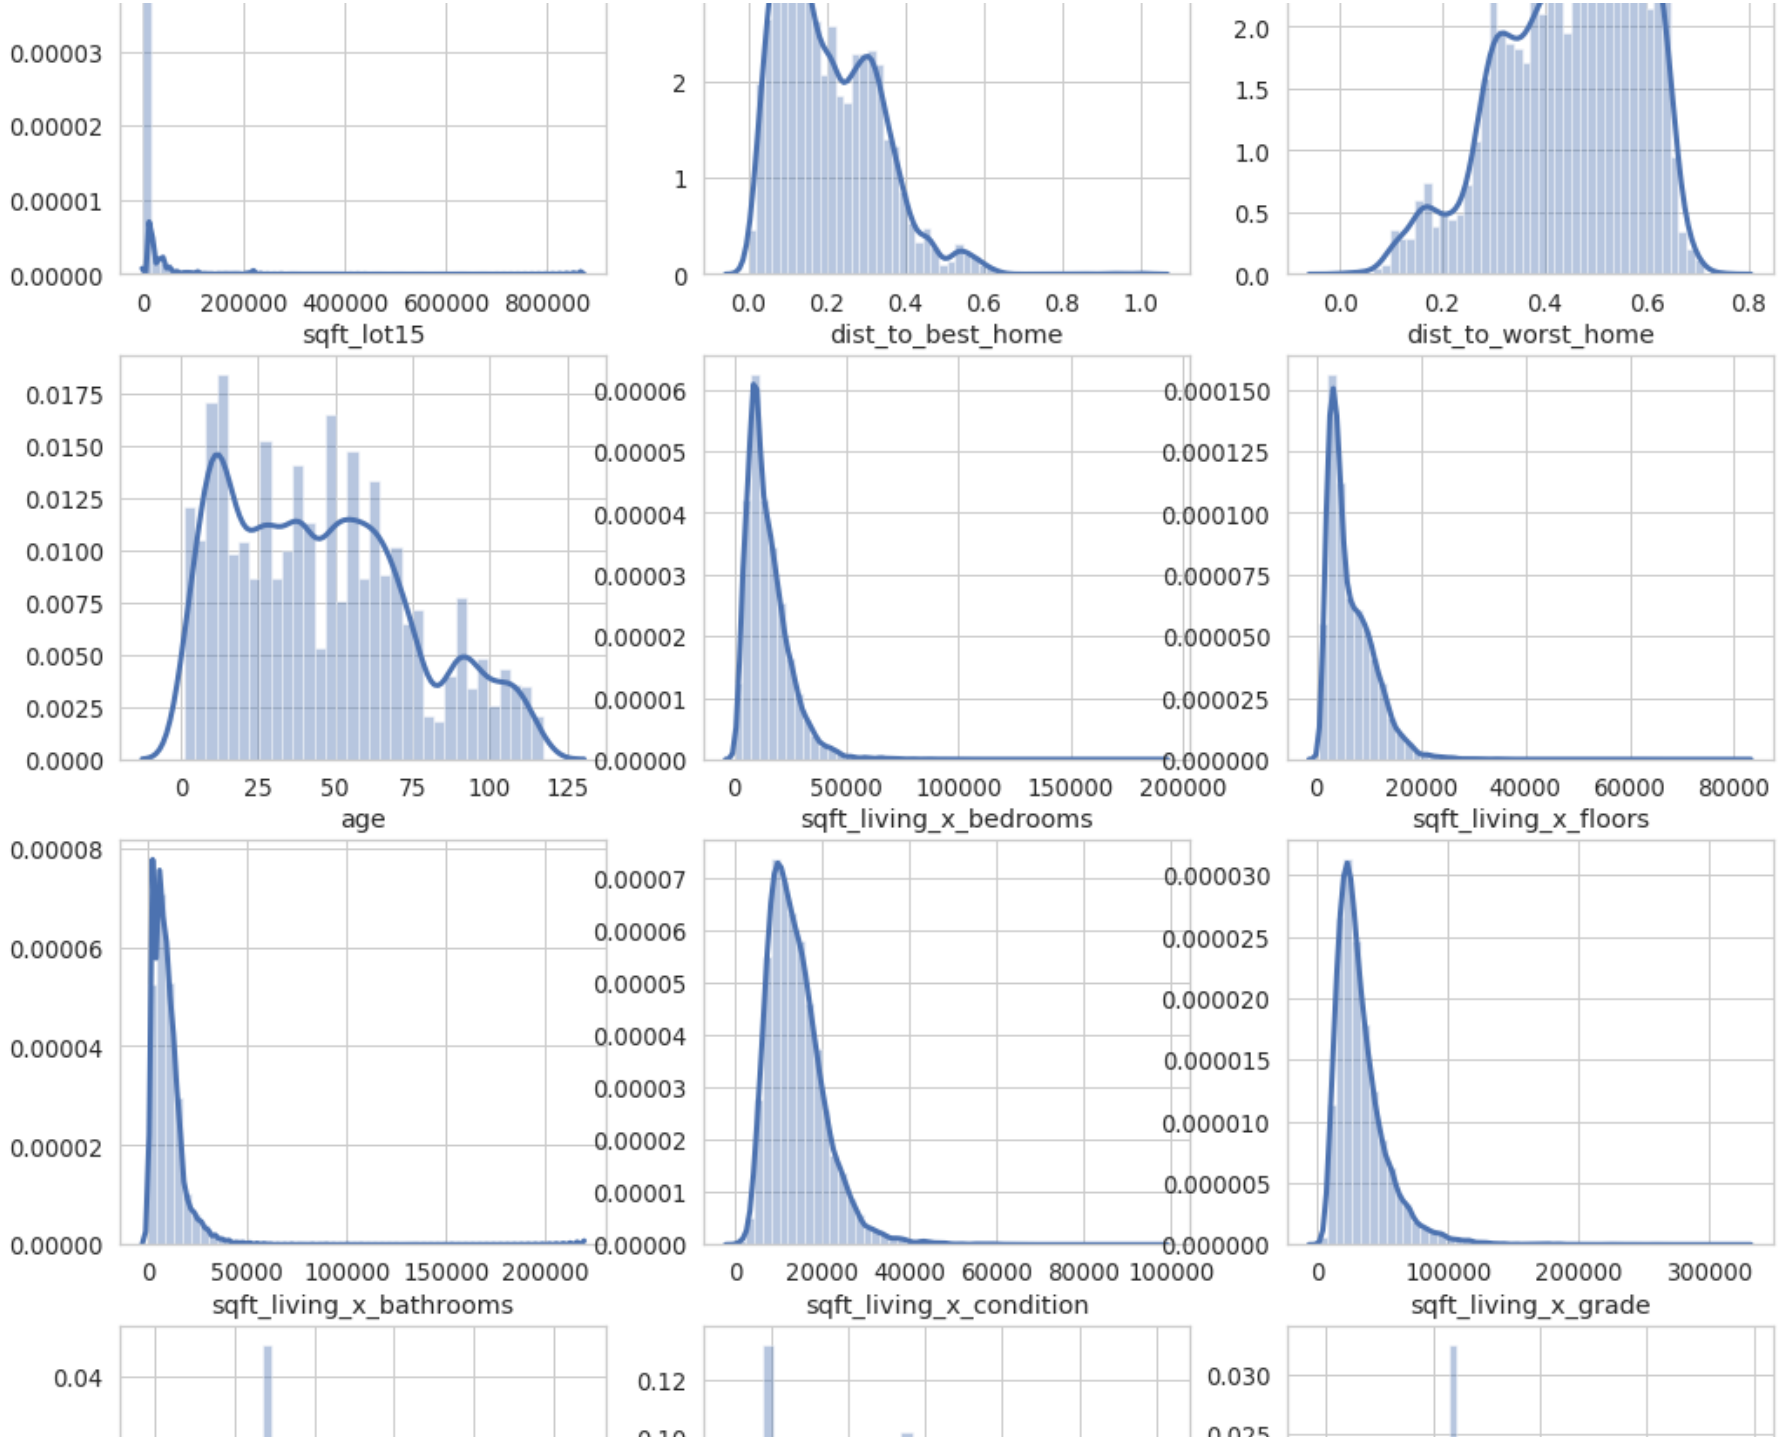
sqft_lot15
dist_to_best_home
dist_to_worst_home
age
sqft_living_x_bedrooms
sqft_living_x_floors
sqft_living_x_bathrooms
sqft_living_x_condition
sqft_living_x_grade

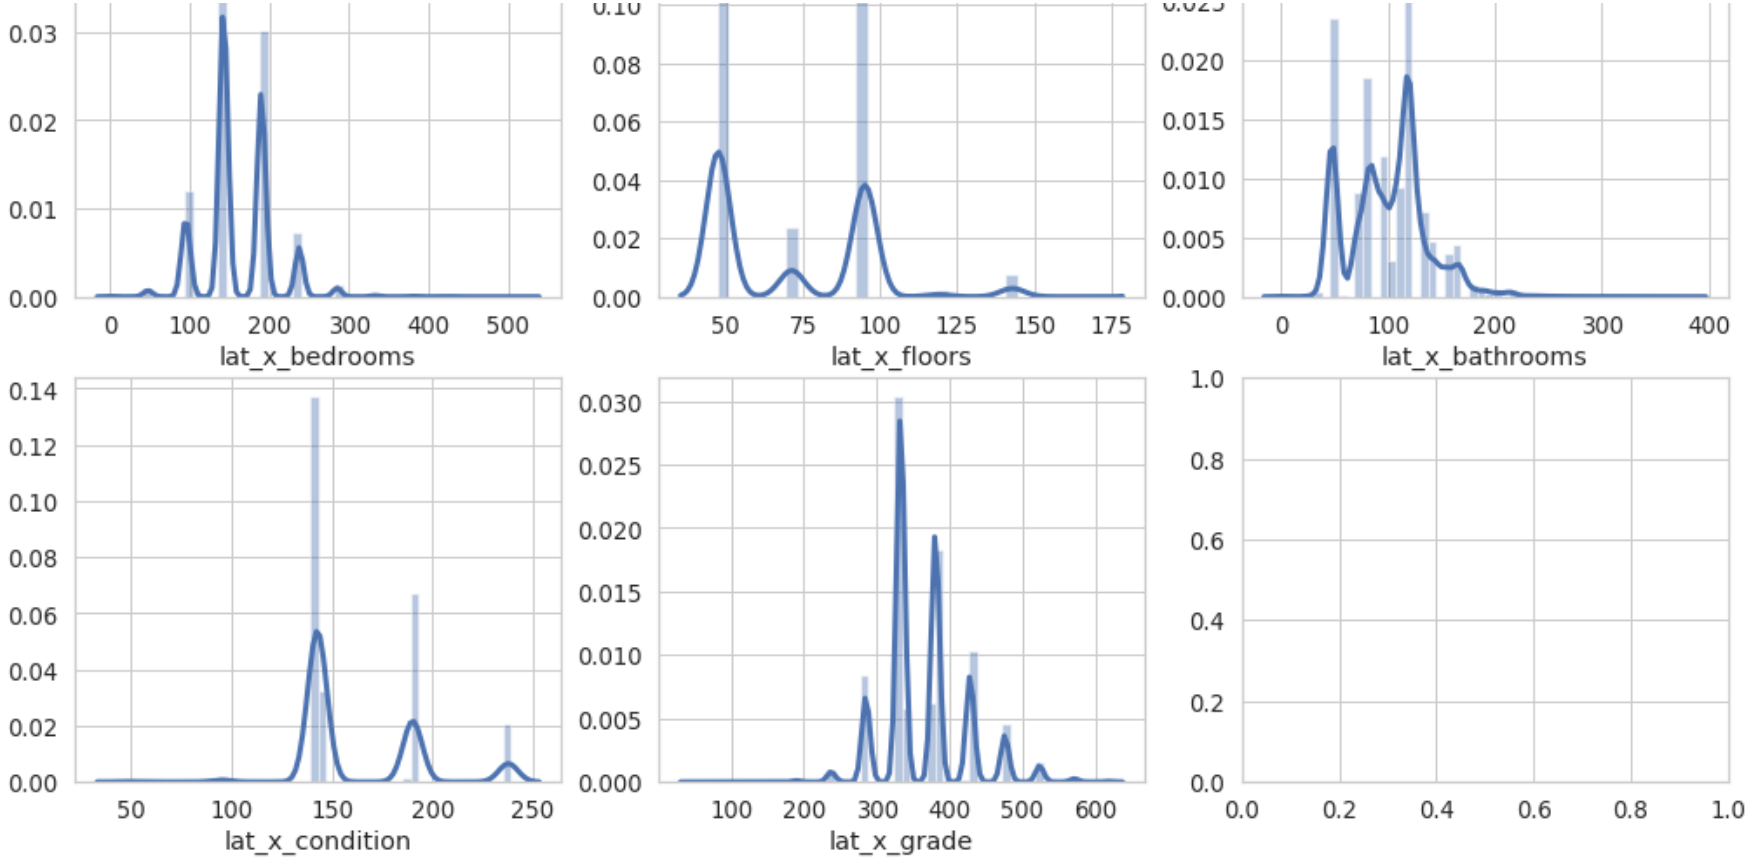

От некоторых из оставшихся фичей уместно взять логарифм, чтобы сделать их более похожими на нормально распределённые.

In [28]:
```
def take_logs(df):
    for colname in ["sqft_living", "sqft_lot", "sqft_living15", "sqft_lot15"]:
        df[colname] = np.log(df[colname] + 1)
    return df

transformer_lst.append(take_logs)
train_df = train_df.pipe(take_logs)
```

started 23:40:36 2019-04-13, finished in 23ms

Видно, что корреляции остались отчётливо выраженными.

In [29]:

```
1  plt.figure(figsize=(14, 10));
2  sns.heatmap(train_df.corr("spearman"), cmap="coolwarm")
3  plt.title("Корреляция Спирмена между признаками");
```

started 23:40:36 2019-04-13, finished in 2.01s

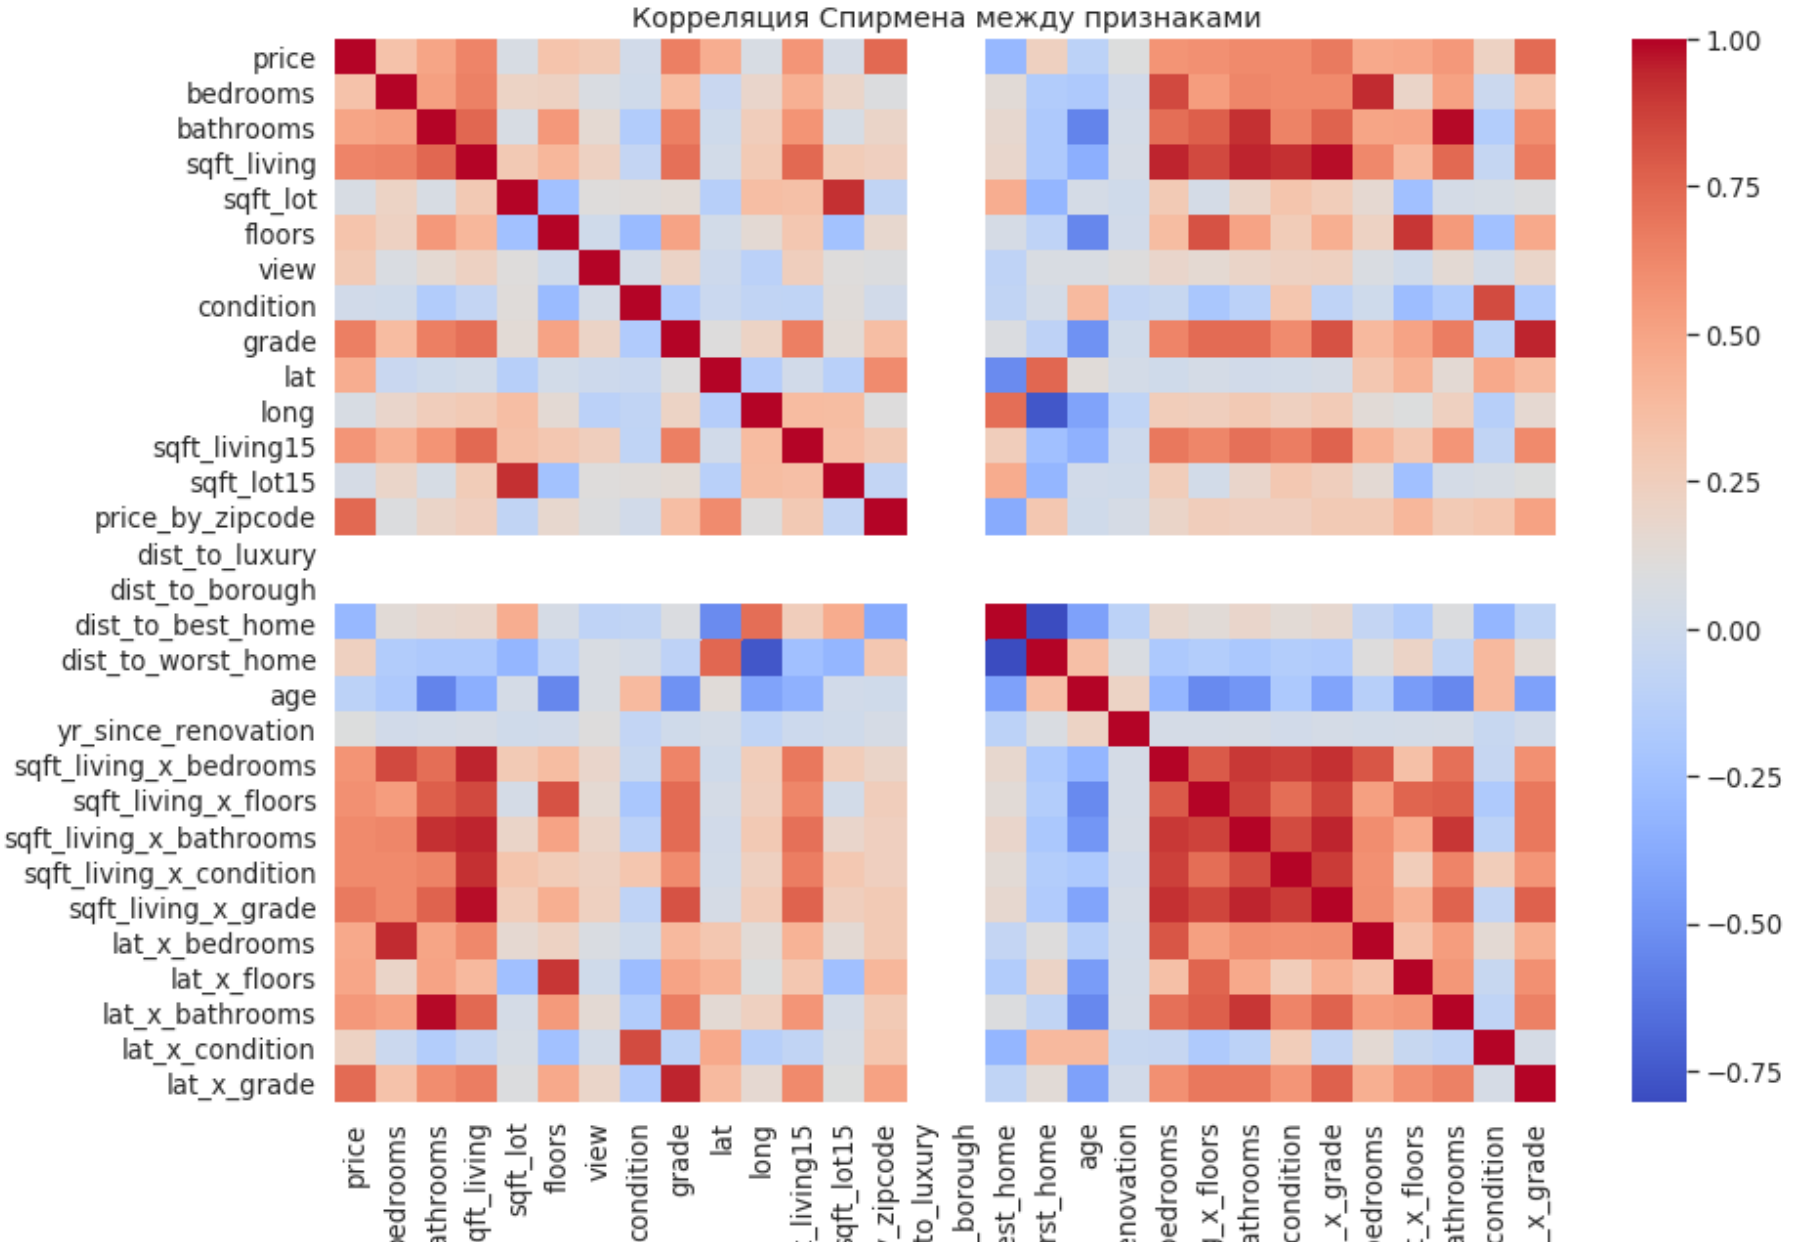

Посмотрим на зависимость целевой переменной `price` от признаков:

In [30]:

```
sns.set()

f_chunk_lst = [["condition", "grade", "view"],
               ["age",  "yr_since_renovation"],
               ["bedrooms", "bathrooms", "floors"],
               ["sqft_living", "sqft_lot"],
               ["dist_to_luxury", "dist_to_best_home", "dist_to_borough", "dist_to_worst_home"],
               ["sqft_living15", "sqft_lot15"]]

for chunk in tqdm_notebook(f_chunk_lst):
    sns.pairplot(x_vars=chunk,
                 y_vars=["price"],
                 data=train_df,
                 hue="grade",
                 palette="coolwarm");
```

started 23:40:38 2019-04-13, finished in 10.1s

```
HBox(children=(FloatProgress(value=0.0, max=6.0), HTML(value='')))
```

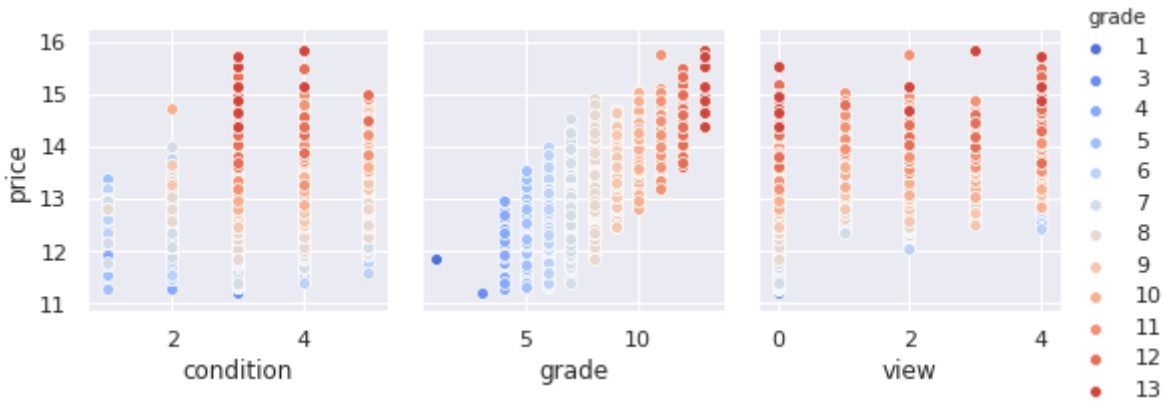


price
16
15
14
13
12
11
0
50
100
age
0
25
50
75
yr_since_renovation
grade
1
3
4
5
6
7
8
9
10
11
12
13

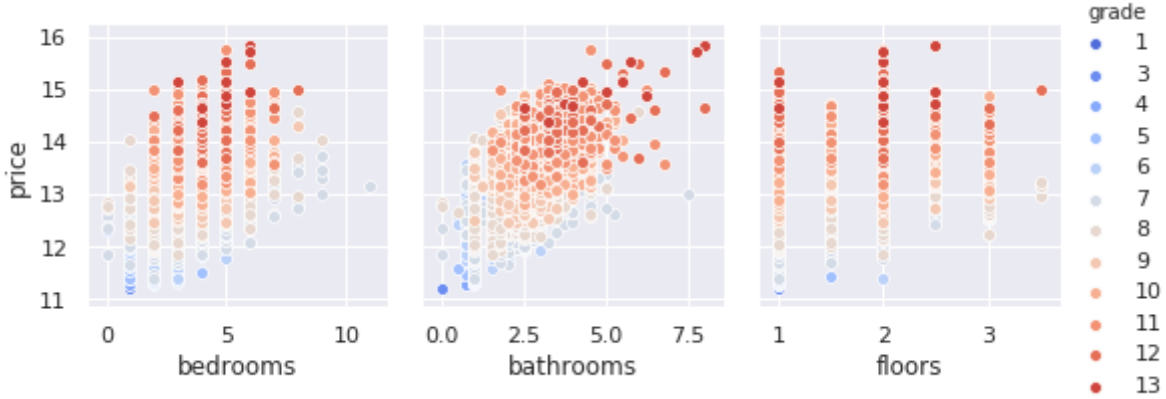
price
16
15
14
13
12
11
0
5
10
bedrooms
0.0
2.5
5.0
7.5
bathrooms
1
2
3
floors
grade
1
3
4
5
6
7
8
9
10
11
12
13

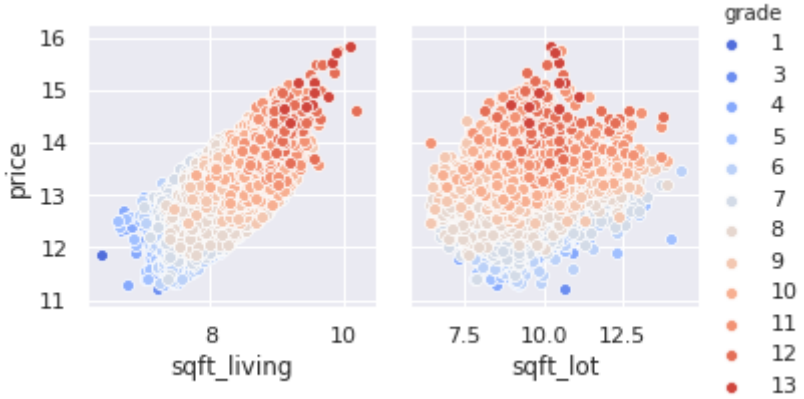
price
16
15
14
13
12
11
8
10
sqft_living
7.5
10.0
12.5
sqft_lot
grade
1
3
4
5
6
7
8
9
10
11
12
13

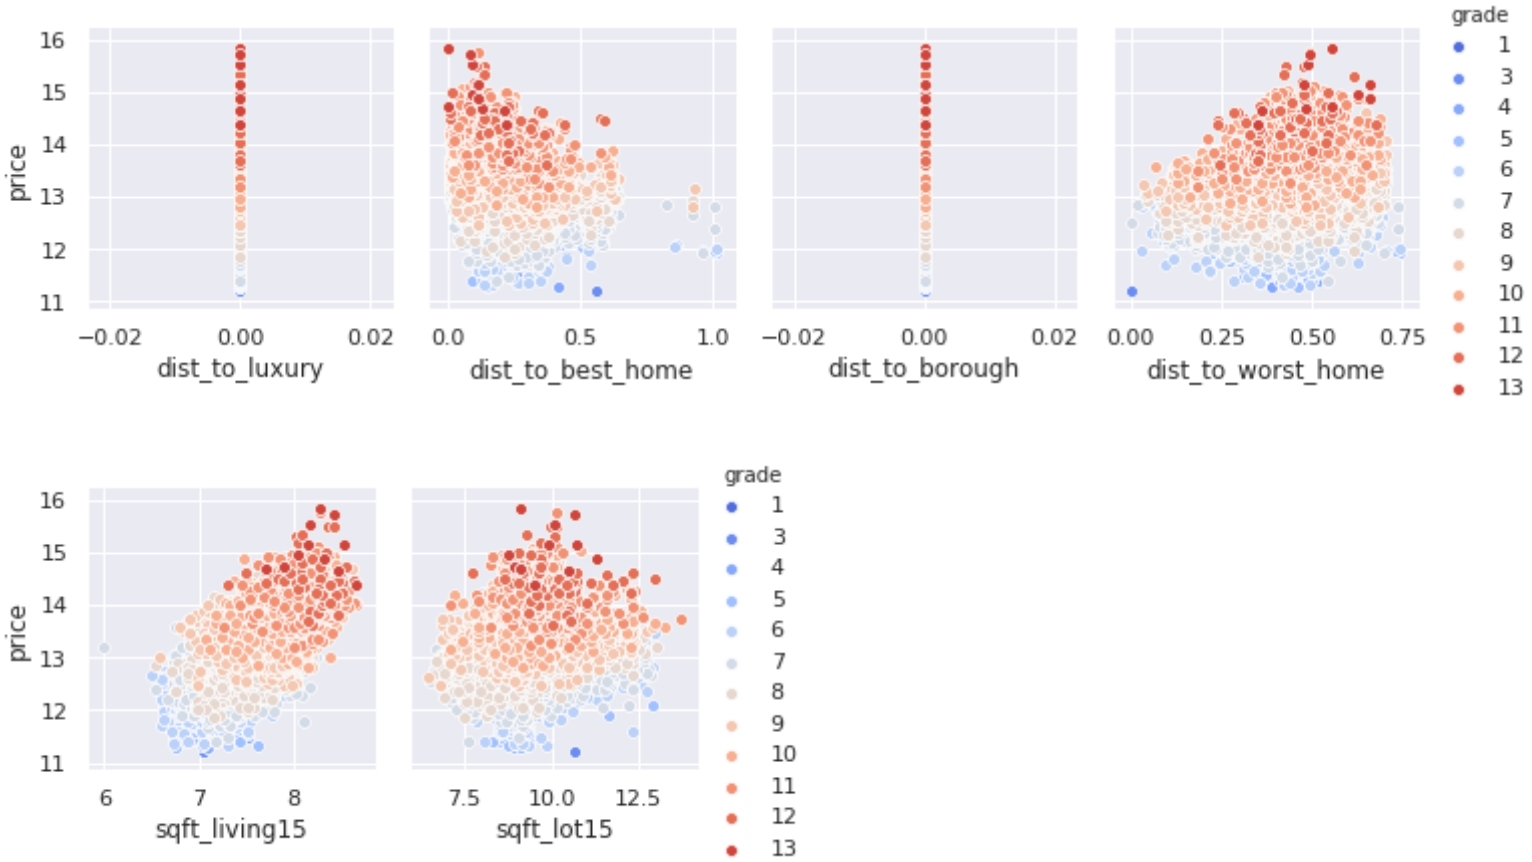

Чуть-чуть текста о неудачных экспериментах:

Мне казалось, что у меня есть секретное оружие: `UMAP` , статья 2018 года, `t-SNE + transform` .
Планировалось с его помощью понизить размерность таким образом, чтобы точки, максимально похожие друг на друга по совокупности значимых параметров, оказались рядом.

Я рассчитывал получить хорошее приближение значений на тесте, но не судьба.

In [ ]:

```
import umap

useful_column_lst = ["sqft_living",
                     "condition",
                     "grade",
                     "lat", "long",
                     "price_by_zipcode",
                     "dist_to_luxury",
                     "dist_to_best_home",
                     "dist_to_borough",
                     "dist_to_worst_home"]

umap_prj = umap.UMAP(verbose=True)
umap_prj.fit(train_df[useful_column_lst], train_df.price)
```

started 23:43:21 2019-04-13, finished in 24.1s

In [ ]:

```
def add_embedding(df):
    embedding = umap_prj.transform(df[useful_column_lst])
    df["umap_x"] = embedding[:, 0]
    df["umap_y"] = embedding[:, 1]
    return df

transformer_lst.append(add_embedding)
train_df = train_df.pipe(add_embedding)
```

started 23:43:45 2019-04-13, finished in 7ms

In [43]:

```
plt.figure(figsize=(20,10))
plt.scatter(umap_prj.embedding_[:, 0],
            umap_prj.embedding_[:, 1],
            c=train_df.price,
            cmap="jet")
```

started 23:43:45 2019-04-13, finished in 1.22s

Out[43]: <matplotlib.collections.PathCollection at 0x7f4a4ce16828>

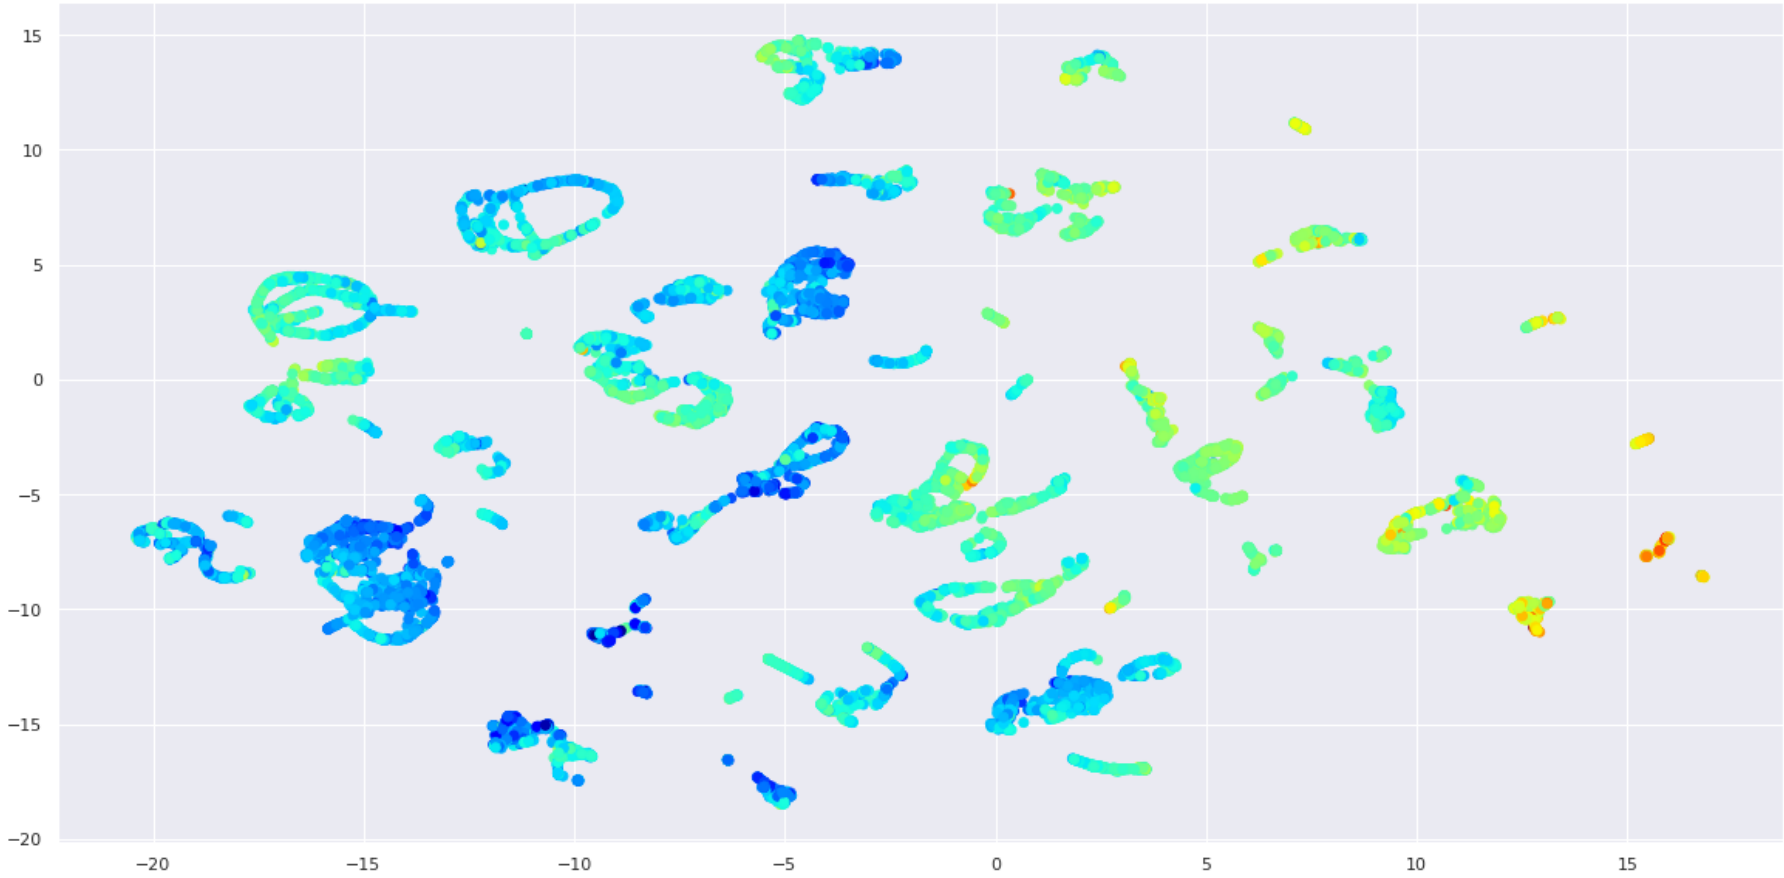

Показательно, как явственно очерчены кластеры домов, подобных по цене.
Тем не менее, добавление этой информации в модель ничего не давало, когда я пробовал (тут не стал).

In [44]:

```
test_df = pd.read_csv("houses_test.csv").drop(columns=["id"])
for f in tqdm_notebook(transformer_lst, "transformer map"):
    test_df = test_df.pipe(f)
```

started 23:43:46 2019-04-13, finished in 9.81s

```
HBox(children=(IntProgress(value=0, description='transformer map', max=11, style=ProgressStyle(description_
wid…

        completed  0  /  100 epochs
        completed  10  /  100 epochs
        completed  20  /  100 epochs
        completed  30  /  100 epochs
        completed  40  /  100 epochs
        completed  50  /  100 epochs
        completed  60  /  100 epochs
        completed  70  /  100 epochs
        completed  80  /  100 epochs
        completed  90  /  100 epochs
        completed  0  /  100 epochs
        completed  10  /  100 epochs
        completed  20  /  100 epochs
        completed  30  /  100 epochs
        completed  40  /  100 epochs
        completed  50  /  100 epochs
        completed  60  /  100 epochs
        completed  70  /  100 epochs
        completed  80  /  100 epochs
        completed  90  /  100 epochs
```

In [45]:

```
assert np.all(np.sort(train_df.drop(columns=["price"]).columns) == np.sort(test_df.columns))
```

started 23:43:56 2019-04-13, finished in 5ms

In [46]:
```
1  test_df.columns
```

started 23:43:56 2019-04-13, finished in 4ms

Out[46]:
```
Index(['bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors', 'view',
       'condition', 'grade', 'lat', 'long', 'sqft_living15', 'sqft_lot15',
       'price_by_zipcode', 'dist_to_luxury', 'dist_to_borough',
       'dist_to_best_home', 'dist_to_worst_home', 'age', 'yr_since_renovation',
       'sqft_living_x_bedrooms', 'sqft_living_x_floors',
       'sqft_living_x_bathrooms', 'sqft_living_x_condition',
       'sqft_living_x_grade', 'lat_x_bedrooms', 'lat_x_floors',
       'lat_x_bathrooms', 'lat_x_condition', 'lat_x_grade', 'umap_x',
       'umap_y'],
      dtype='object')
```

4. Финальное обучение

In [47]:

```
scaler = StandardScaler()
grid_cv = GridSearchCV(
    xgb.XGBRegressor(gamma=0.1, subsample=0.75,
                     n_estimators=1000, max_depth=5,
                     nthread=-1),
    {}, cv=5, verbose=True, scoring=mape_scorer, n_jobs=5
)

grid_cv.fit(scaler.fit_transform(train_df.drop(columns=["price"])), train_df.price)
y_pred = np.exp(grid_cv.predict(scaler.transform(test_df)))
-mape_scorer(grid_cv, scaler.transform(train_df.drop(columns=["price"])), train_df.price)
```

started 23:43:56 2019-04-13, finished in 31.7s

```
Fitting 5 folds for each of 1 candidates, totalling 5 fits

/home/common/ivanov.vv/anaconda3/envs/py37/lib/python3.6/site-packages/sklearn/preprocessing/data.py:645: D
ataConversionWarning: Data with input dtype int64, float32, float64 were all converted to float64 by Standa
rdScaler.
  return self.partial_fit(X, y)
/home/common/ivanov.vv/anaconda3/envs/py37/lib/python3.6/site-packages/sklearn/base.py:464: DataConversionW
arning: Data with input dtype int64, float32, float64 were all converted to float64 by StandardScaler.
  return self.fit(X, **fit_params).transform(X)
[Parallel(n_jobs=5)]: Using backend LokyBackend with 5 concurrent workers.
[Parallel(n_jobs=5)]: Done   2 out of   5 | elapsed:   25.5s remaining:   38.2s
[Parallel(n_jobs=5)]: Done   5 out of   5 | elapsed:   27.5s finished
/home/common/ivanov.vv/anaconda3/envs/py37/lib/python3.6/site-packages/ipykernel_launcher.py:17: DataConver
sionWarning: Data with input dtype int64, float32, float64 were all converted to float64 by StandardScaler.
/home/common/ivanov.vv/anaconda3/envs/py37/lib/python3.6/site-packages/ipykernel_launcher.py:18: DataConver
sionWarning: Data with input dtype int64, float32, float64 were all converted to float64 by StandardScaler.
```

Out[47]:

```
0.6082375676466303
```

Усредняем полученные .csv-файлы, в лучших традициях Kaggle.

In [48]:

```
submission_df = pd.DataFrame((y_pred + pd.read_csv("answer_20190407-1546-47.csv")["price"]) / 2 ,
                             columns=["price"])
submission_df.index += 1
submission_df.to_csv(f'answer_{datetime.now():%Y%m%d-%H%M-%S}.csv', index=True, index_label="index")
```

started 23:44:28 2019-04-13, finished in 32ms

Ещё чуть-чуть о неудачных попытках:

5. Что ещё я пробовал:

1. **Стекинг** (случайные леса + lasso-регрессия + kNN). То ли я обучил слишком мало моделей (я брал 4 леса, 2 регрессии и 1 kNN), то ли он просто не должен был здесь сработать. Я делал его грамотно: для каждой модели бил данные на 10 фолдов, обучал на 9, предсказывал 10, а также параллельно с этим предсказывал на тесте и потом усреднял предсказания по фолдам. Поверх этого я обучал бустинг, но он не справился нормально предсказать. MAPE был порядка 14.
2. **Нейросети**. Я накидал пару сеток на keras, но соотношение данные/фичи было слишком печальным, они не обучались. Структура была стандартная: (Dense, BatchNorm, ReLU, Dropout), 3-4 таких блока.
3. **Ансамблирование**. В какой-то момент я психанул и решил обучить все известные мне простые модели в большом количестве, а потом усреднить их предсказания, уповая на УЗБЧ. Вышло неплохо, но мой лучший результат не переплюнуло.

Вывод:

грамотный feature engineering и подбор гиперпараметров градиентного бустинга помогли мне достичь самого лучшего результата.