



# Доп. задачи анализа данных

Лекция "Временные ряды"



# 1. Временные ряды



**Временной ряд** — случайный процесс  $(y_t, t \in \mathbb{N})$ , являющийся значениями некоторого признака, измеренного через постоянные промежутки времени. Известны значения  $y_1, \dots, y_T$ .

### **Задача прогнозирования.**

Найти функцию  $f_T$ , т.ч. величина  $\hat{y}_{T+h|T} = f_T(y_1, \dots, y_T, h)$

как можно лучше приближает значение  $y_{T+h}$ ,


где  $h \in \{1, \dots, H\}$ ,

величина  $H$  — горизонт прогнозирования.

Кроме этого имеет смысл строить **предсказательный интервал**, то есть интервал  $(d_{T+h|T}, u_{T+h|T})$ , т.ч.  $P(d_{T+h|T} \leq y_{T+h} \leq u_{T+h|T}) \geq \alpha$ .




## Ежемесячное количество погибших в ДТП в провинции Онтарио (Канада) в 1960-1974 года



Данные




## Ежемесячное производство электроэнергии в Австралии (миллион киловатт-часов). Январь 1956 — Август 1995



Данные



Максимальный спрос на электричество в штате Виктория  
(Австралия) за 30-минутные интервалы с 10 января 2000 в течении  
115 дней




Данные



Ежемесячные продажи антидиабетических лекарств в Австралии.

Июль 1991 — Июнь 2008




Данные



# Заболевание коронавирусом

График заражений по миру









# Метрика

Посетители







# Попробуем приблизить линейной регрессией



# Попробуем приблизить линейной регрессией





## 2. Аналитика временных рядов.

### 2.1. Первые шаги



# Автокорреляционная функция

$$r_{\tau} = \widehat{corr}(y_t, y_{t+\tau}) = \frac{\sum_{t=1}^{T-\tau} (y_t - \bar{y})(y_{t+\tau} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2}, \quad \bar{y} = \frac{1}{T} \sum_{t=1}^T y_t$$

где  $\tau$  — лаг автокорреляции.

*Формула:* корреляция Пирсона ряда с самим собой со сдвигом на  $\tau$ .

*Смысл:* степень влияния значения  $y_t$  на значение  $y_{t+\tau}$ .



# Библиотека statsmodels

Автокорреляционная функция

```
statsmodels.tsa.stattools.acf(x, unbiased=False, nlags=40, qstat=False,  
fft=False, alpha=None, missing='none')
```

Возвращает: acf, confint, qstat, pvalues

Коррелограмма

```
statsmodels.graphics.tsaplots.plot_acf(x, ax=None, lags=None,  
alpha=0.05, use_vlines=True, unbiased=False, fft=False,  
title='Autocorrelation', zero=True, **kwargs)
```



# Критерий Льюнга-Бокса

$y_1, \dots, y_T$  — временной ряд

$r_\tau$  — автокорреляция с лагом  $\tau$

$H_0: r_1 = \dots = r_L = 0$

Q-статистика критерия


$$Q = T(T+2) \sum_{\tau=1}^L \frac{r_\tau^2}{T-\tau}$$

Если  $H_0$  верна, то  $Q \sim \chi_L^2$


Если  $H_0$  отвергается, то признается наличие значимой корреляции до лага  $L$  включительно.





Monthly traffic fatalities in Ontario 1960-1974



Коррелограмма









# STL-декомпозиция

Пусть  $s$  — известный заранее период сезонности.

Разложение временного ряда на несколько компонент:

- ▶ **Тренд** — плавное долгосрочное изменение уровня ряда.


Вычисляется с помощью скользящего окна длины  $s$ .

- ▶ **Сезонность** — циклические изменения уровня ряда  
с постоянным периодом сезонности  $s$ .

Усреднение наблюдений для каждого сезона после удаления тренда.  
Например, усреднение значений по апрелю за все года.

- ▶ **Ошибка** — непрогнозируемая случайная компонента ряда.

Monthly electricity production in Australia





# Библиотека statsmodels

```
statsmodels.tsa.seasonal.seasonal_decompose  
(x, model='additive', filt=None, freq=None, two_sided=True)
```

Возвращает: results

results.trend — тренд


results.seasonal — сезонность

results.resid — остатки




# Календарные эффекты

Ежемесячное производство молока (фунты на корову) [Данные]



Интервалы времени не равны, т.к. месяцы разной длины.

Поделим значения на количество дней в месяце:





## 2. Аналитика временных рядов.

### 2.2. Стационарность

# Стационарные случайные процессы

Случайный процесс  $(X_t, t \in T)$  называется **стационарным**

- ▶ **в узком смысле** если  $\forall t_1, \dots, t_n, \tau$  вектор  $(X_{t_1+\tau}, \dots, X_{t_n+\tau})$  совпадает по распределению с  $(X_{t_1}, \dots, X_{t_n})$ .
- ▶ **в широком смысле** если
  1.  $X_t$  является  $L^2$ -процессом, т.е.  $EX_t^2 < +\infty$  для любого  $t$ .
  2.  $EX_t$  не зависит от  $t$ .
  3.  $\text{cov}(X_{t+\tau}, X_{s+\tau}) = \text{cov}(X_t, X_s)$  для любых  $t, s, \tau$ .
- ▶ **для гауссовских** определения эквивалентны.

*Пример.*  $X_t = \xi_1 \cos t + \xi_2 \sin t$ , где  $\xi_1, \xi_2 \sim \text{Bern}_{\pm 1}(1/2)$  и незав.

$EX_1 = 0$ ,  $\text{cov}(X_t, X_s) = \cos t \cos s D\xi_1 + \sin t \sin s D\xi_2 = \cos(t - s)$   
 $\implies$  есть стационарность в широком смысле.

Но при  $t = 0$ :  $X_0 = \xi_1 \in \{-1, 1\}$

при  $t = \pi/4$ :  $X_{\pi/4} = (\xi_1 + \xi_2) / \sqrt{2} \in \{-\sqrt{2}, 0, \sqrt{2}\}$

Распределения разные  $\implies$  поэтому нет стационар. в узком смысле.



# Критерий KPSS (Kwiatkowski-Phillips-Schmidt-Shin)

$H_0$ : ряд  $y_t$  стационарен

Статистика

$$KPSS(y) = \frac{1}{T^2} \sum_{t=1}^T S_t^2 / \hat{\sigma}_y^2, \quad \text{где } S_t = \sum_{i=1}^t y_i, \quad \hat{\sigma}_y^2 = \frac{1}{T} \sum_{t=1}^T y_t^2$$

При  $H_0$  имеет табличное распределение.

```
statsmodels.tsa.stattools.kpss(y)
/usr/local/lib/python3.5/dist-packages/statsmodels/tsa/stattools.py:125
8: InterpolationWarning: p-value is smaller than the indicated p-value
   warn("p-value is smaller than the indicated p-value", InterpolationWa
rning)
(1.3136750533447588,
 0.01,
 15,
 {'1%': 0.739, '10%': 0.347, '2.5%': 0.574, '5%': 0.463})
```

Значения  $p$ -value рассчитаны только в интервале (0.01, 0.1).





# Приведение к стационарному: стабилизация дисперсии

## Зачем?

Методы прогнозирования, требующие стационарность, лучше обрабатывают стационарные ряды.

Как правило, это сильно влияет на предсказательный интервал.

## Преобразования:

1. Класс преобразований Бокса-Кокса:

$$z_t = \begin{cases} \ln y_t, & \lambda = 0 \\ (y_t^\lambda - 1)/\lambda, & \lambda \neq 0 \end{cases}$$

2. Если есть предположения о зависимости  $Dy_t$  от  $t$ , то можно рассмотреть ряд  $z_t = y_t / \sqrt{Dy_t}$

После построения прогноза для преобразованного ряда нужно сделать обратное преобразование.



# Приведение к стационарным: тренд и сезонность

## Преобразования:

1. Дифференцирование ряда — переход к ряду  $(y'_t, t \in \{2, \dots, T\})$ ,

где  $y'_t = y_t - y_{t-1}$ .


Используется для снятия тренда.

2. Сезонное дифференцирование ряда — переход к ряду  $(y'_t, t \in \{s + 1, \dots, T\})$ , где  $y'_t = y_t - y_{t-s}$ ,  $s$  — длина сезона.


Преобразования можно применять несколько раз.

Обычно сначала применяют сезонное дифференцирование.


Monthly anti-diabetic drug sales in Australia



Monthly anti-diabetic drug log sales in Australia



Annual change in monthly anti-diabetic drug log sales in Australia



Критерий KPSS:

Исходный ряд

$pvalue < 0.01$

логарифмированный

$pvalue < 0.01$

еще и сезонно

дифференцированный

$pvalue > 0.01$



## 3. Прогнозирование

### 3.1. Анализ остатков



# Остатки

$y_1, \dots, y_T$  — временной ряд

$f$  — прогнозирующая модель, построенная по  $y_1, \dots, y_T$

$\hat{y}_{t|t-1} = f(y_1, \dots, y_{t-1}, 1)$  — прогнозы на обучении

$\hat{\varepsilon}_t = y_t - \hat{y}_{t|t-1}$  — остатки модели

Необходимые свойства остатков:

1. **Несмещенность** — равенство среднего нулю:  
Критерий Стьюдента (для норм.), критерий Уилкоксона
2. **Стационарность** — отсутствие зависимости от времени:  
Визуальный анализ, критерий KPSS
3. **Неавтокоррелированность** — отсутствие завис. от значений:  
Кореллограмма, критерий Льюнга-Бокса ( $\chi^2_{L-k}$ )



# Остатки

Желательные свойства остатков:

## 4. **Нормальность:**

Q-Q plot, критерий Шапиро-Уилка

## 5. **Гомоскедастичность:**

Визуальный анализ, критерий Бройша-Пагана

- ▶ Если свойства 1-3 не выполняются, прогноз можно улучшить.
- ▶ Свойства 4-5 влияют на построение доверительного интервала:
  - ▶ Выполняются  $\implies$  теоретическим способом;
  - ▶ Не выполняются  $\implies$  с помощью семплирования.



## 3. Прогнозирование

### 3.2. Модели экспоненциального сглаживания

## Простое экспоненциальное сглаживание

Прогноз средним:  $\hat{y}_{T+1|T} = \sum_{t=t_0}^T y_t$

Прогноз взвешенным средним с экспоненциально убыв. весами:

$$\begin{aligned}\hat{y}_{T+1|T} &= \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots = \\ &= \alpha y_T + (1 - \alpha)\hat{y}_{T|T-1}\end{aligned}$$


- ▶  $\alpha \approx 1 \rightarrow$  больший вес последним точкам:  $\hat{y}_{T+1|T} \approx y_T$ ;
- ▶  $\alpha \approx 0 \rightarrow$  большее сглаживание:  $\hat{y}_{T+1|T} \approx \bar{y}$ .

Прогноз константный:  $\hat{y}_{T+h|T} = \hat{y}_{T+1|T}$






# Простое экспоненциальное сглаживание






# Простое экспоненциальное сглаживание





# Простое экспоненциальное сглаживание





## Учет тренда

Аддитивный линейный тренд (метод Хольта):

$$\hat{y}_{t+d|t} = l_t + db_t,$$

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1})$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$$

Мультипликативный линейный тренд:

$$\hat{y}_{t+d|t} = l_t b_t^d,$$

$$l_t = \alpha y_t + (1 - \alpha)(l_{t-1} b_{t-1})$$

$$b_t = \beta \frac{l_t}{l_{t-1}} + (1 - \beta)b_{t-1}$$



## Учет сезонности

Аддитивная сезонность с периодом длины  $m$   
(метод Хольта-Уинтерса):

$$\hat{y}_{t+d|t} = l_t + db_t + s_{t-m+(d \bmod m)},$$

$$l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1})$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$$



# Учет сезонности

Мультипликативная сезонность:

$$\hat{y}_{t+d|t} = (l_t + db_t)s_{t-m+(d \bmod m)},$$

$$l_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(l_{t-1} + b_{t-1})$$

$$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$$

$$s_t = \gamma \frac{y_t}{l_{t-1} - b_{t-1}} + (1 - \gamma)s_{t-m}$$



# Адаптивное экспоненциальное сглаживание

Пусть  $\hat{\varepsilon}_t = y_t - \hat{y}_t$  — ошибка прогноза, сделанного на шаге  $t - 1$ .

$E_t = \gamma \hat{\varepsilon}_t + (1 - \gamma)E_{t-1}$  — среднее значение ошибки

$A_t = \gamma |\hat{\varepsilon}_t| + (1 - \gamma)A_{t-1}$  — средний разброс ошибки

Берем

$$\alpha_t = \min \left( \frac{|E_t|}{A_t}, 1 \right)$$

Обычно берут  $\gamma \in (0.05, 0.1)$ .



## 3. Прогнозирование

### 3.3. Модели типа ARIMA





## Модель скользящего среднего $MA(q)$

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

где  $y_t$  — стационарный ряд со средним  $\mu$ ;

$\varepsilon_t$  — гауссовский белый шум ( $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$  и независимы).

## Модель авторегрессии $AR(p)$

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t$$

где  $y_t$  — стационарный ряд;

$\varepsilon_t$  — гауссовский белый шум ( $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$  и независимы).

*Для стационарности нужны условия на коэффициенты  $\varphi_1, \dots, \varphi_p$ .*



# Связь модели авторегрессии с линейной регрессией

## Модель авторегрессии $AR(p)$

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t$$

где  $y_t$  — стационарный ряд;

$\varepsilon_t$  — гауссовский белый шум ( $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$  и независимы).

Это модель линейной регрессией для которой

- ▶ **Отклик:**  $y_t$  — знач. ряда в мом. времени  $t$
- ▶ **Признаки:**  $y_{t-1}, \dots, y_{t-p}$  — знач. ряда в пред. мом. времени



# Стационарность моделей

$L$  — оператор сдвига:  $Ly_t = y_{t-1}$ ,  $L\varepsilon_t = \varepsilon_{t-1}$ .

$$y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1} + \dots + \theta_q\varepsilon_{t-q} = \mu + b(L)\varepsilon_t$$

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t \implies a(L)y_t = \alpha + \varepsilon_t$$

где  $b(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ ,

$$a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p.$$

**Теорема:**

1. Любой стационарный процесс  $AR(p)$  представим в виде  $MA(\infty)$ .
2. Процесс  $AR(p)$  стационарен  $\iff$   
все комплексные корни  $a(z) = 0$  лежат вне единичного круга.



## Модель $ARMA(p, q)$

Соединяем  $AR(p)$  и  $MA(q)$

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} \\ + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Эквивалентная запись:

$$a(L)y_t = \alpha + b(L)\varepsilon_t \quad \text{или} \quad y_t = \mu + \frac{b(L)}{a(L)}\varepsilon_t,$$

где  $a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p$ ,

$$b(z) = 1 + \theta_1 z + \dots + \theta_q z^q,$$

$L$  — оператор сдвига:  $Ly_t = y_{t-1}$ ,  $L\varepsilon_t = \varepsilon_{t-1}$ .



## Модель $ARIMA(p, d, q)$

Модель  $ARIMA(p, d, q)$  для  $y_t$

= модель  $ARMA(p, q)$  для ряда разностей порядка  $d$  ряда  $y_t$ .

Что такое разность порядка 1?  $y_t - y_{t-1} = (1 - L)y_t$

Получаем формулу модели  $ARIMA$ :

$$a(L)(1 - L)^d y_t = \alpha + b(L)\varepsilon_t \quad \text{или} \quad (1 - L)^d y_t = \mu + \frac{b(L)}{a(L)}\varepsilon_t.$$

То есть многочлен  $\tilde{a}(z) = a(z)(1 - z)^d$  имеет  $d$  единичных корней.

*Свойство:* Позволяет учесть нестационарности, в частности, тренд.



# Оценка коэффициентов в ARIMA

Пусть  $p, d, q$  фиксированы.

Предполагаем, что  $\varepsilon_t$  — гауссовский белый шум.

$\Rightarrow y_t$  — гауссовский случайный процесс.

Даны значения временного ряда  $y_1, \dots, y_T$ , и их совместная плотность согласно модели  $ARIMA(p, d, q)$  равна  $p_{\theta, \varphi, \alpha}(a_1, \dots, a_T)$ .

Тогда  $L_y(\theta, \varphi, \alpha) = p_{\theta, \varphi, \alpha}(y_1, \dots, y_T)$  — функция правдоподобия.

В качестве оценок коэффициентов берется оценка макс. правд..

Почему  $p, d, q$  нельзя оценивать с помощью ОМП?

*Максимизация  $L_y(\theta, \varphi, \alpha)$  по  $p, d, q$  приводит к переобучению.*

*Это гиперпараметры.*



## Оценка $\rho$ и $q$

**Частичная автокорреляция (PACF)** — корреляция ряда с собой после снятия линейной зависимости от предыдущих элементов ряда.

$$\gamma_h = \begin{cases} \text{corr}(y_{t+1}, y_t), & h = 1; \\ \text{corr}(y_{t+h} - y_{t+h}^{h-1}, y_t - y_t^{h-1}), & h \geq 2, \end{cases}$$

где  $y_t^{h-1}$  — линейная регрессия на  $y_{t-1}, y_{t-2}, \dots, y_{t-(h-1)}$ :

$$y_t^{h-1} = \beta_1 y_{t-1} + \beta_2 y_{t-2} + \dots + \beta_{h-1} y_{t-(h-1)}$$

$$y_{t+h}^{h-1} = \beta_1 y_{t+h-1} + \beta_2 y_{t+h-2} + \dots + \beta_{h-1} y_{t+1}$$


*Пример для  $h = 2$ :*

$$\gamma_2 = \text{corr}(y_{t+2} - \beta_1 y_{t+1}, y_t - \beta_1 y_{t-1})$$

где  $\beta_1$  — МНК-оценка в модели  $y_t = \beta y_{t-1}$



# Оценка $\rho$ и $q$





## Оценка $p$ и $q$

Начальное приближение  $p$ : последний значимый пик у ACF.

Начальное приближение  $q$ : последний значимый пик у PACF.

Далее используем поиск по сетке вокруг подобранных значений, минимизируя информационный критерий:

$AIC = -2l^* + 2(p + q + 1)$  — критерий Акаике;

$AIC_c = -2l^* + \frac{2(p+q+1)(p+q+2)}{T-p-q-2}$  — критерий Акаике (короткие ряды);

$BIC = -2l^* + (\log T - 2)(p + q + 1)$  — критерий Шварца,

где  $l^* = \ln L_y(\hat{\theta}, \hat{\phi}, \hat{\alpha})$  — логарифм функции правд. (для ОМП).



## Итог: прогнозирование с помощью ARIMA

1. Анализ выбросов: замена нерелевантных выбросов на NA или "усреднение" по соседним элементам.
2. Стабилизация дисперсии (преобразования).
3. Дифференцирование, если ряд не стационарен.
4. Выбор пилотных  $p$  и  $q$  по ACF и PACF.
5. Вокруг этих параметров подбираем оптим. модель по  $AIC/AIC_c$ .
6. Если для полученной модели не выполняются необходимые свойства остатков, модель можно улучшить.



# Итог: прогнозирование с помощью ARIMA

## 7. Пошаговое построение прогноза:

- ▶ для  $t \leq T$ :  $\varepsilon_t \implies \hat{\varepsilon}_t = y_t - \hat{y}_t$ ;
- ▶ для  $t > T$ :  $\varepsilon_t \implies 0$ ;
- ▶ для  $t > T$ :  $y_t \implies \hat{y}_t$ .

## 8. Построение предсказательного интервала:

- ▶ если остатки модели нормальны и гомоскедастичны, то строится теоретический предсказательный интервал;
- ▶ иначе интервалы строятся с помощью симуляции.



Слишком просто...

Давайте усложнять!



# Модель SARIMA

ARIMA( $p, d, q$ ):

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)} \varepsilon_t$$

Пусть  $s$  — период сезонности ряда. Добавим в модель

ARIMA( $p, d, q$ ) компоненты на значения в предыдущие сезоны...

SARIMA( $p, d, q$ ) $\times$ ( $P, D, Q$ ) $_s$ :

$$(1 - L)^d (1 - L^s)^D y_t = \mu + \frac{b(L)B(L^s)}{a(L)A(L^s)} \varepsilon_t,$$

где  $a(z) = 1 - \varphi_1 z - \dots - \varphi_p z^p$ ,  $b(z) = 1 + \theta_1 z + \dots + \theta_q z^q$ ,

$$A(z) = 1 - \varphi_1^s z - \dots - \varphi_p^s z^p, \quad B(z) = 1 + \theta_1^s z + \dots + \theta_q^s z^q.$$



Еще усложним?



# Модель ARIMAX

ARIMA( $p, d, q$ ):

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)} \varepsilon_t$$

Пусть  $x_t \in \mathbb{R}^n$  — процесс регрессоров, *известный до начала прогноза*.

Простой вариант:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{1}{a(L)} x_t^i + \frac{b(L)}{a(L)} \varepsilon_t$$

Общий случай:

$$(1 - L)^d y_t = \mu + \sum_{i=1}^n \frac{u_i(L)}{v_i(L)} x_t^i + \frac{b(L)}{a(L)} \varepsilon_t$$

Пример:  $x_t = I\{\text{в момент времени } t \text{ праздник}\}$



# Модель SARIMAX

ARIMA( $p, d, q$ ):

$$(1 - L)^d y_t = \mu + \frac{b(L)}{a(L)} \varepsilon_t$$

Соединим...

SARIMAX( $p, d, q$ ) $\times$ ( $P, D, Q$ ) $_s$ :

$$(1 - L)^d (1 - L^s)^D y_t = \mu + \sum_{i=1}^n \frac{u_i(L)}{v_i(L)} x_t^i + \frac{b(L)B(L^s)}{a(L)A(L^s)} \varepsilon_t$$





# Аналогия с линейной регрессией

SARIMAX( $p, d, q$ ) $\times$ ( $P, D, Q$ ) $_s$ :

$$(1 - L)^d(1 - L^s)^D y_t = \mu + \sum_{i=1}^n \frac{u_i(L)}{v_i(L)} x_t^i + \frac{b(L)B(L^s)}{a(L)A(L^s)} \varepsilon_t$$

Это линейная по признакам модель, в которой

- ▶ **Отклик:**  $y_t$  — знач. ряда в мом. времени  $t$
- ▶ **Признаки:**
  - ▶  $y_{t-1}, \dots, y_{t-p}$  — знач. ряда в пред. мом. времени
  - ▶ Знач. ряда за предыдущие сезоны
  - ▶ Значения признаков в пред. мом. времени
  - ▶ Значения признаков в пред. сезоны
- ▶ **Ошибка:** сумма шума за пред. мом. времени и пред. сезоны.



## Пакет forecast в R

Построение модели:

```
auto.arima(y, d = NA, D = NA, max.p = 5, max.q = 5, max.P  
= 2, max.Q = 2, max.order = 5, max.d = 2, max.D = 1,  
start.p = 2, start.q = 2, start.P = 1, start.Q = 1,  
stationary = FALSE, seasonal = TRUE, ic = c("aicc", "aic",  
"bic"), stepwise = TRUE, trace = FALSE, approximation =  
(length(x) > 150 | frequency(x) > 12), truncate = NULL,  
xreg = NULL, test = c("kpss", "adf", "pp"), seasonal.test  
= c("ocsb", "ch"), allowdrift = TRUE, allowmean = TRUE,  
lambda = NULL, biasadj = FALSE, parallel = FALSE,  
num.cores = 2, x = y, ...)
```



## Пакет forecast в R

Прогнозирование:

```
forecast(object, h = ifelse(frequency(object) > 1, 2 *  
frequency(object), 10), level = c(80, 95), fan = FALSE,  
robust = FALSE, lambda = NULL, find.frequency = FALSE,  
allow.multiplicative.trend = FALSE, model = NULL, ...)
```



## 3. Прогнозирование

### 3.4. Нелинейные модели



# Идея

Модель  $AR(p)$ :

$$y_t = \alpha + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t = f(y_{t-1}, \dots, y_{t-p}, \varepsilon_t),$$

где  $f$  — линейная функция.

**Идея:** функция  $f$  строится произв. методом машинного обучения.

Примеры признаков:

1. несколько предыдущих значений ряда;
2. несколько последних сезонных компонент;
3. максимальное и минимальное значение ряда за период;
4. степень изменчивости ряда за период;
5. экзогенные факторы.



# Построение модели

## Способ 1.

Для каждого  $t_0 \leq t \leq T$  создается объект обучающей выборки:

- ▶ *признаковое описание* — история ряда до мом. времени  $t - 1$ ;
- ▶ *целевая метка* — значение  $y_t$ .

Предсказание строится на шаг вперед, далее рекурсивно.

## Способ 2.

Для каждого  $t_0 \leq t \leq T - h + 1$  создается  $h$  объектов обуч. выборки:

- ▶ *признаковое описание* — история ряда до мом. времени  $t - 1$ ;
- ▶ *целевая метка* — значение  $y_t$ ;
- ▶ *число*  $j \in \{1, \dots, h\}$  — насколько шагов строить прогноз.

## 3. Прогнозирование

### 3.5. Нейронные сети

Позже :))



## 3. Прогнозирование

### 3.5. Качество моделей





## Метрики качества

Средняя квадратичная ошибка

$$MSE = \frac{1}{T - R + 1} \sum_{t=R}^T (\hat{y}_t - y_t)^2.$$

Средняя абсолютная ошибка

$$MAE = \frac{1}{T - R + 1} \sum_{t=R}^T |\hat{y}_t - y_t|.$$

Средняя абсолютная ошибка в процентах

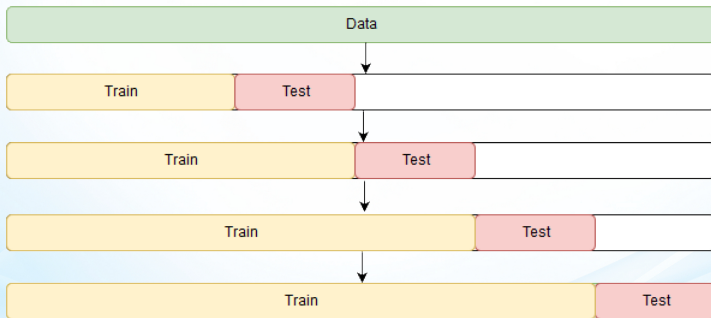
$$MAPE = \frac{100}{T - R + 1} \sum_{t=R}^T \left| \frac{\hat{y}_t - y_t}{y_t} \right|.$$

Симметричная средняя абсолютная ошибка в процентах

$$SMAPE = \frac{200}{T - R + 1} \sum_{t=R}^T \left| \frac{\hat{y}_t - y_t}{\hat{y}_t + y_t} \right|.$$



# Кросс-валидация для временных рядов



# Кросс-валидация для временных рядов

Как выбрать лучшую модель среди тех, которые обладают хорошими свойствами?

1.1 Считаем качество прогнозов  $\hat{y}_{t_0+1|t_0}, \dots, \hat{y}_{t_0+\Delta t|t_0}$

1.2 Считаем качество прогнозов  $\hat{y}_{t_0+\Delta t+1|t_0+\Delta t}, \dots, \hat{y}_{t_0+2\Delta t|t_0+\Delta t}$

...

1.k Считаем качество прогнозов

$\hat{y}_{t_0+k\Delta t+1|t_0+k\Delta t}, \dots, \hat{y}_{t_0+(k+1)\Delta t|t_0+k\Delta t}$

2. Усредняем полученные значения качества.

3. Выбираем модель, которая показывает наилучшее усредненное качество.



**ВСЁ!**