



Машинное обучение

Съезд II



Задача классификации

Классификация

\mathcal{X} — пространство объектов,

\mathcal{Y} — конечное множество классов.

Истинное правило классификации:
неизвестная функция $f : \mathcal{X} \rightarrow \mathcal{Y}$.

Пространство \mathcal{X} разбивается
на *подпространства (decision regions)*
 $\mathcal{X}_y = \{x \in \mathcal{X} \mid f(x) = y\}$,
границы которых называются
разделяющими поверхностями
(*decision surfaces*).





Часто $\mathcal{X} \subset \mathbb{R}^d$, в т.ч. могут быть категориальные.

Типы классификации

1. Двухклассовая.

$$\mathcal{Y} = \{0, 1\} \text{ или } \mathcal{Y} = \{-1, 1\}.$$

2. Многоклассовая.

$$\mathcal{Y} = \{1, \dots, K\} \text{ или } \mathcal{Y} = \{(1, 0, \dots, 0), (0, 1, \dots, 0), \dots, (0, 0, \dots, 1)\}.$$

Задача классификации:

предложить оценку $\hat{f} : \mathcal{X} \rightarrow \mathcal{Y}$ правила классификации на основе обуч. выборки $(x_1, Y_1), \dots, (x_n, Y_n)$, где $x_i = (x_{i1}, \dots, x_{id}) \in \mathcal{X}$, $Y_i \in \mathcal{Y}$.
как можно точнее приближающую неизвестное правило классиф-ции.

Оценку правила классификации чаще будем называть **моделью**.



Вероятностная природа

Часто предполагается случайная принадлежность классу:

функция f при повторении эксперимента один и тот же объект $x \in \mathcal{X}$ может отнести как одному классу, так и к другому.


\Rightarrow имеет смысл **предсказывать вероятность** $P_x(Y = y)$
принадлежности объекта x каждому из классов.

Точечная оценка: $\arg \max_{y \in \mathcal{Y}} P_x(Y = y)$

Если классы неравнозначны:

$\arg \max_{y \in \mathcal{Y}} [w_y P_x(Y = y)],$

w_y — приоритетность класса



Примеры:

1. $P(Y = 0 \mid X = x_2) = 0.95, \quad P(Y = 1 \mid X = x_2) = 0.05$
уверенное предсказание в пользу класса 0
2. $P(Y = 0 \mid X = x_1) = 0.55, \quad P(Y = 1 \mid X = x_1) = 0.45$
модель не уверена в предсказании.



Типы моделей

Среди моделей, предсказывающих вероятность принадлежности классу, можно выделить две категории моделей:

1. Дискриминативные.

Оценивается $P_x(Y = y)$ для каждого $x \in \mathcal{X}$.

Например, $\mathcal{P} = \{P_{\varphi(x, \theta)}\}$ — семейство распр. с параметром θ .

2. Генеративные.

Признаки X предполагаются случайными.

Оценивается совместная плотность $p_{X,Y}(x, y)$.

Вероятность класса считается, например, по формуле Байеса

$$P(Y = y | X = x) = \frac{p(x | Y = y) P(Y = y)}{\sum_{y \in \mathcal{Y}} p(x | Y = y) P(Y = y)}.$$

Это не есть байесовский вывод!

Генеративный подход сложнее дискриминативного.

Линейные модели

$y(x) = \theta^T x$ — линейная модель регрессии.

Линейная модель в классификации:

разделяющая поверхность — линейная гиперплоскость в пр-ве \mathcal{X} .

В многоклассовом случае — при дополнении до гиперплоскости.

Например, при $\mathcal{Y} = \{0, 1\}$ линейна модель $y(x) = \text{sign}(\theta^T x)$.



Замечание.

Исходное пр-во признаков может быть предварительно преобразовано с помощью нелинейных функций, в частности можно включить константный признак. В таком случае разделяющая поверхность лин. классификатора не будет линейной в исходном пространстве.



ВСЁ!